# Data Science Machine Learning Python course

Thang Nguyen
Viet Nguyen

http://www.viet-it.com

# Nội dung

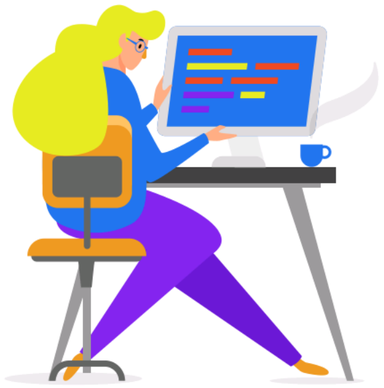

01 **Machine Learning**
Tổng quan về Machine Learning

02 **Supervised Learning**
Các mô hình cơ bản

03 **Unsupervised Learning**
Các mô hình cơ bản

04 **Data Visualization**
Trực quan hóa dữ liệu

05 **Model evaluation**
Đánh giá mô hình

06 **Projects**
Xây dựng mô hình với các datasets

# Tổng quan về Machine Learning

# Tổng quan về Machine Learning và Data Science

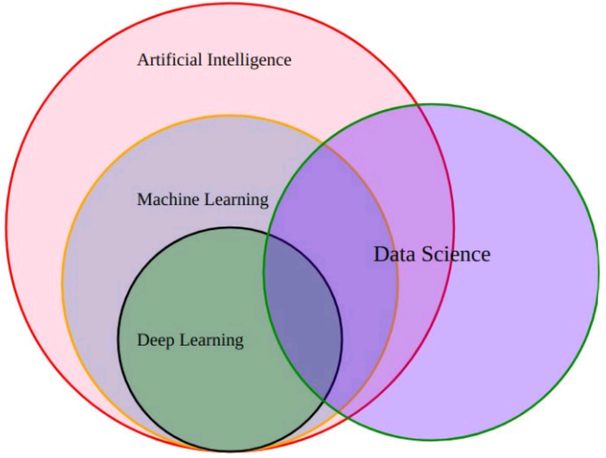


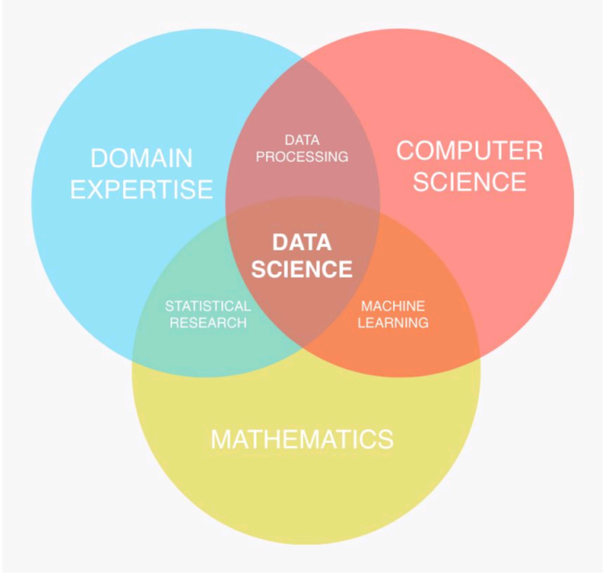

# Tổng quan các khái niệm

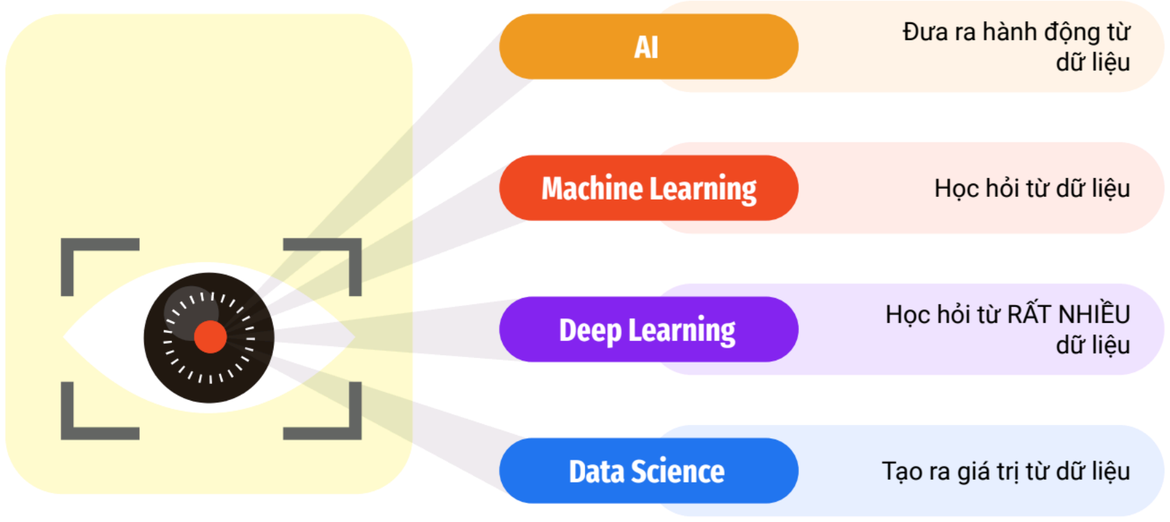

Dữ liệu đầu vào thường được mã hoá dưới dạng 1 vector

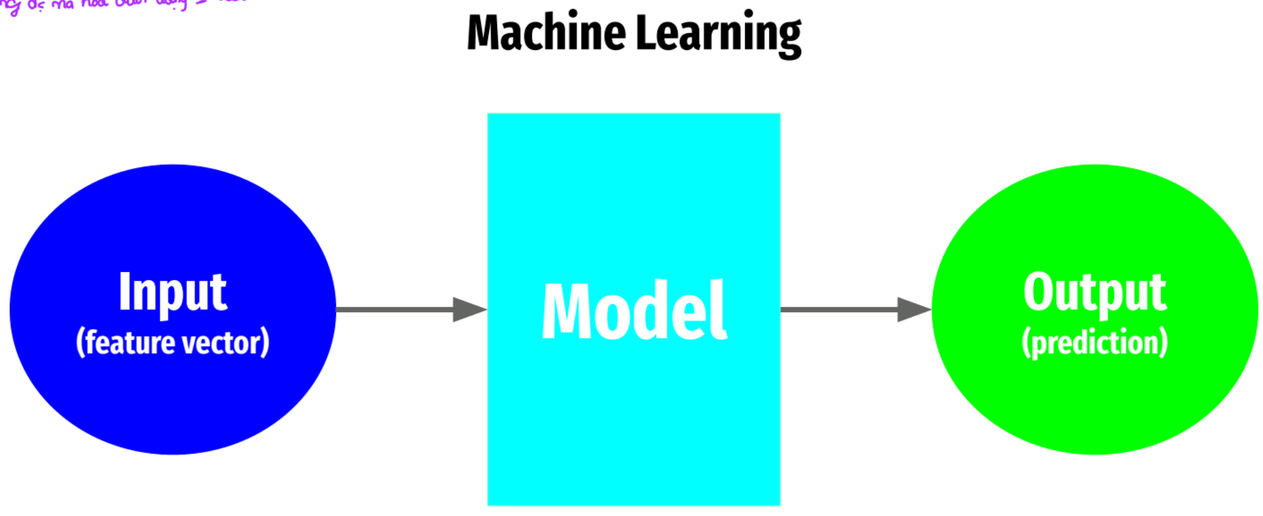

Tabular Data
[ Structure Data

# Dataset (Bộ dữ liệu)

## Adult dataset

| age | workclass | fnlwgt | education | education.num | marital.status | occupation | relationship | race | sex | capital.gain | capital.loss | hours.per.week | native.country | income |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 90 | ? | 77053 | HS-grad | 9 | Widowed | ? | Not-in-family | White | Female | 0 | 4356 | 40 | United-States | <=50K |
| 82 | Private | 132870 | HS-grad | 9 | Widowed | Exec-managerial | Not-in-family | White | Female | 0 | 4356 | 18 | United-States | <=50K |
| 66 | ? | 186061 | Some-college | 10 | Widowed | ? | Unmarried | Black | Female | 0 | 4356 | 40 | United-States | <=50K |
| 54 | Private | 140359 | 7th-8th | 4 | Divorced | Machine-op-inspct | Unmarried | White | Female | 0 | 3900 | 40 | United-States | <=50K |
| 41 | Private | 264663 | Some-college | 10 | Separated | Prof-specialty | Own-child | White | Female | 0 | 3900 | 40 | United-States | <=50K |
| 34 | Private | 216864 | HS-grad | 9 | Divorced | Other-service | Unmarried | White | Female | 0 | 3770 | 45 | United-States | <=50K |
| 38 | Private | 150601 | 10th | 6 | Separated | Adm-clerical | Unmarried | White | Male | 0 | 3770 | 40 | United-States | <=50K |
| 74 | State-gov | 88638 | Doctorate | 16 | Never-married | Prof-specialty | Other-relative | White | Female | 0 | 3683 | 20 | United-States | >50K |
| 68 | Federal-gov | 422013 | HS-grad | 9 | Divorced | Prof-specialty | Not-in-family | White | Female | 0 | 3683 | 40 | United-States | <=50K |
| 41 | Private | 70037 | Some-college | 10 | Never-married | Craft-repair | Unmarried | White | Male | 0 | 3004 | 60 | ? | >50K |
| 45 | Private | 172274 | Doctorate | 16 | Divorced | Prof-specialty | Unmarried | Black | Female | 0 | 3004 | 35 | United-States | >50K |
| 38 | Self-emp-not-inc | 164526 | Prof-school | 15 | Never-married | Prof-specialty | Not-in-family | White | Male | 0 | 2824 | 45 | United-States | >50K |
| 52 | Private | 129177 | Bachelors | 13 | Widowed | Other-service | Not-in-family | White | Female | 0 | 2824 | 20 | United-States | >50K |
| 32 | Private | 136204 | Masters | 14 | Separated | Exec-managerial | Not-in-family | White | Male | 0 | 2824 | 55 | United-States | >50K |
| 51 | ? | 172175 | Doctorate | 16 | Never-married | ? | Not-in-family | White | Male | 0 | 2824 | 40 | United-States | >50K |
| 46 | Private | 45363 | Prof-school | 15 | Divorced | Prof-specialty | Not-in-family | White | Male | 0 | 2824 | 40 | United-States | >50K |
| 45 | Private | 172822 | 11th | 7 | Divorced | Transport-moving | Not-in-family | White | Male | 0 | 2824 | 76 | United-States | >50K |
| 57 | Private | 317847 | Masters | 14 | Divorced | Exec-managerial | Not-in-family | White | Male | 0 | 2824 | 50 | United-States | >50K |
| 22 | Private | 119592 | Assoc-acdm | 12 | Never-married | Handlers-cleaners | Not-in-family | Black | Male | 0 | 2824 | 40 | ? | >50K |
| 34 | Private | 203034 | Bachelors | 13 | Separated | Sales | Not-in-family | White | Male | 0 | 2824 | 50 | United-States | >50K |
| 37 | Private | 188774 | Bachelors | 13 | Never-married | Exec-managerial | Not-in-family | White | Male | 0 | 2824 | 40 | United-States | >50K |

numeric (cát) feature = quantitative feature
categorical feature = qualitative feature

# Feature (thuộc tính)

Có hữu hạn các giá trị khác nhau, rời rạc

## Numerical (số)

### Integer (số nguyên)

- 1, 2, 3
- -2, -1, 0, 1, 2

### Float (số thực)

- 0.1, 0.2, 0.3

Có 1 TH ngoại lệ: Hình thức coi giống numerical feature nhưng ko phải numerical feature
VD: Cột thông tin về SĐT, mã vùng biển số xe → ko để xếp vào
Cách nhận biết: Coi xem có quan hệ thứ bậc hay ko?
VD: Độ tuổi thì có ↑tuổi, ↓tuổi → numerical feature
Biển số xe ko có qh thứ bậc, vì bằng gì có số nào lớn hơn số nào → ko phải numerical feature.

## Categorical (phân loại)

Giữa các giá trị này bình đẳng về mặt ý nghĩa

### Nominal (định danh)

- Red, green, blue
- US, Vietnam, Thailand

### Ordinal (thứ bậc)

Giữa các giá trị có liên quan với nhau về mặt thứ bậc

- Happy, normal, sad
- XS, S, M, L, XL

### Boolean (logic)

- True, False
- Yes, No

Cần phân biệt rõ để xử lý dữ liệu

Có thể số hoá sau này để xử lý

- Có rất nhiều thuật toán trong Machine Learning
- phân loại theo phương thức học: Cách thức nó tương tác, xử lý với dữ liệu)

Dữ liệu xung quanh ta là dữ liệu thô (unlabeled → labeled data) → data labelling (data annotation)

rẻ, có sẵn

Quá trình đánh nhãn dữ liệu có 1 quy tắc: bao giờ cũng có sự can thiệp của con người

# Các phương thức học trong Machine Learning

Học có giám sát

## Supervised learning

Chia thành 2 nhóm

### Classification

dự đoán output có hữu hạn giá trị ≠ nhau

- Fraud detection
- Email spam detection
- Diagnostics
- Image classification

### Regression

Hồi quy

giá trị output vô hạn ∈ đoạn thực (VD: giá trị giá nhà)

- Risk assessment
- Score prediction

Điều kiện bắt buộc: được huấn luyện với labeled data

Học ko giám sát

## Unsupervised learning

### Clustering

phân cụm dữ liệu thành các cụm dữ liệu ≠ nhau sao cho các mẫu trong cùng 1 cụm thì sẽ giống giống nhau, trong khi mẫu của cụm này ≠ xa mẫu của cụm khác.

- Customer clustering
- Data visualization

- Nghe giống giống thì giống Classification nhưng sự ≠ biệt là:
Trong Classification, biết rõ ý nghĩa từng cụm là gì
Trong Clustering: ko biết
VD:

### Association

- Recommendation System

Huấn luyện với unlabeled data

Đầu ra output thường có rất nhiều trường hợp ko giám sát được.

bài toán phân loại đồ chơi

giới tính của
màu sắc
hình dáng
chất liệu

Học tăng cường

## Reinforcement learning

- Game theory
- Autonomous cars

Nặng về Toán, Khó học

Ít job

Trong ML thường không

Lưu ý: Regression: Hồi quy

Recurrent: Hồi quy

Recurrent Neural Network (RNN)

Trong Deep Learning

Khi dịch tài liệu bằng tiếng Việt có thể ý là "hồi quy" nhưng ở trường hợp nào!

thường để cả cụm từ

# Supervised learning

# Labeled data (dữ liệu có nhãn)

## Diabetes dataset

gọi là 1 feature

gọi là lable

| Pregnancies | Glucose | BloodPressure | SkinThickness | Insulin | BMI | DiabetesPedigreeFunction | Age | Outcome |
|---|---|---|---|---|---|---|---|---|
| 6 | 148 | 72 | 35 | 0 | 33.6 | 0.627 | 50 | 1 |
| 1 | 85 | 66 | 29 | 0 | 26.6 | 0.351 | 31 | 0 |
| 8 | 183 | 64 | 0 | 0 | 23.3 | 0.672 | 32 | 1 |
| 1 | 89 | 66 | 23 | 94 | 28.1 | 0.167 | 21 | 0 |
| 0 | 137 | 40 | 35 | 168 | 43.1 | 2.288 | 33 | 1 |
| 5 | 116 | 74 | 0 | 0 | 25.6 | 0.201 | 30 | 0 |
| 3 | 78 | 50 | 32 | 88 | 31 | 0.248 | 26 | 1 |
| 10 | 115 | 0 | 0 | 0 | 35.3 | 0.134 | 29 | 0 |
| 2 | 197 | 70 | 45 | 543 | 30.5 | 0.158 | 53 | 1 |
| 8 | 125 | 96 | 0 | 0 | 0 | 0.232 | 54 | 1 |
| 4 | 110 | 92 | 0 | 0 | 37.6 | 0.191 | 30 | 0 |
| 10 | 168 | 74 | 0 | 0 | 38 | 0.537 | 34 | 1 |
| 10 | 139 | 80 | 0 | 0 | 27.1 | 1.441 | 57 | 0 |
| 1 | 189 | 60 | 23 | 846 | 30.1 | 0.398 | 59 | 1 |
| 5 | 166 | 72 | 19 | 175 | 25.8 | 0.587 | 51 | 1 |

1 sample

# Labeled data (dữ liệu có nhãn)

**Diabetes dataset**

**sample**

| Pregnancies | Glucose | BloodPressure | SkinThickness | Insulin | BMI | DiabetesPedigreeFunction | Age | Outcome |
|---|---|---|---|---|---|---|---|---|
| 6 | 148 | 72 | 35 | 0 | 33.6 | 0.627 | 50 | 1 |
| 1 | 85 | 66 | 29 | 0 | 26.6 | 0.351 | 31 | 0 |
| 8 | 183 | 64 | 0 | 0 | 23.3 | 0.672 | 32 | 1 |
| 1 | 89 | 66 | 23 | 94 | 28.1 | 0.167 | 21 | 0 |
| 0 | 137 | 40 | 35 | 168 | 43.1 | 2.288 | 33 | 1 |
| 5 | 116 | 74 | 0 | 0 | 25.6 | 0.201 | 30 | 0 |
| 3 | 78 | 50 | 32 | 88 | 31 | 0.248 | 26 | 1 |
| 10 | 115 | 0 | 0 | 0 | 35.3 | 0.134 | 29 | 0 |
| 2 | 197 | 70 | 45 | 543 | 30.5 | 0.158 | 53 | 1 |
| 8 | 125 | 96 | 0 | 0 | 0 | 0.232 | 54 | 1 |
| 4 | 110 | 92 | 0 | 0 | 37.6 | 0.191 | 30 | 0 |
| 10 | 168 | 74 | 0 | 0 | 38 | 0.537 | 34 | 1 |
| 10 | 139 | 80 | 0 | 0 | 27.1 | 1.441 | 57 | 0 |
| 1 | 189 | 60 | 23 | 846 | 30.1 | 0.398 | 59 | 1 |
| 5 | 166 | 72 | 19 | 175 | 25.8 | 0.587 | 51 | 1 |

# Labeled data (dữ liệu có nhãn)

**Diabetes dataset**

**feature**

| Pregnancies | Glucose | BloodPressure | SkinThickness | Insulin | BMI | DiabetesPedigreeFunction | Age | Outcome |
|---|---|---|---|---|---|---|---|---|
| 6 | 148 | 72 | 35 | 0 | 33.6 | 0.627 | 50 | 1 |
| 1 | 85 | 66 | 29 | 0 | 26.6 | 0.351 | 31 | 0 |
| 8 | 183 | 64 | 0 | 0 | 23.3 | 0.672 | 32 | 1 |
| 1 | 89 | 66 | 23 | 94 | 28.1 | 0.167 | 21 | 0 |
| 0 | 137 | 40 | 35 | 168 | 43.1 | 2.288 | 33 | 1 |
| 5 | 116 | 74 | 0 | 0 | 25.6 | 0.201 | 30 | 0 |
| 3 | 78 | 50 | 32 | 88 | 31 | 0.248 | 26 | 1 |
| 10 | 115 | 0 | 0 | 0 | 35.3 | 0.134 | 29 | 0 |
| 2 | 197 | 70 | 45 | 543 | 30.5 | 0.158 | 53 | 1 |
| 8 | 125 | 96 | 0 | 0 | 0 | 0.232 | 54 | 1 |
| 4 | 110 | 92 | 0 | 0 | 37.6 | 0.191 | 30 | 0 |
| 10 | 168 | 74 | 0 | 0 | 38 | 0.537 | 34 | 1 |
| 10 | 139 | 80 | 0 | 0 | 27.1 | 1.441 | 57 | 0 |
| 1 | 189 | 60 | 23 | 846 | 30.1 | 0.398 | 59 | 1 |
| 5 | 166 | 72 | 19 | 175 | 25.8 | 0.587 | 51 | 1 |

# Labeled data (dữ liệu có nhãn)

## Diabetes dataset

label (target)

| Pregnancies | Glucose | BloodPressure | SkinThickness | Insulin | BMI | DiabetesPedigreeFunction | Age | Outcome |
|---|---|---|---|---|---|---|---|---|
| 6 | 148 | 72 | 35 | 0 | 33.6 | 0.627 | 50 | 1 |
| 1 | 85 | 66 | 29 | 0 | 26.6 | 0.351 | 31 | 0 |
| 8 | 183 | 64 | 0 | 0 | 23.3 | 0.672 | 32 | 1 |
| 1 | 89 | 66 | 23 | 94 | 28.1 | 0.167 | 21 | 0 |
| 0 | 137 | 40 | 35 | 168 | 43.1 | 2.288 | 33 | 1 |
| 5 | 116 | 74 | 0 | 0 | 25.6 | 0.201 | 30 | 0 |
| 3 | 78 | 50 | 32 | 88 | 31 | 0.248 | 26 | 1 |
| 10 | 115 | 0 | 0 | 0 | 35.3 | 0.134 | 29 | 0 |
| 2 | 197 | 70 | 45 | 543 | 30.5 | 0.158 | 53 | 1 |
| 8 | 125 | 96 | 0 | 0 | 0 | 0.232 | 54 | 1 |
| 4 | 110 | 92 | 0 | 0 | 37.6 | 0.191 | 30 | 0 |
| 10 | 168 | 74 | 0 | 0 | 38 | 0.537 | 34 | 1 |
| 10 | 139 | 80 | 0 | 0 | 27.1 | 1.441 | 57 | 0 |
| 1 | 189 | 60 | 23 | 846 | 30.1 | 0.398 | 59 | 1 |
| 5 | 166 | 72 | 19 | 175 | 25.8 | 0.587 | 51 | 1 |

input

output

# Labeled data (dữ liệu có nhãn)

## Diabetes dataset

feature vector

corresponding label (target)

| Pregnancies | Glucose | BloodPressure | SkinThickness | Insulin | BMI | DiabetesPedigreeFunction | Age | Outcome |
|---|---|---|---|---|---|---|---|---|
| 6 | 148 | 72 | 35 | 0 | 33.6 | 0.627 | 50 | 1 |
| 1 | 85 | 66 | 29 | 0 | 26.6 | 0.351 | 31 | 0 |
| 8 | 183 | 64 | 0 | 0 | 23.3 | 0.672 | 32 | 1 |
| 1 | 89 | 66 | 23 | 94 | 28.1 | 0.167 | 21 | 0 |
| 0 | 137 | 40 | 35 | 168 | 43.1 | 2.288 | 33 | 1 |
| 5 | 116 | 74 | 0 | 0 | 25.6 | 0.201 | 30 | 0 |
| 3 | 78 | 50 | 32 | 88 | 31 | 0.248 | 26 | 1 |
| 10 | 115 | 0 | 0 | 0 | 35.3 | 0.134 | 29 | 0 |
| 2 | 197 | 70 | 45 | 543 | 30.5 | 0.158 | 53 | 1 |
| 8 | 125 | 96 | 0 | 0 | 0 | 0.232 | 54 | 1 |
| 4 | 110 | 92 | 0 | 0 | 37.6 | 0.191 | 30 | 0 |
| 10 | 168 | 74 | 0 | 0 | 38 | 0.537 | 34 | 1 |
| 10 | 139 | 80 | 0 | 0 | 27.1 | 1.441 | 57 | 0 |
| 1 | 189 | 60 | 23 | 846 | 30.1 | 0.398 | 59 | 1 |
| 5 | 166 | 72 | 19 | 175 | 25.8 | 0.587 | 51 | 1 |

# Labeled data (dữ liệu có nhãn)

feature matrix (X)

Label/target vector (y)

## Diabetes dataset

| Pregnancies | Glucose | BloodPressure | SkinThickness | Insulin | BMI | DiabetesPedigreeFunction | Age | Outcome |
|---|---|---|---|---|---|---|---|---|
| 6 | 148 | 72 | 35 | 0 | 33.6 | 0.627 | 50 | 1 |
| 1 | 85 | 66 | 29 | 0 | 26.6 | 0.351 | 31 | 0 |
| 8 | 183 | 64 | 0 | 0 | 23.3 | 0.672 | 32 | 1 |
| 1 | 89 | 66 | 23 | 94 | 28.1 | 0.167 | 21 | 0 |
| 0 | 137 | 40 | 35 | 168 | 43.1 | 2.288 | 33 | 1 |
| 5 | 116 | 74 | 0 | 0 | 25.6 | 0.201 | 30 | 0 |
| 3 | 78 | 50 | 32 | 88 | 31 | 0.248 | 26 | 1 |
| 10 | 115 | 0 | 0 | 0 | 35.3 | 0.134 | 29 | 0 |
| 2 | 197 | 70 | 45 | 543 | 30.5 | 0.158 | 53 | 1 |
| 8 | 125 | 96 | 0 | 0 | 0 | 0.232 | 54 | 1 |
| 4 | 110 | 92 | 0 | 0 | 37.6 | 0.191 | 30 | 0 |
| 10 | 168 | 74 | 0 | 0 | 38 | 0.537 | 34 | 1 |
| 10 | 139 | 80 | 0 | 0 | 27.1 | 1.441 | 57 | 0 |
| 1 | 189 | 60 | 23 | 846 | 30.1 | 0.398 | 59 | 1 |
| 5 | 166 | 72 | 19 | 175 | 25.8 | 0.587 | 51 | 1 |

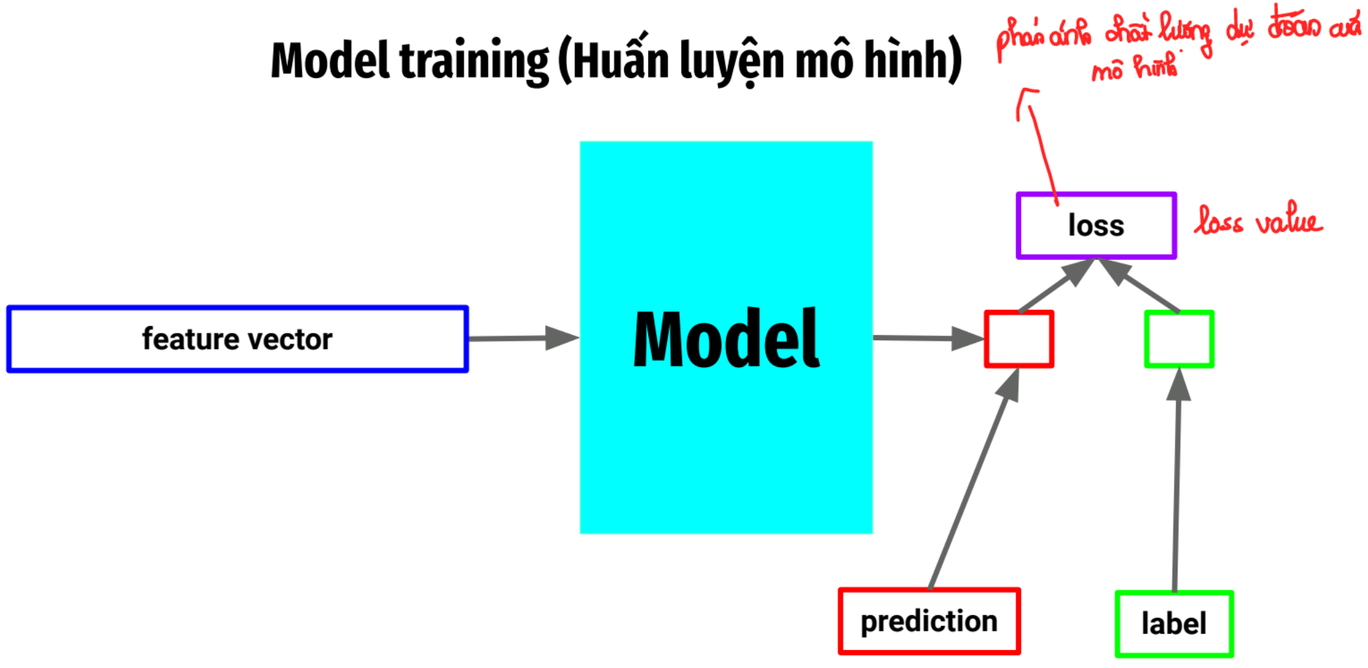
Model training (Huấn luyện mô hình)
phản ánh chất lượng dự đoán của mô hình
loss
loss value
feature vector
Model
prediction
label

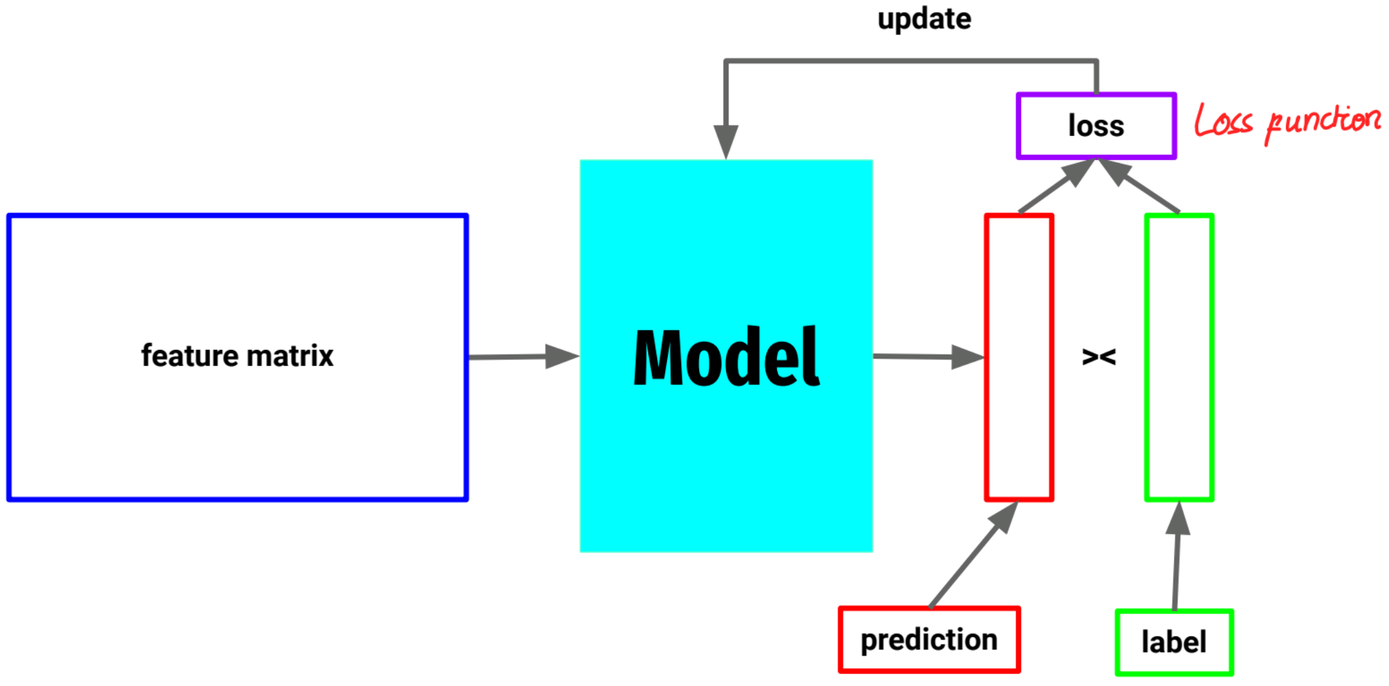
update
loss
Loss function
feature matrix
Model
><
prediction
label

# Loss function (Hàm mất mát)

**Ví dụ về mô hình dự đoán giá nhà ở Việt Nam (Đơn vị: Tỉ VND)**

| Diện tích | Số tầng | Thành phố | Trong ngõ |
|---|---|---|---|
| 40 | 6 | HCM | No |
| 60 | 4 | Hà Nội | No |
| 120 | 3 | Hải Dương | Yes |
| 50 | 4 | Huế | No |

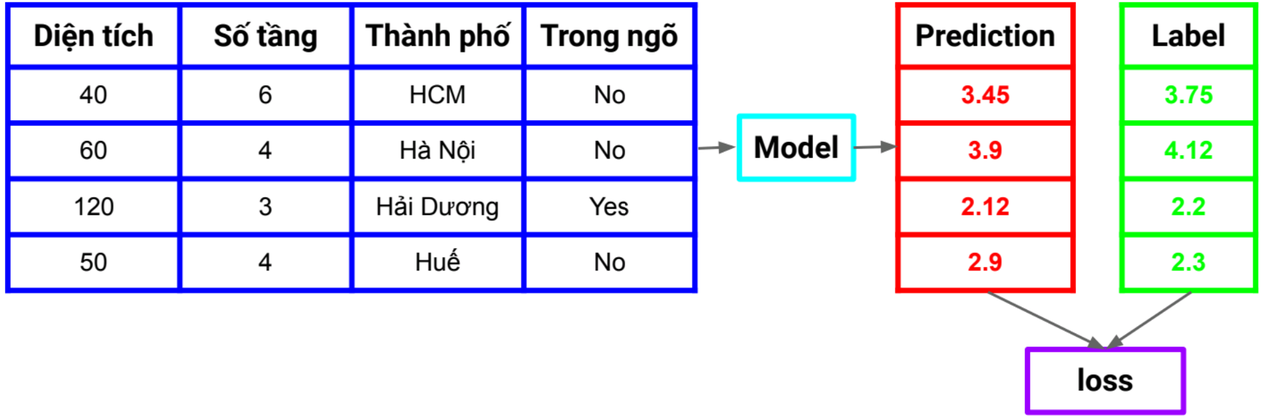

L1 hay 2 thì nói về bậc của hàm loss

Tối ưu hoá mô hình chính là tối thiểu hoá giá trị của hàm loss (Lossfunction)
→ Thằng nào làm cho lossvalue lớn thì mô hình sẽ tập trung vào thằng đấy

# Loss function (Hàm mất mát)

## L1 loss

**Loss = $\Sigma |y_{prediction} - y_{actual}|$** bậc 1

**Các tên gọi:** ý: Lệch tuyệt đối tối thiểu

- **Least Absolute Deviations (LAD)**
- **Absolute Error**
- **Mean of these Absolute Errors**

Có xu hướng dự đoán sai lệch đều đều

## L2 loss

**Loss = $\Sigma (y_{prediction} - y_{actual})^2$** bậc 2 → phóng đại sai lầm lớn tập trung

**Các tên gọi:**

- **Least Square Errors (LS)**
- **Squared Error**
- **Mean of these Squared Errors**

sai lệch ít

Có xu hướng ± tối cũng ± xấu

# Loss function (Hàm mất mát)

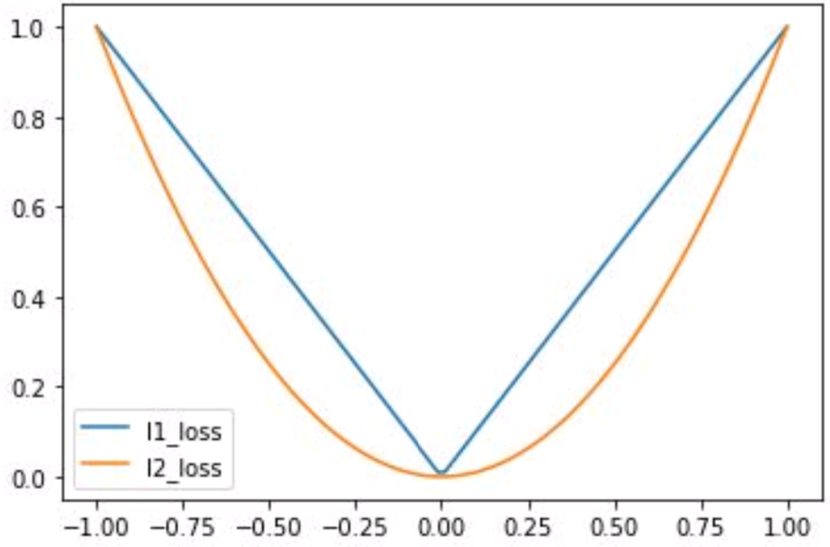

Làm việc với bộ dữ liệu thì phải chia nhỏ bộ dữ liệu

Tiêu chuẩn: chia thành 3 bộ con

Phân chia dữ liệu: thường nếu dữ liệu khan hiếm thì chia theo 80 - 10 - 10 hoặc 90 - 5 - 5, tức là tỉ lệ bộ training lớn

# Phân chia dataset

## Diabetes dataset

| Pregnancies | Glucose | BloodPressure | SkinThickness | Insulin | BMI | DiabetesPedigreeFunction | Age | Outcome |
|---|---|---|---|---|---|---|---|---|
| 6 | 148 | 72 | 35 | 0 | 33.6 | 0.627 | 50 | 1 |
| 1 | 85 | 66 | 29 | 0 | 26.6 | 0.351 | 31 | 0 |
| 8 | 183 | 64 | 0 | 0 | 23.3 | 0.672 | 32 | 1 |
| 1 | 89 | 66 | 23 | 94 | 28.1 | 0.167 | 21 | 0 |
| 0 | 137 | 40 | 35 | 168 | 43.1 | 2.288 | 33 | 1 |
| 5 | 116 | 74 | 0 | 0 | 25.6 | 0.201 | 30 | 0 |
| 3 | 78 | 50 | 32 | 88 | 31 | 0.248 | 26 | 1 |
| 10 | 115 | 0 | 0 | 0 | 35.3 | 0.134 | 29 | 0 |
| 2 | 197 | 70 | 45 | 543 | 30.5 | 0.158 | 53 | 1 |
| 8 | 125 | 96 | 0 | 0 | 0 | 0.232 | 54 | 1 |
| 4 | 110 | 92 | 0 | 0 | 37.6 | 0.191 | 30 | 0 |
| 10 | 168 | 74 | 0 | 0 | 38 | 0.537 | 34 | 1 |
| 10 | 139 | 80 | 0 | 0 | 27.1 | 1.441 | 57 | 0 |
| 1 | 189 | 60 | 23 | 846 | 30.1 | 0.398 | 59 | 1 |
| 5 | 166 | 72 | 19 | 175 | 25.8 | 0.587 | 51 | 1 |

TRAINING SET

VALIDATION SET

TEST SET

Tập dữ liệu huấn luyện

Không dc dùng để cải thiện mô hình mà đánh giá xem quá trình huấn luyện có đang dc đúng hướng hay không!

Nói cách khác thì bộ validation set này càng ngày càng test hơn

Giáo viên kiểm tra hs có học đúng hướng ko.

Thi Học Kì

Thi THPT

Về mặt lí thuyết gồm 3 bộ

Training Set: quá trình training

Validation set: đánh giá quá trình training trc và sau

Test Set: Sau khi xong hết, đánh giá cuối cùng

Bộ training set dùng loss value để quay ngược bc up date mô hình.

Bộ val và test dùng loss để tuning thôi (Như thi lại lấy thêm thôi, ko cải giới)

Training Set, Val Set: Dùng trong qtr huấn luyện

Test: Sau khi Quá huấn luyện xong

Chọn số K: K=4 Huấn luyện 4 mô hình y hệt nhau

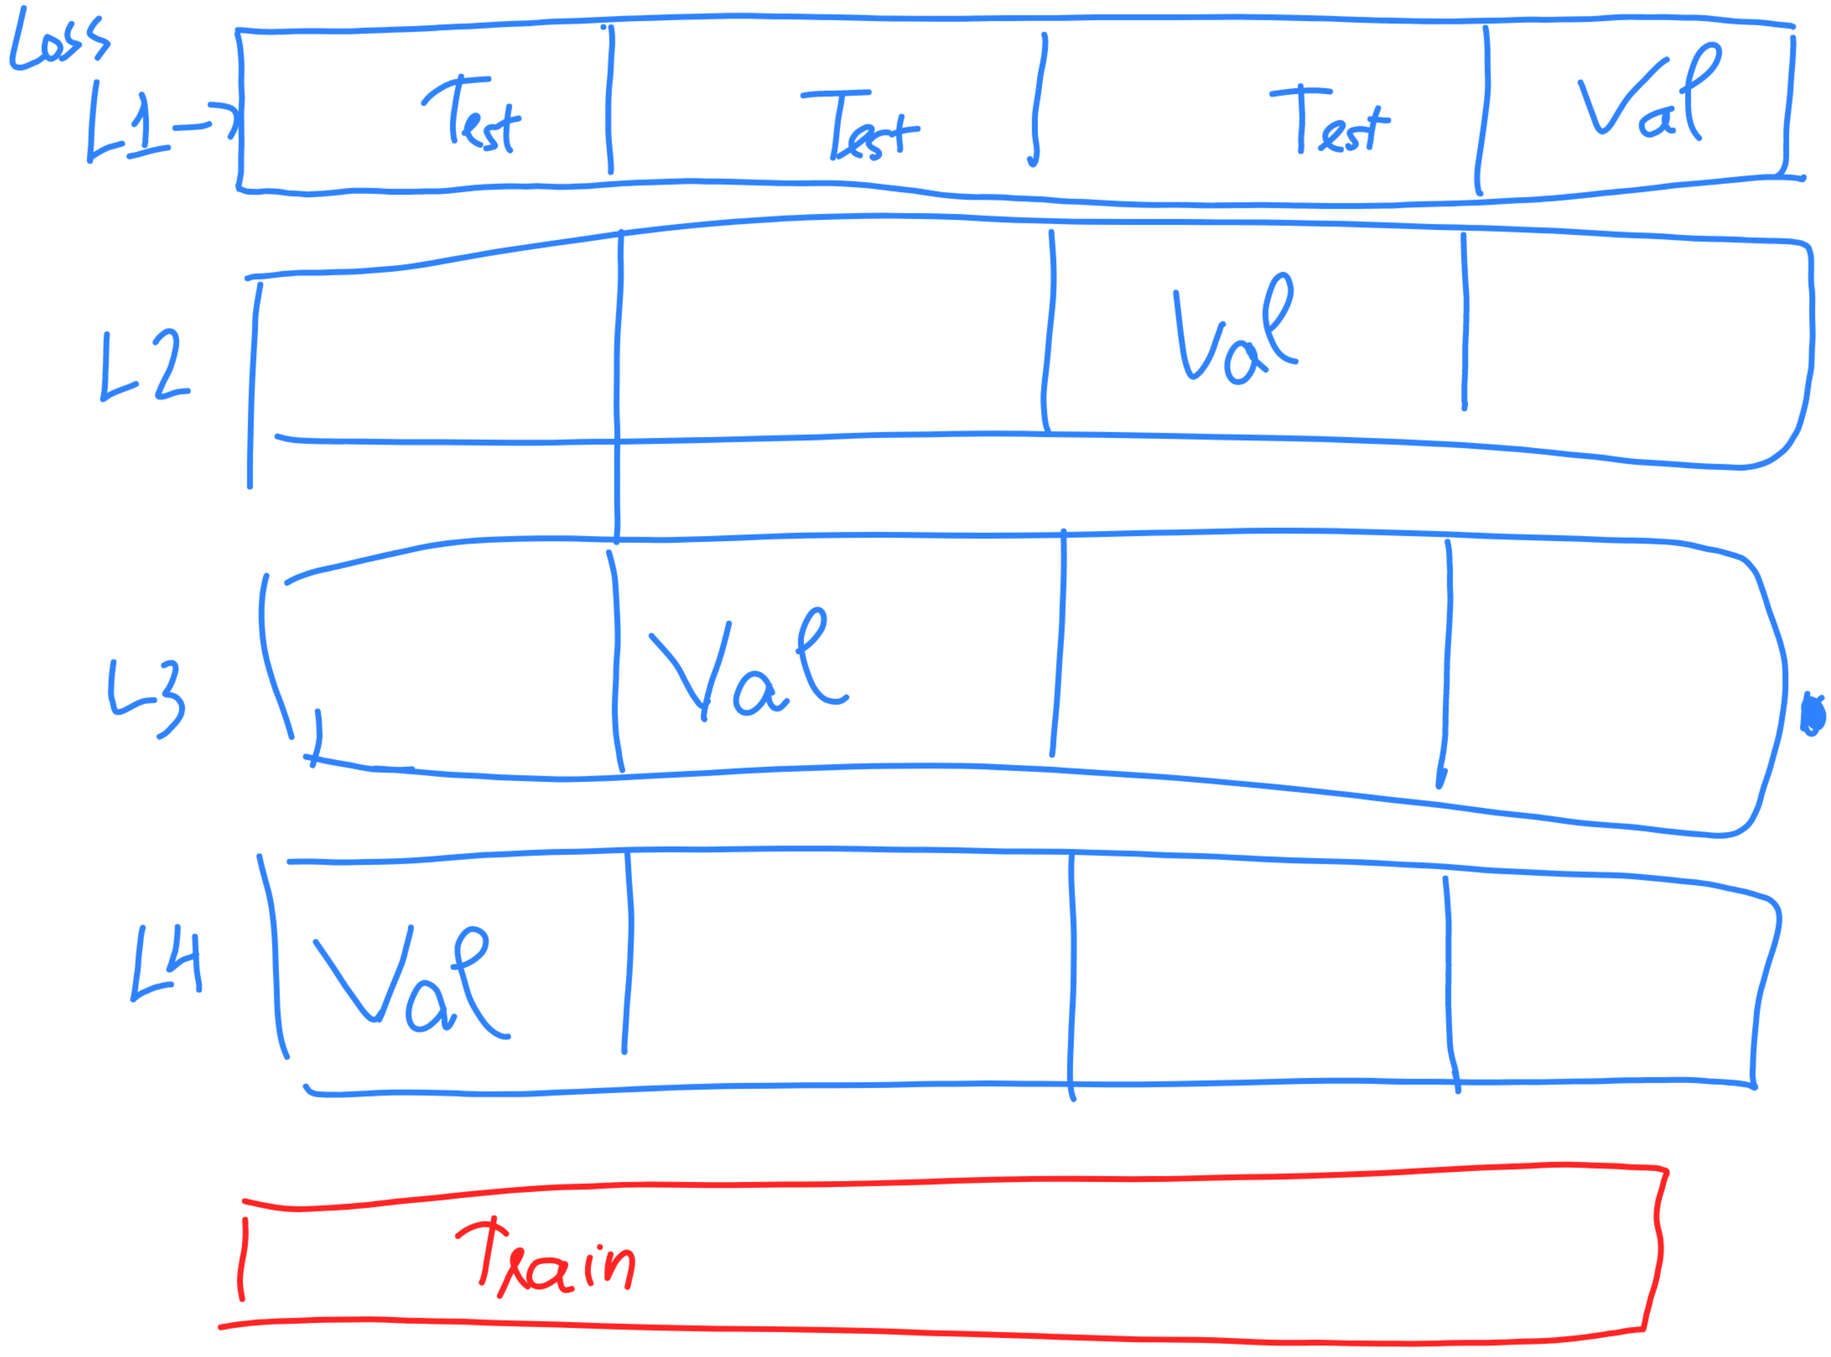


K lần, mỗi lần dùng 1 tập con làm tập val, 0 lần nào giống lần nào

Tính trung bình bộ

Loss

$$\sum_{i=1}^{K} \frac{L_i}{K}$$

K - gold cross Validation

Phân tích về **K - fold cross validation.**

Thông thường chia dữ liệu thành 3 phần: → Train Set
→ Validation Set
→ Test Set

Vấn đề: Nếu dataset ít dữ liệu thì validation set sẽ rất nhỏ. Ví dụ có 100 mẫu dữ liệu: Train : 70
Validation: 15
Test : 15
} Model chỉ được train trên 70 mẫu, khai phí dữ liệu
→ K - fold giúp tận dụng dữ liệu tốt hơn

---

K fold chỉ áp dụng cho Train set và Validation set, Test set đã được tách ra ngay từ đầu

!!!
Test set chỉ được dùng 1 lần duy nhất

---

**Stratified K - fold.** Giả sử giải quyết bài toán Classification: Có Dataset

| Class | Số lượng |
|---|---|
| Cat | 90 |
| Dog | 10 |

} → Dataset mất cân bằng

Nếu chia K - fold bình thường có thể xảy ra:

| Fold | Cat | Dog |
|---|---|---|
| Fold 1 | 25 | 0 |
| Fold 2 | 20 | 5 |
| Fold 3 | 30 | 0 |
| Fold 4 | 15 | 3 |

} Có Fold 2 có con Dog
→ Model Validation sai hoàn toàn

Stratified K - fold giúp giữ tỉ lệ giống ở data set gốc.

Data set gốc → Cat 90%
→ Dog 10%

Sau khi chia

| Fold | Cat | Dog |
|---|---|---|
| Fold 1 | 22 | 3 |
| Fold 2 | 22 | 3 |
| Fold 3 | 23 | 2 |
| Fold 4 | 23 | 2 |

!!! Chỉ dùng cho Classification

# Các bài toán trong Supervised Learning

## Classification (phân loại)

### Binary Classification

- Fraud detection
- Email spam detection
- Diagnostics

### Multiclass Classification

- Animals (cat/dog/horse)
- Fruits (apple/orange/lemon)
- Flowers (rose/daisy/sunflower)

## Regression(hồi quy)

- House price estimation
- Stock prediction
- Temperature forecast

# Classification

"Is this email spam or not spam?"

To: daniel@mrdbourke.com
Hey Daniel,

This deep learning course is incredible!
I can't wait to use what I've learned!

Not spam

To: daniel@mrdbourke.com
Hay daniel...

COongratu1ations! U win $1139239230

Spam

**Binary classification**

(one thing or another)

"Is this a photo of sushi, steak or pizza?"

**Multiclass classification**

(more than one thing or another)

"What tags should this article have?"

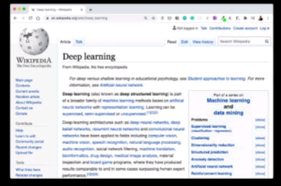


Machine learning
Representation learning
Artificial intelligence

(multiple label options per sample)

**Multilabel classification**

# Cách đánh giá mô hình trong Supervised Learning

## Classification: dog vs cat

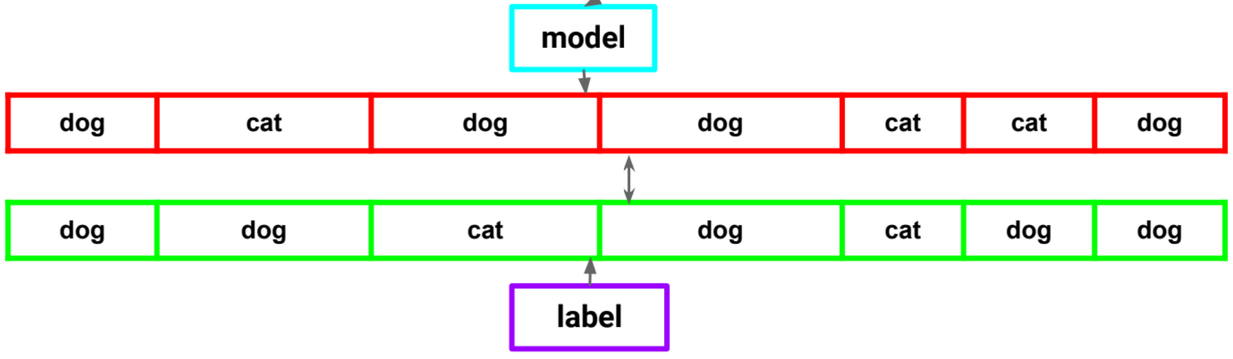

# Classification metrics

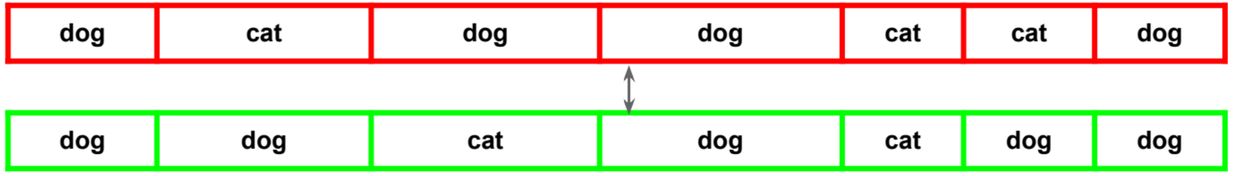


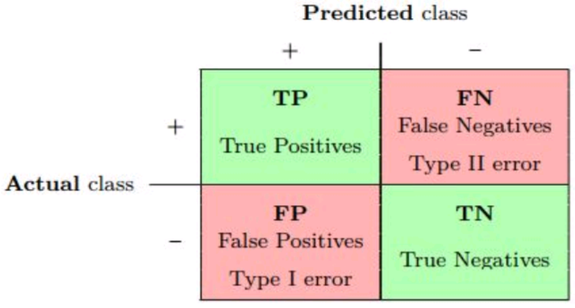


**Class +:** Class ta quan tâm: e.g. dog
**Class -:** class(es) còn lại: e.g. cat

# Classification metrics

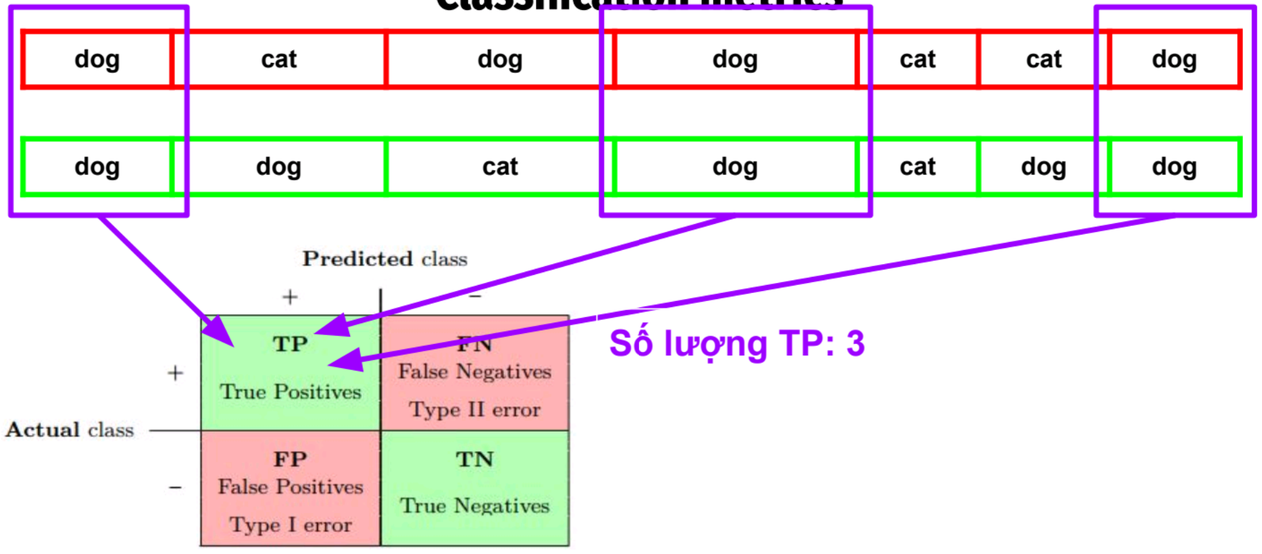

# Classification metrics

| | | | | | | |
|---|---|---|---|---|---|---|
| dog | cat | dog | dog | cat | cat | dog |
| dog | dog | cat | dog | cat | dog | dog |

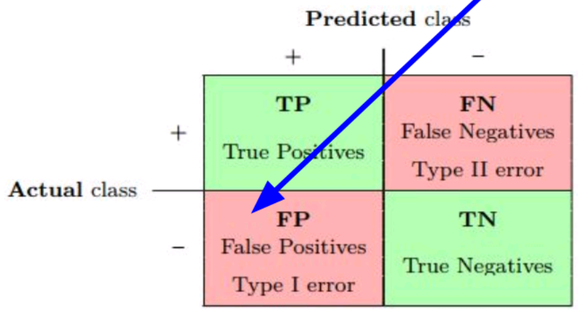


Số lượng TP: 3

Số lượng FP: 1

# Classification metrics

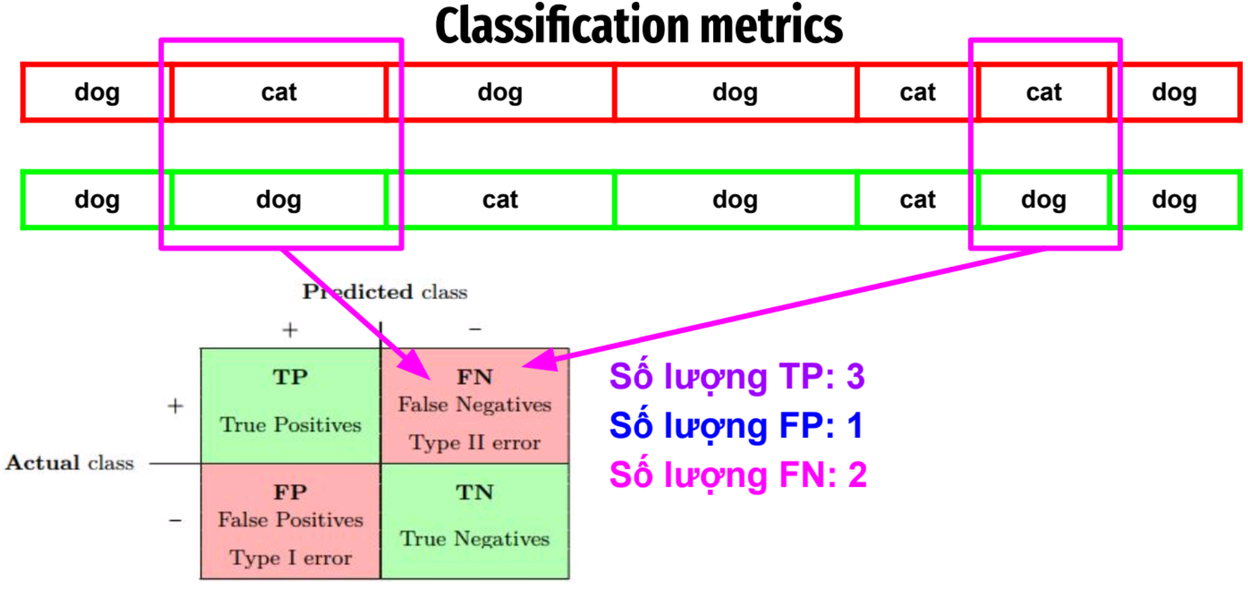

# Classification metrics

| dog | cat | dog | dog | cat | cat | dog |
|---|---|---|---|---|---|---|

| dog | dog | cat | dog | cat | dog | dog |
|---|---|---|---|---|---|---|

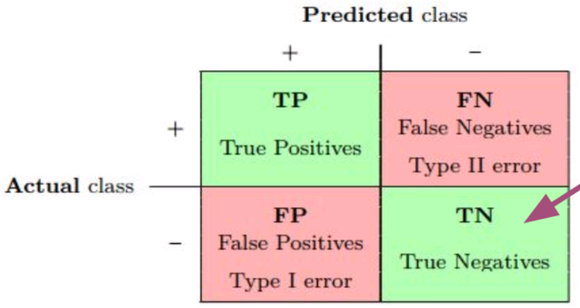


Số lượng TP: 3

Số lượng FP: 1

Số lượng FN: 2

Số lượng TN: 1

| Metric | Công thức | Ý nghĩa |
|---|---|---|
| Accuracy | (TP+TN)/All | Độ chính xác tổng quát |

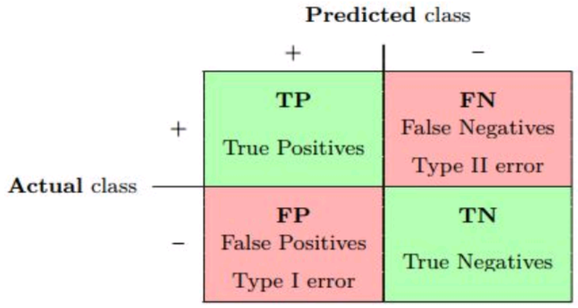


Số lượng TP: 3 Accuracy = (3+1)/7

Số lượng FP: 1

Số lượng FN: 2

Số lượng TN: 1

All: 7

| Metric | Công thức | Ý nghĩa |
|---|---|---|
| Accuracy | (TP+TN)/All | Độ chính xác tổng quát |
| Precision | TP/(TP+FP) | Độ chính xác đối với class + |

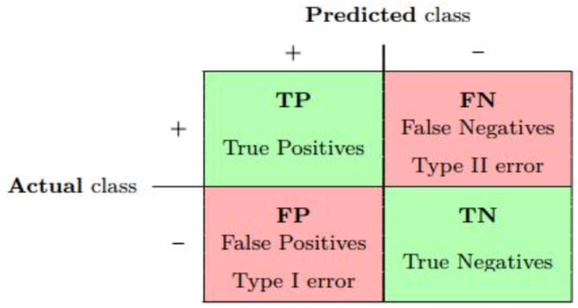


Số lượng TP: 3
Số lượng FP: 1
Số lượng FN: 2
Số lượng TN: 1
All: 7

Accuracy = (3+1)/7
Precision = 3/(3+1)

| Metric | Công thức | Ý nghĩa |
|---|---|---|
| Accuracy | (TP+TN)/All | Độ chính xác tổng quát |
| Precision | TP/(TP+FP) | Độ chính xác đối với class + |
| Recall | TP/(TP+FN) | Độ bao phủ đối với các dự đoán về class + |

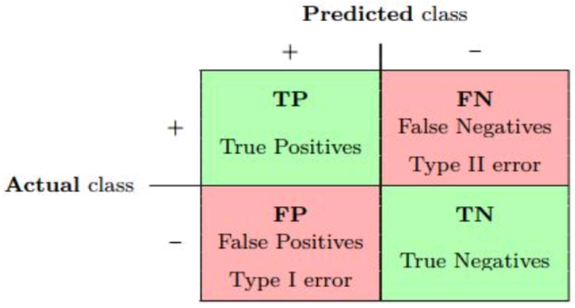


Số lượng TP: 3
Số lượng FP: 1
Số lượng FN: 2
Số lượng TN: 1
All: 7

Accuracy = (3+1)/7
Precision = 3/(3+1)
Recall = 3/(3+2)

| Metric | Công thức | Ý nghĩa |
|---|---|---|
| Accuracy | (TP+TN)/All | Độ chính xác tổng quát |
| Precision | TP/(TP+FP) | Độ chính xác đối với class + |
| Recall | TP/(TP+FN) | Độ bao phủ đối với các dự đoán về class + |
| F1 score | (2*Pre*Re)/(Pre+Re): Trung bình điều hòa giữa Precision và Recall | |

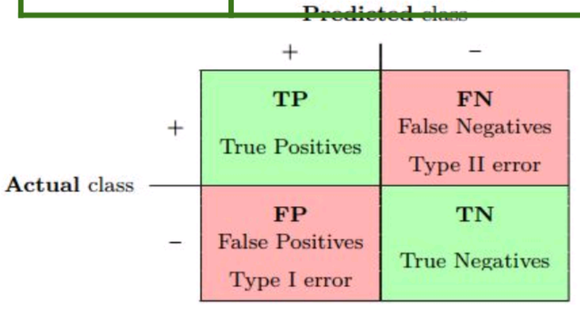


Số lượng TP: 3
Số lượng FP: 1
Số lượng FN: 2
Số lượng TN: 1
All: 7

Accuracy = (3+1)/7
Precision = 3/(3+1)
Recall = 3/(3+2)
F1 score = (2*0.75*0.6)/(0.75+0.6)

# Classification metrics

| Actual class \ Predicted class | + | − |
|---|---|---|
| + | **TP** True Positives | **FN** False Negatives Type II error |
| − | **FP** False Positives Type I error | **TN** True Negatives |

| Metric | Công thức |
|---|---|
| True Positive Rate (= Recall) | TP/(TP+FN) |
| False Positive Rate | FP/(FP+TN) |

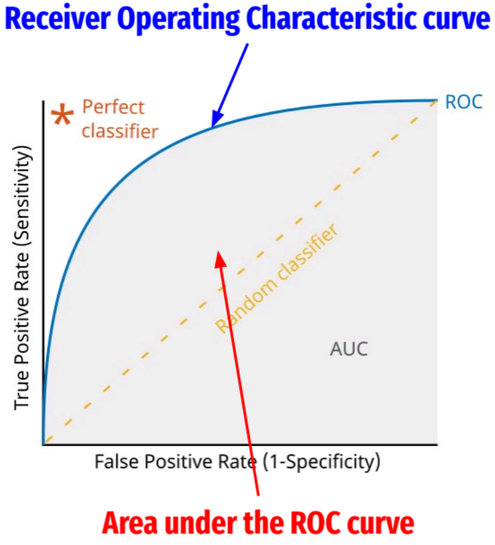

# Cách đánh giá mô hình trong Supervised Learning

## Regression: House price prediction

| Diện tích | Số tầng | Thành phố | Trong ngõ |
|---|---|---|---|
| 40 | 6 | HCM | No |
| 60 | 4 | Hà Nội | No |
| 120 | 3 | Hải Dương | Yes |
| 50 | 4 | Huế | No |

→ **Model** →

| Prediction | Label |
|---|---|
| 3.45 | 3.75 |
| 3.9 | 4.12 |
| 2.12 | 2.2 |
| 2.9 | 2.3 |

**Mean absolute error** = $\frac{1}{N}\sum_{1}^{N} |y_{prediction} - y_{actual}|$

**Root Mean Squared Error (RMSE)** = $\sqrt{\frac{1}{N}\sum_{1}^{N} (y_{prediction} - y_{actual})^2}$

# Machine Learning pipeline

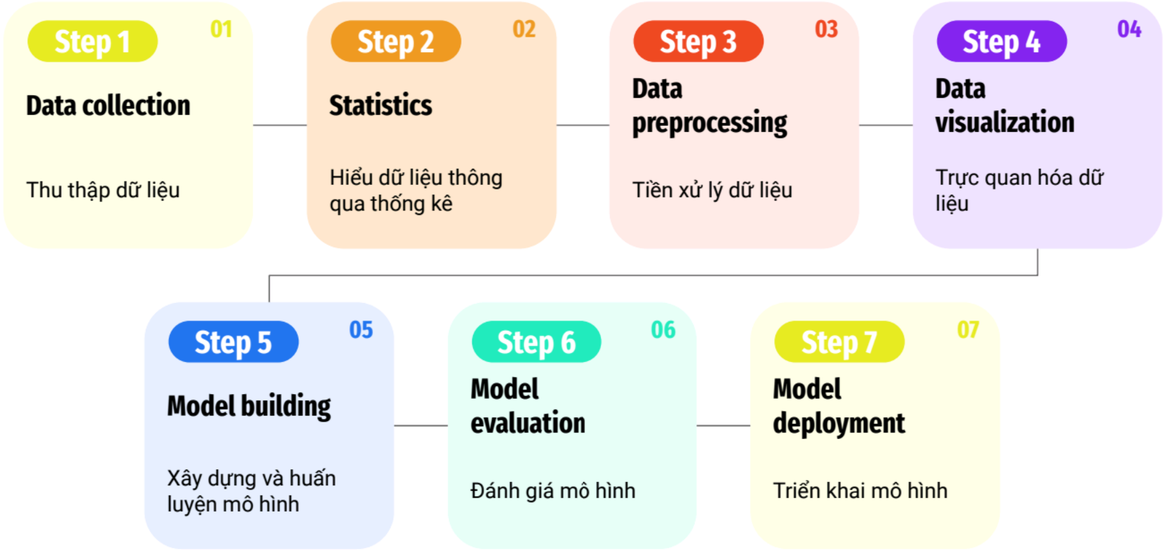

# Step 2: Statistics

## Diabetes dataset

| Pregnancies | Glucose | BloodPressure | SkinThickness | Insulin | BMI | DiabetesPedigreeFunction | Age | Outcome |
|---|---|---|---|---|---|---|---|---|
| 6 | 148 | 72 | 35 | 0 | 33.6 | 0.627 | 50 | 1 |
| 1 | 85 | 66 | 29 | 0 | 26.6 | 0.351 | 31 | 0 |
| 8 | 183 | 64 | 0 | 0 | 23.3 | 0.672 | 32 | 1 |
| 1 | 89 | 66 | 23 | 94 | 28.1 | 0.167 | 21 | 0 |
| 0 | 137 | 40 | 35 | 168 | 43.1 | 2.288 | 33 | 1 |
| 5 | 116 | 74 | 0 | 0 | 25.6 | 0.201 | 30 | 0 |
| 3 | 78 | 50 | 32 | 88 | 31 | 0.248 | 26 | 1 |
| 10 | 115 | 0 | 0 | 0 | 35.3 | 0.134 | 29 | 0 |
| 2 | 197 | 70 | 45 | 543 | 30.5 | 0.158 | 53 | 1 |
| 8 | 125 | 96 | 0 | 0 | 0 | 0.232 | 54 | 1 |
| 4 | 110 | 92 | 0 | 0 | 37.6 | 0.191 | 30 | 0 |
| 10 | 168 | 74 | 0 | 0 | 38 | 0.537 | 34 | 1 |
| 10 | 139 | 80 | 0 | 0 | 27.1 | 1.441 | 57 | 0 |
| 1 | 189 | 60 | 23 | 846 | 30.1 | 0.398 | 59 | 1 |
| 5 | 166 | 72 | 19 | 175 | 25.8 | 0.587 | 51 | 1 |

# Step 2: Statistics

## How data looks like

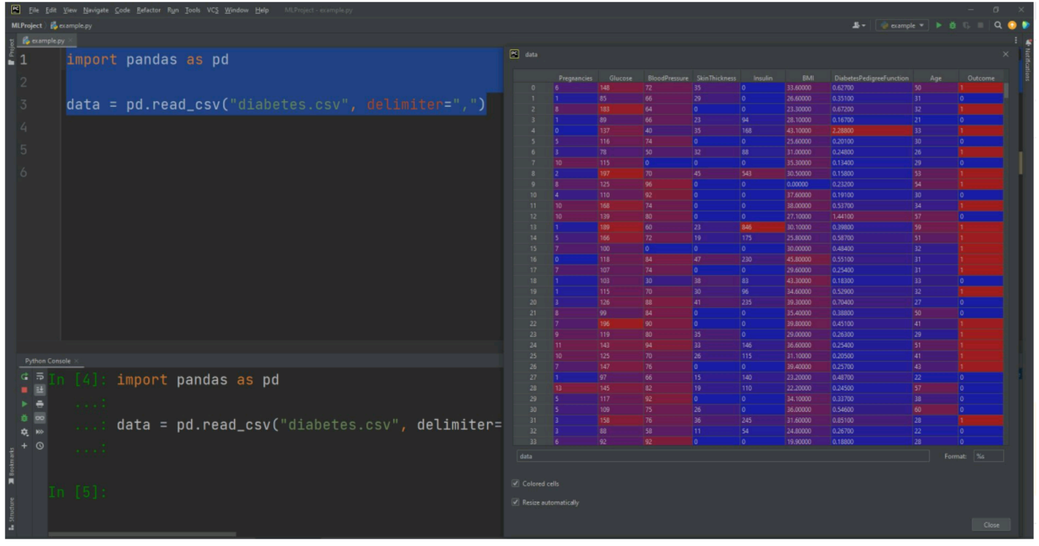

# Step 2: Statistics

## Check each feature’s data type

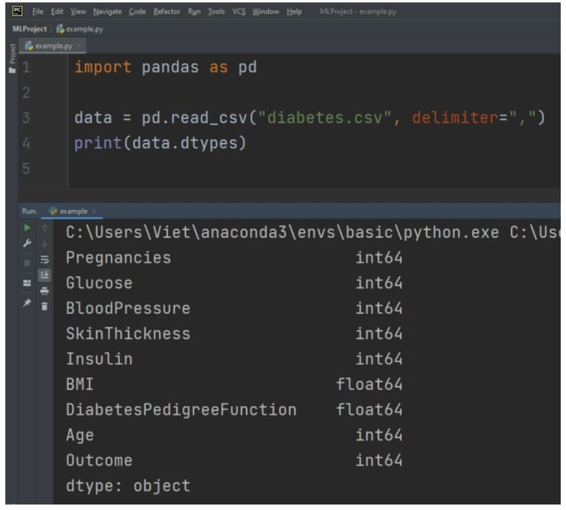


- Tất cả các features và target đều là numerical data
- Có 2 features là float, còn lại là int

# Step 2: Statistics

## Statistical Summary of Data

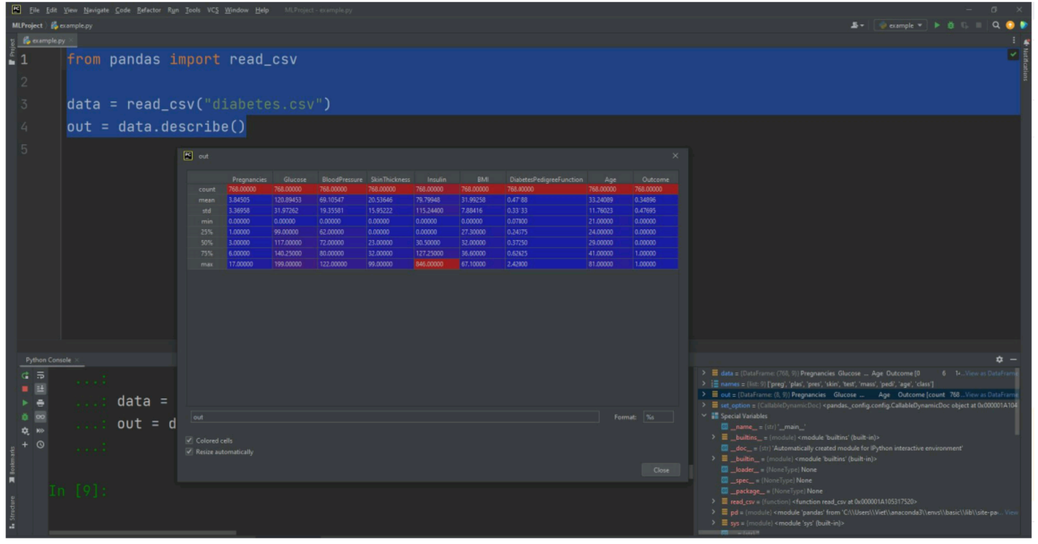

# Step 2: Statistics

## Category distribution

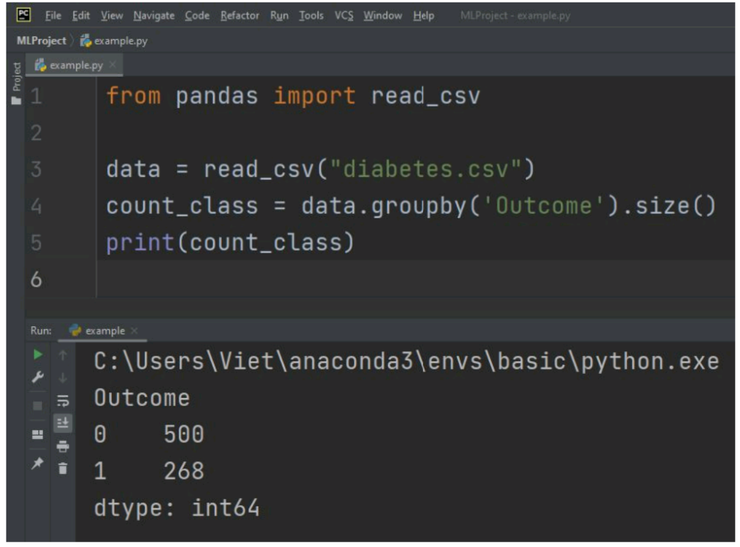

# Step 3.1: Handle missing or invalid values

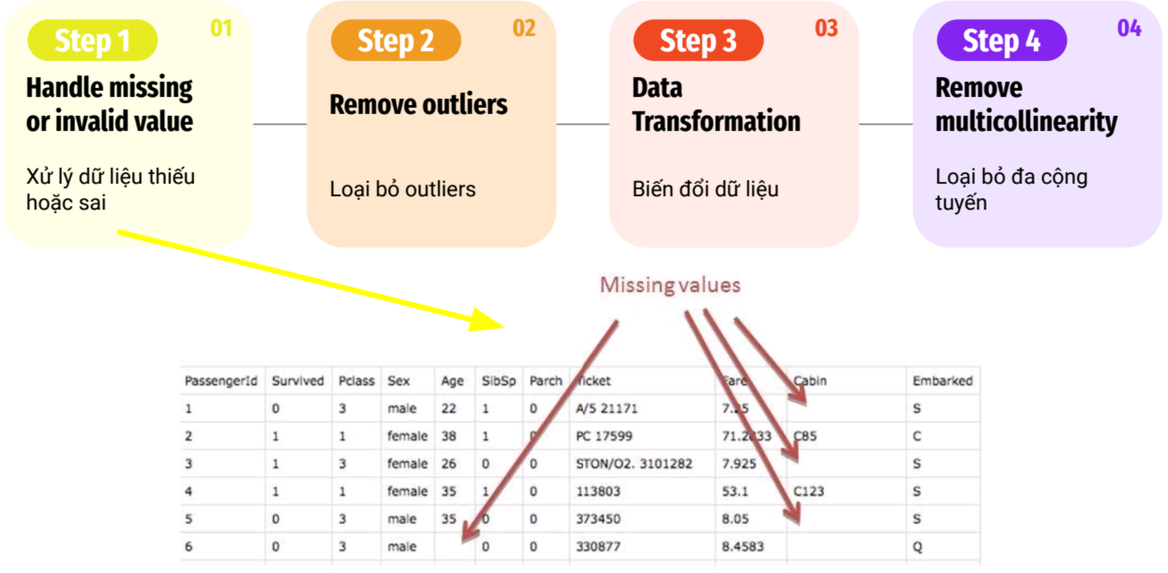

# Step 3.2: Remove outliers

**Step 1** 01

**Handle missing or invalid value**

Xử lý dữ liệu thiếu hoặc sai

**Step 2** 02

**Remove outliers**

Loại bỏ outliers

**Step 3** 03

**Data Transformation**

Biến đổi dữ liệu

**Step 4** 04

**Remove multicollinearity**

Loại bỏ đa cộng tuyến

# Step 3.3: Tiền xử lý numerical features

## MinMaxScaler

```python
from pandas import read_csv
from sklearn.preprocessing import MinMaxScaler

data = read_csv("diabetes.csv")
scaler = MinMaxScaler(feature_range=(0, 1))
before = data[["Pregnancies"]].values
after = scaler.fit_transform(data[["Pregnancies"]])
for b, a in zip(before, after):
    print("Before: {}. After: {}".format(b, a))
```

```
C:\Users\Viet\anaconda3\envs\basic\python.exe C:\Users\
Before: [6]. After: [0.35294118]
Before: [1]. After: [0.05882353]
Before: [8]. After: [0.47058824]
Before: [1]. After: [0.05882353]
Before: [0]. After: [0.]
Before: [5]. After: [0.29411765]
Before: [3]. After: [0.17647059]
Before: [10]. After: [0.58823529]
Before: [2]. After: [0.11764706]
Before: [8]. After: [0.47058824]
```

## StandardScaler

```python
from pandas import read_csv
from sklearn.preprocessing import StandardScaler

data = read_csv("diabetes.csv")
scaler = StandardScaler()
before = data[["Pregnancies"]].values
after = scaler.fit_transform(data[["Pregnancies"]])
for b, a in zip(before, after):
    print("Before: {}. After: {}".format(b, a))
```

```
C:\Users\Viet\anaconda3\envs\basic\python.exe C:\User
Before: [6]. After: [0.63994726]
Before: [1]. After: [-0.84488505]
Before: [8]. After: [1.23388019]
Before: [1]. After: [-0.84488505]
Before: [0]. After: [-1.14185152]
Before: [5]. After: [0.3429808]
Before: [3]. After: [-0.25095213]
Before: [10]. After: [1.82781311]
Before: [2]. After: [-0.54791859]
Before: [8]. After: [1.23388019]
```

# Step 3.3: Tiền xử lý ordinal features

[OrdinalEncoder]

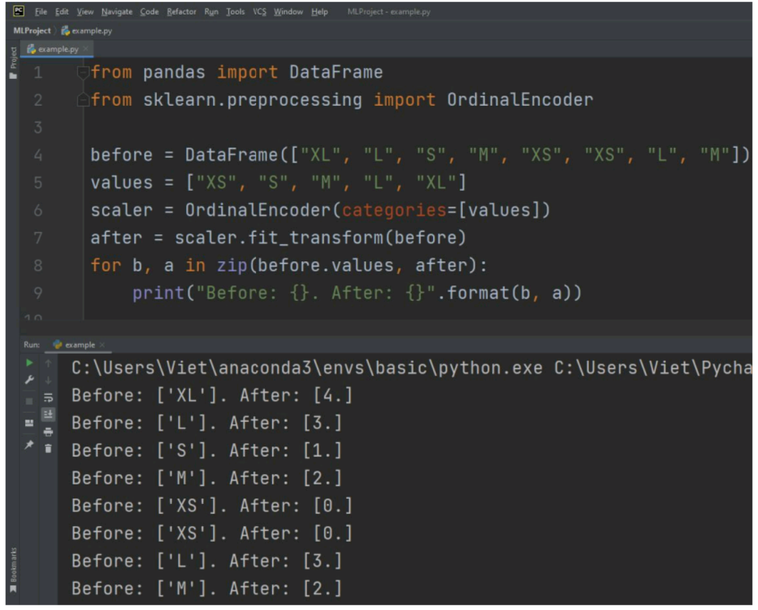

# Step 3.3: Các cách mã hóa nominal features

## One-hot encoding

### Color

- Red -> **1**, 0, 0, 0
- Green - > 0, **1**, 0, 0
- Blue -> 0, 0, **1**, 0
- Black -> 0, 0, 0, **1**

### Advantage

- Simple

### Disadvantage

- Sparse data

## Hash encoding

### Country

- USA -> **1, 0, 0**
- UK -> 0, 0, 1
- Korea -> 0, 1, 0
- Russia -> **1, 0, 0**

### Advantage

- Simple
- Less sparse

### Disadvantage

- Collision
- No inverse-mapping

## Word Embedding

### Animal

- Dog -> 0.27,-0.31, -0.53
- Lion -> **-0.7, 0.61, 0.42**
- Tiger -> **-0.71, 0.6, 0.38**
- Mouse -> 0.31, -0.34, 0.76

### Advantage

- Memory efficient
- Relationship learnt

### Disadvantage

- Word2vec model needed
- Maybe many dimensions needed

# Step 3.4: Mối quan hệ giữa các variables (features, target)

## Correlation

- **Mức độ 2 hay nhiều variables quan hệ tuyến tính với nhau**
- **Hệ số tương quan: [-1, 1]**
- **Correlation does not imply causation**

$$r_{xy} = \frac{\Sigma(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\Sigma(x_i - \bar{x})^2 \Sigma(y_i - \bar{y})^2}}$$

$r_{xy}$ = correlation coefficient between $x$ and $y$

$x_i$ = the values of $x$ within a sample

$y_i$ = the values of $y$ within a sample

$\bar{x}$ = the average of the values of $x$ within a sample

$\bar{y}$ = the average of the values of $y$ within a sample

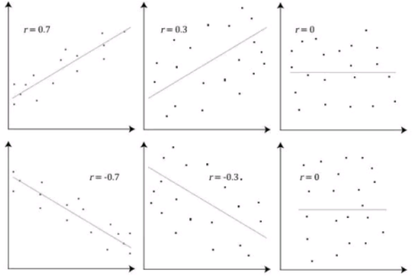


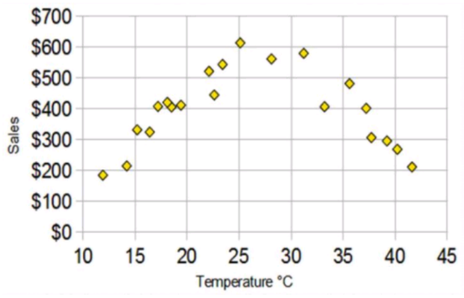

# Step 3.4: Mối quan hệ giữa các features

**(Multi)collinearity**

- **Mức độ 2 hay nhiều features quan hệ tuyến tính với nhau**
- **Thông thường hệ số tương quan > 0.7 hoặc < -0.7 biểu thị rằng 2 hay nhiều features có hiện tượng (đa) cộng tuyến với nhau**

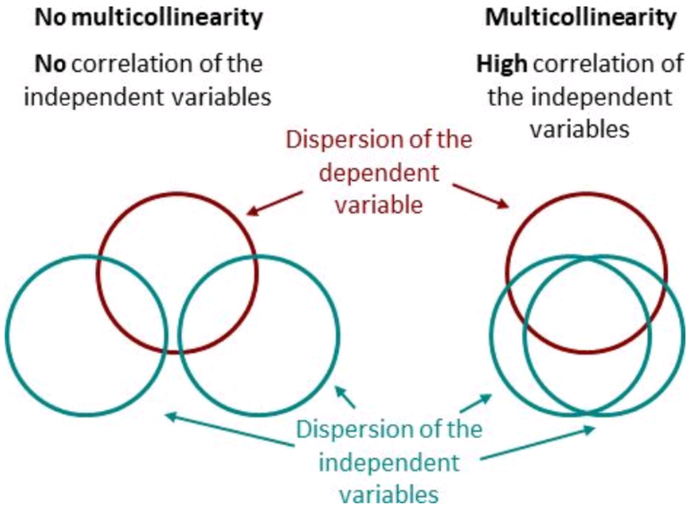

# Step 3.5: Balance data

[Over-sampling]

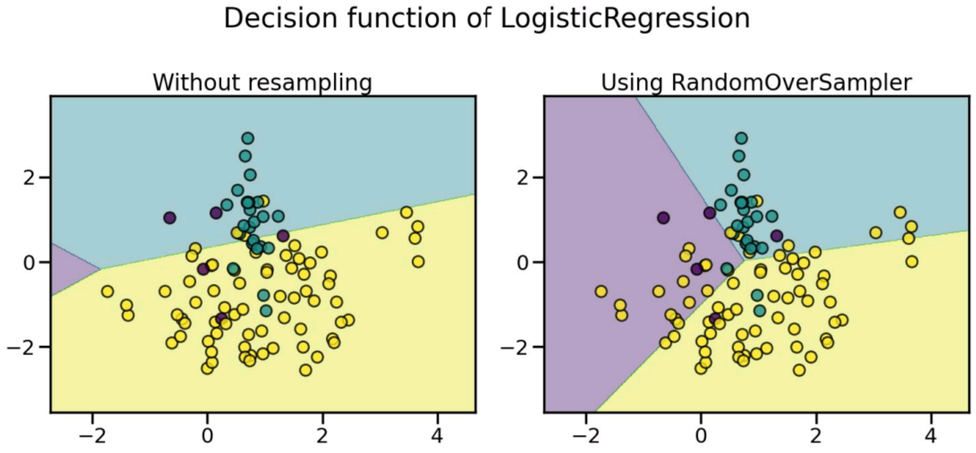

# Step 3.5: Balance data

[Over-sampling]

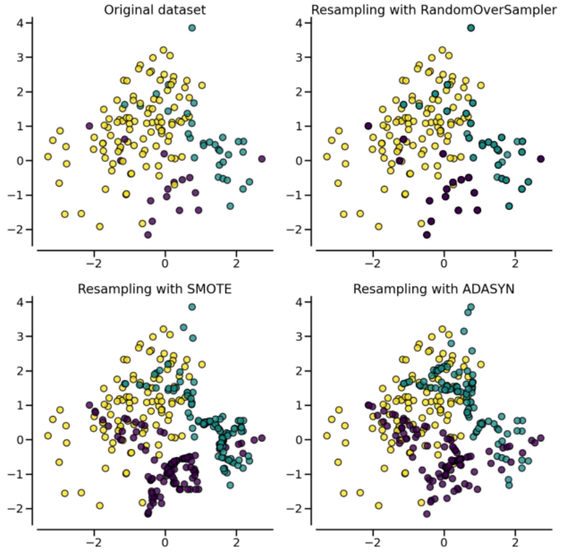

# Step 3.5: Balance data

Under-sampling

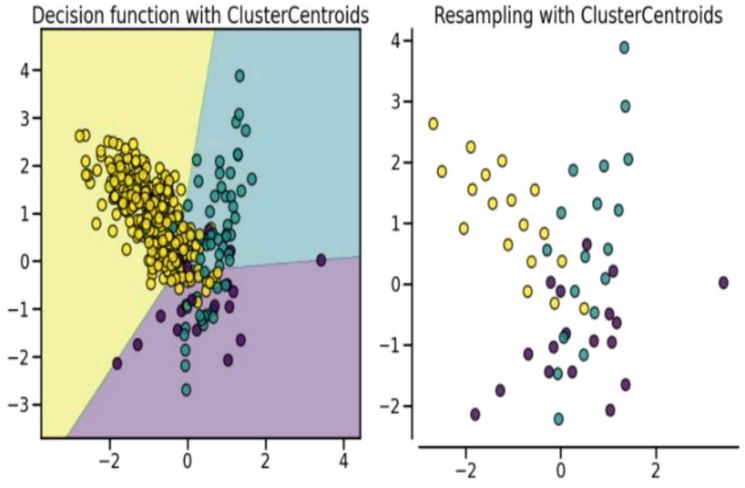

## Step 4: Data visualization

# Histogram

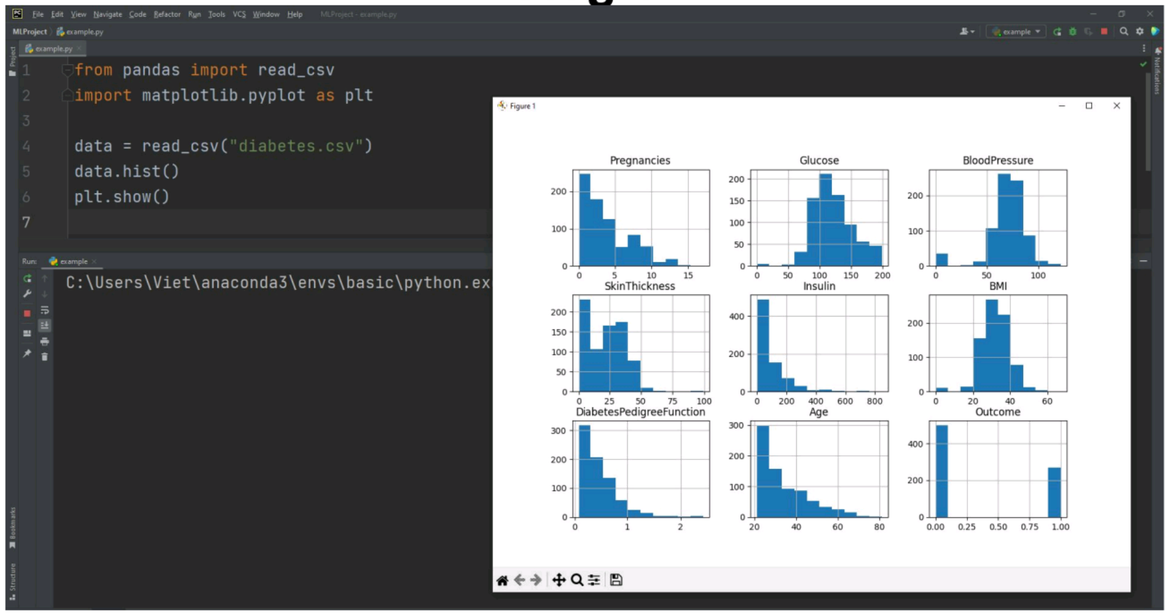
from pandas import read_csv
import matplotlib.pyplot as plt
data = read_csv("diabetes.csv")
data.hist()
plt.show()
C:\Users\Viet\anaconda3\envs\basic\python.ex
Figure 1
Pregnancies
Glucose
BloodPressure
SkinThickness
Insulin
BMI
DiabetesPedigreeFunction
Age
Outcome

# Density Plot

```python
from pandas import read_csv
import matplotlib.pyplot as plt

data = read_csv("diabetes.csv")
data.plot(kind='density', subplots=True, layout=(3, 3), sharex=False)
plt.show()
```

```
C:\Users\Viet\anaconda3\env
```

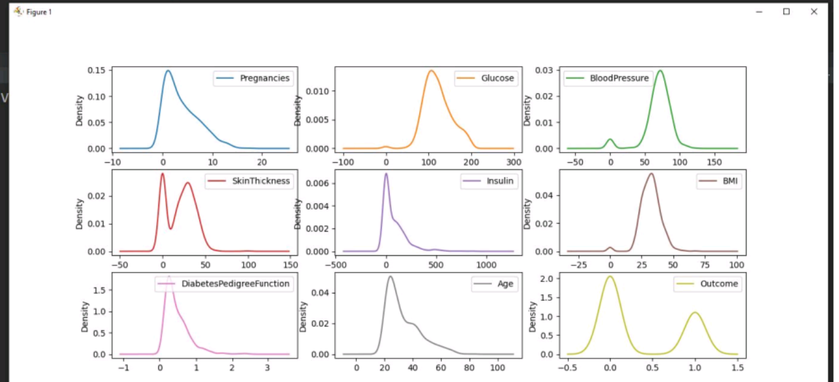

# Box Plot

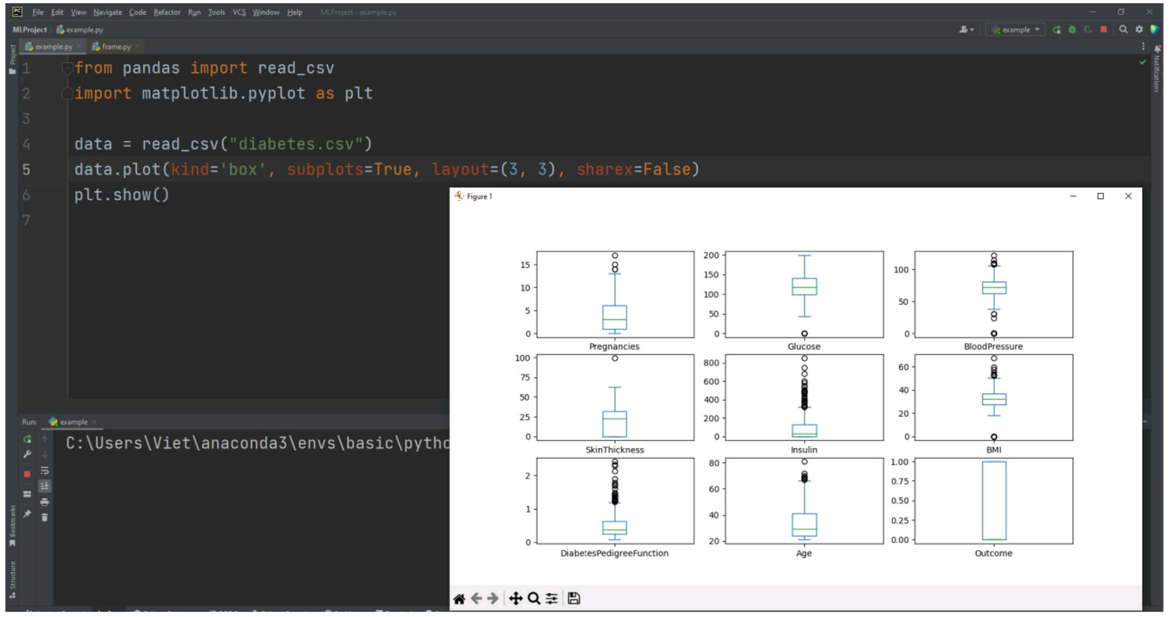
from pandas import read_csv
import matplotlib.pyplot as plt
data = read_csv("diabetes.csv")
data.plot(kind='box', subplots=True, layout=(3, 3), sharex=False)
plt.show()
C:\Users\Viet\anaconda3\envs\basic\pytho
Figure 1
Pregnancies
Glucose
BloodPressure
SkinThickness
Insulin
BMI
DiabetesPedigreeFunction
Age
Outcome

# Correlation Matrix Plot

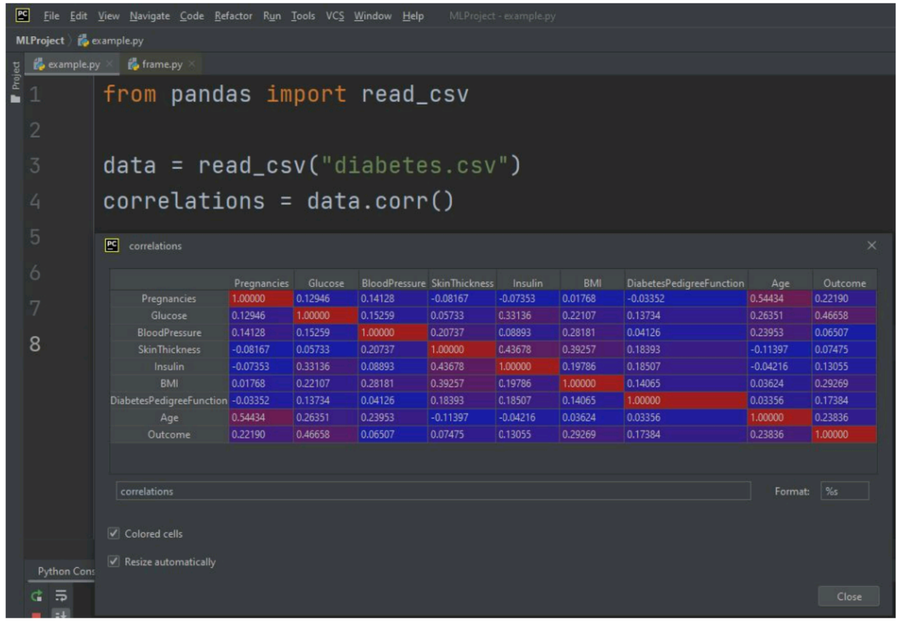

# Correlation Matrix Plot

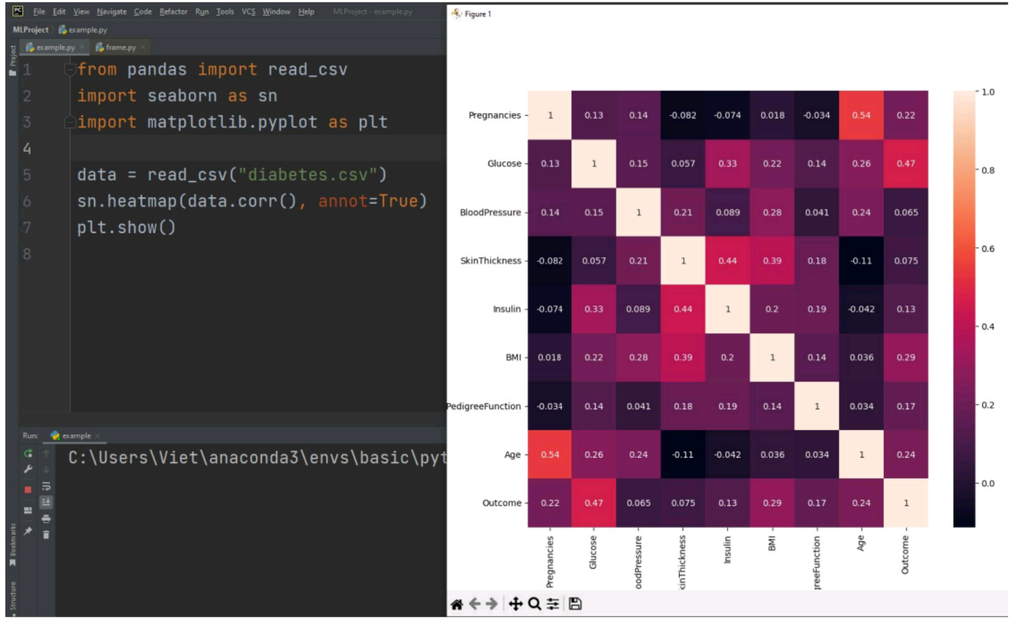

# Scatter Matrix Plot

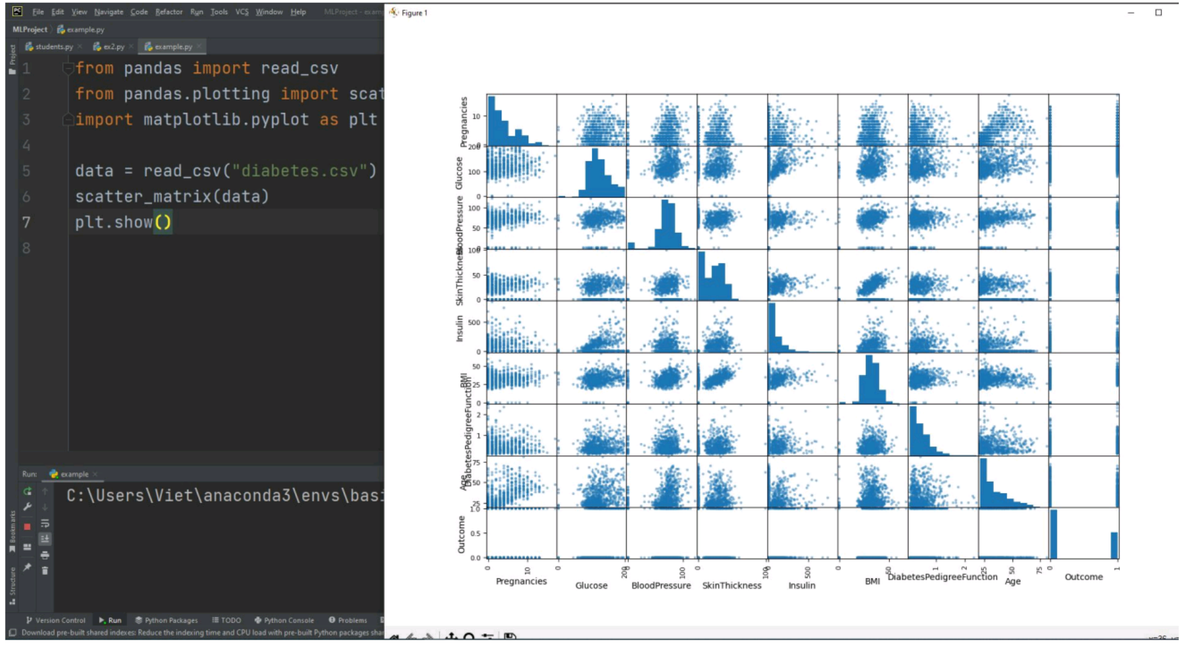

# Data visualization with matplotlib

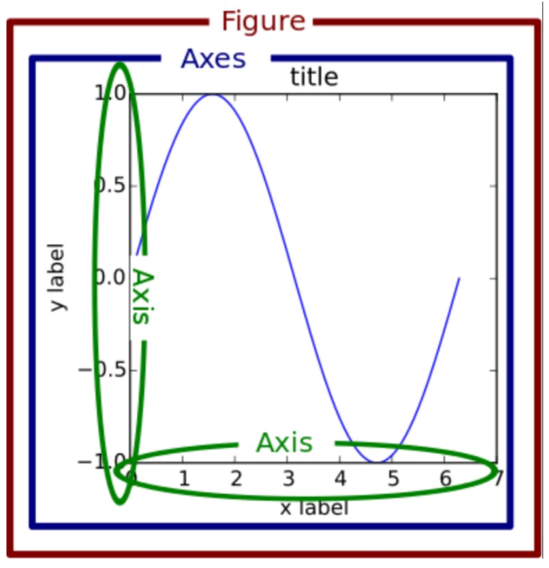


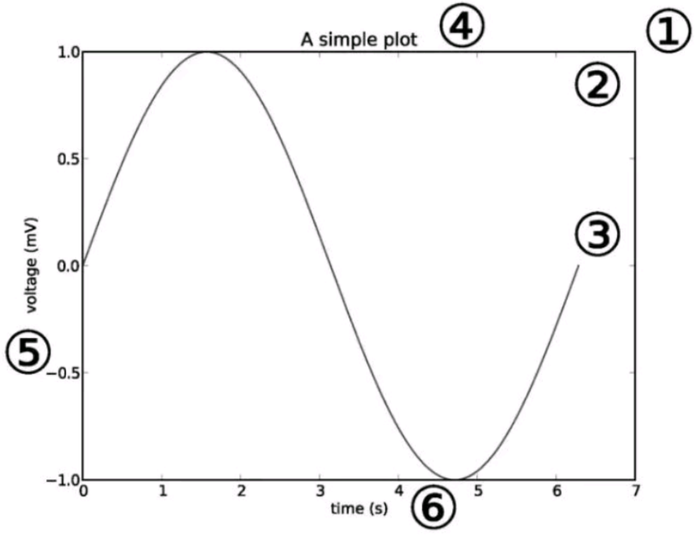

# Data visualization with matplotlib

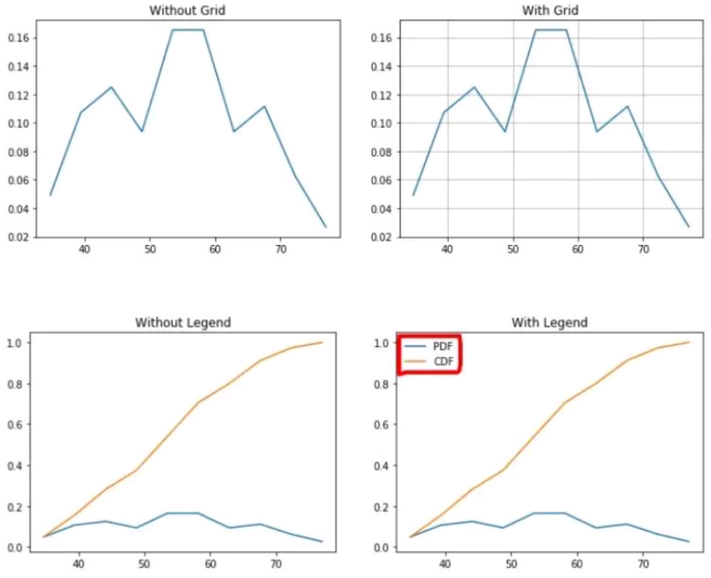

# Supervised Learning algorithms

**Regression(hồi quy)**

Linear Regression
Polynomial Regression

*Could also be used here

**Classification(Phân loại)**

Logistic Regression
Support Vector Machine*

K-nearest neighbours*
Naive Bayes
Decision Tree*
Random Forest*

# Linear Regression

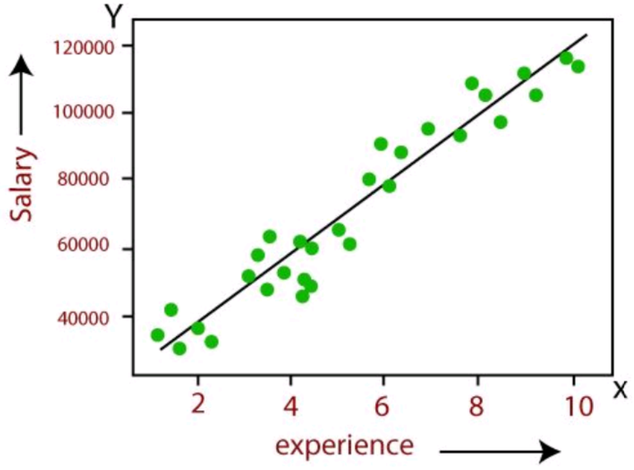


- 1 trong số các thuật toán cơ bản và đơn giản nhất trong Supervised Learning
- Simple linear regression: 1 input feature
- Multiple linear regression: 2 input features trở lên
- Phù hợp với các linear dataset

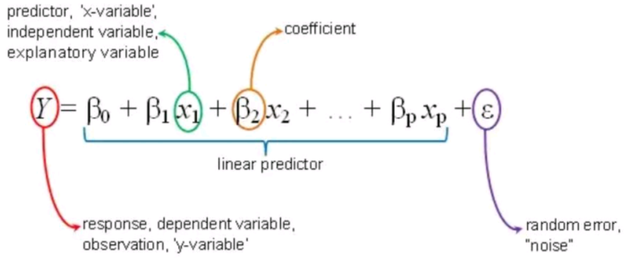

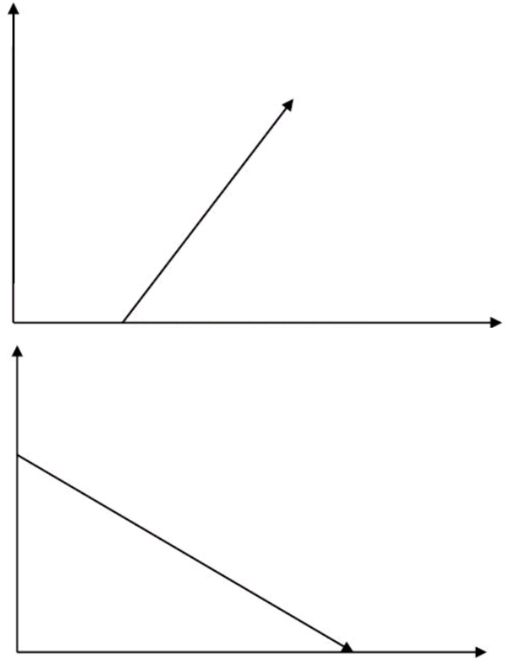

Negative Linear Relationship

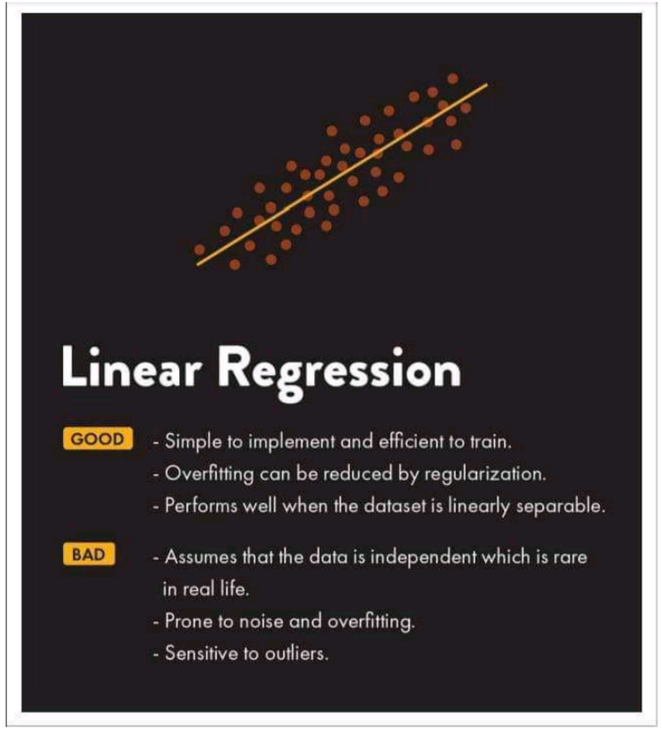

# Polynomial Regression

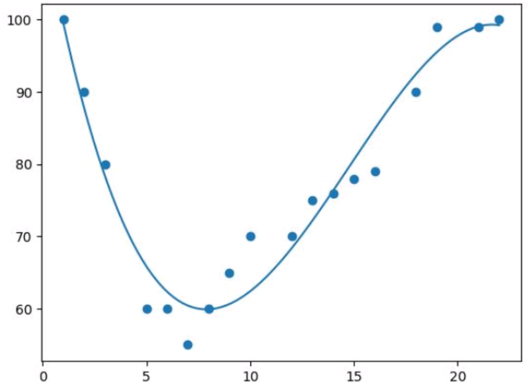


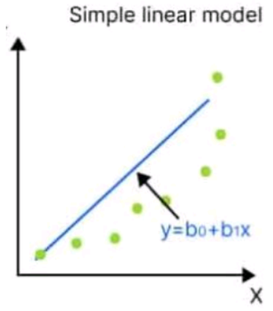


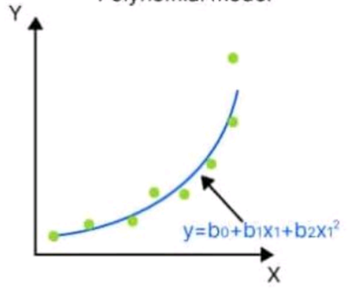

# Logistic Regression

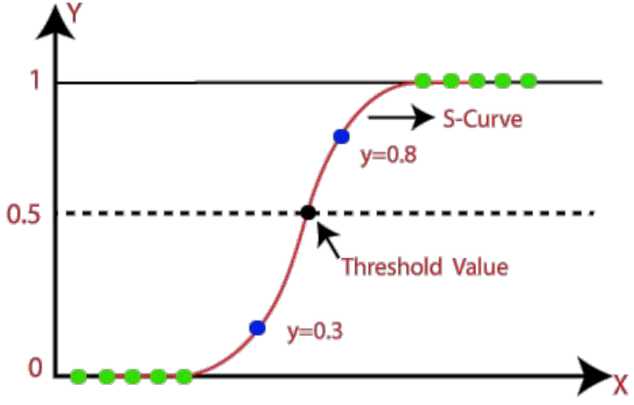


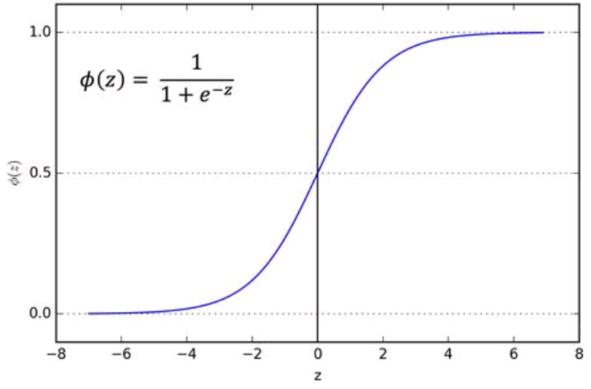

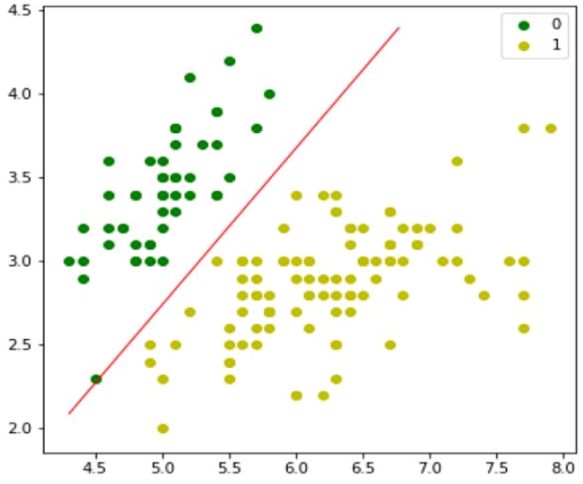
4.5
4.0
3.5
3.0
2.5
2.0
4.5
5.0
5.5
6.0
6.5
7.0
7.5
8.0
0
1

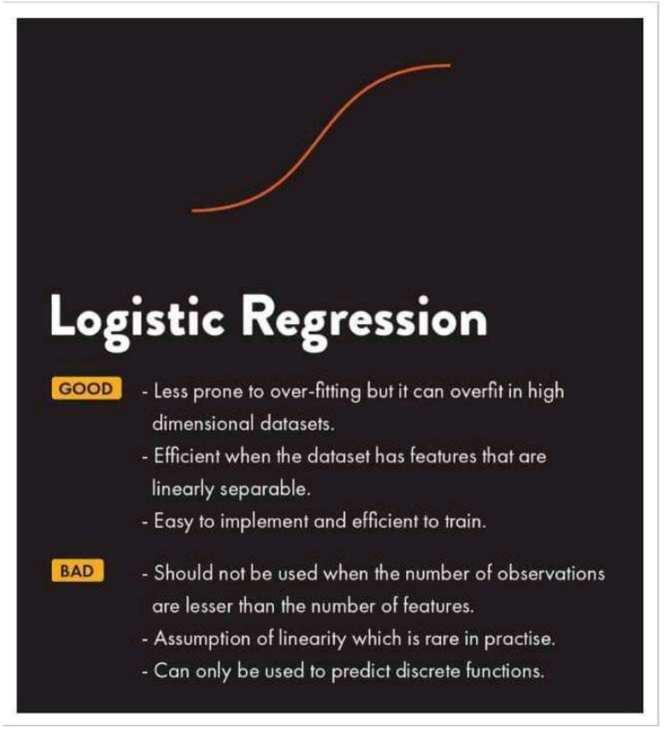
Logistic Regression
GOOD
- Less prone to over-fitting but it can overfit in high dimensional datasets.
- Efficient when the dataset has features that are linearly separable.
- Easy to implement and efficient to train.
BAD
- Should not be used when the number of observations are lesser than the number of features.
- Assumption of linearity which is rare in practise.
- Can only be used to predict discrete functions.

# Support Vector Machine

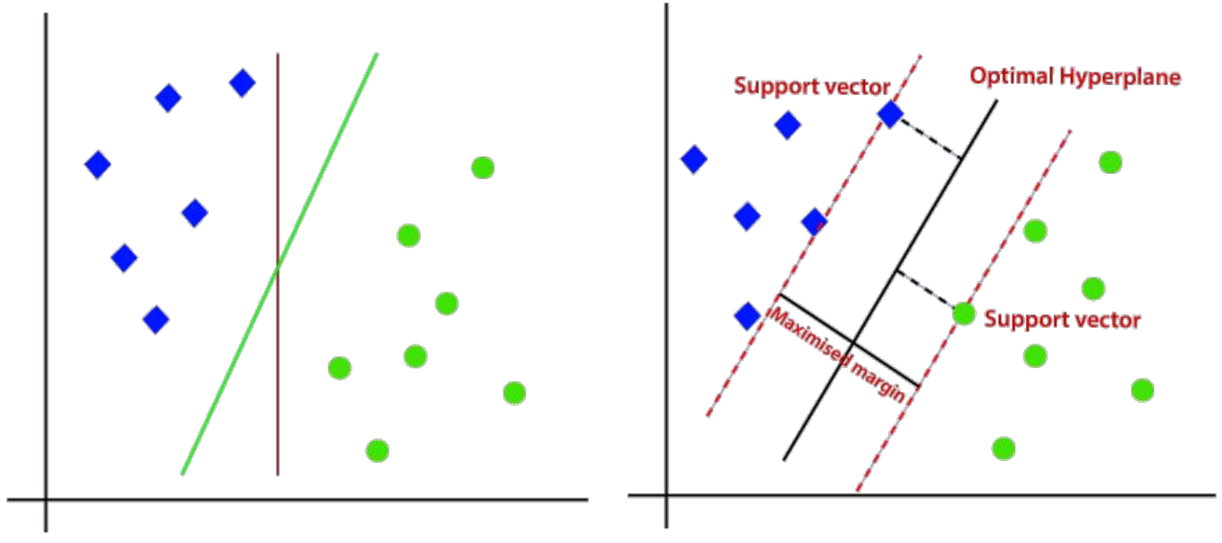

# Support Vector Machine

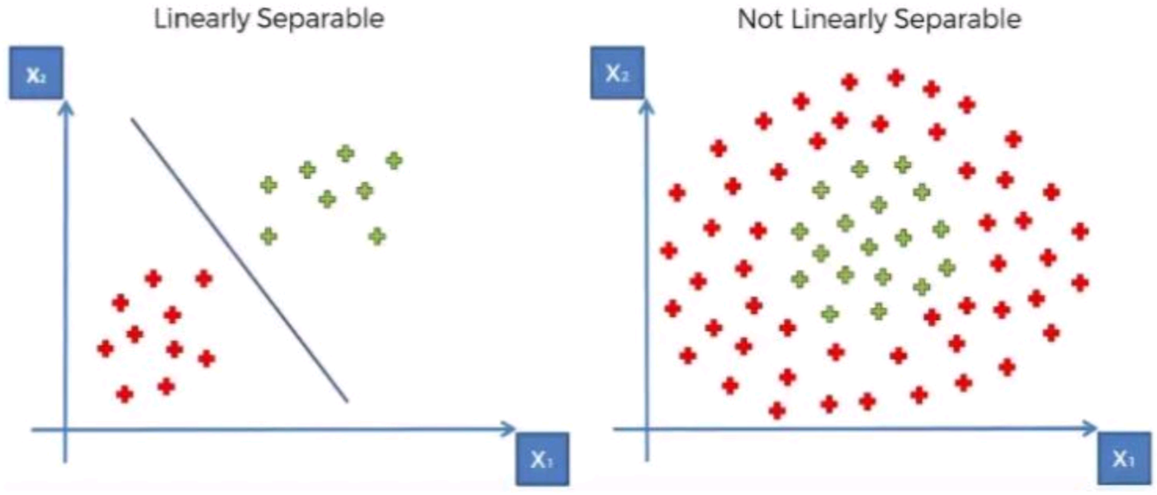

# Support Vector Machine

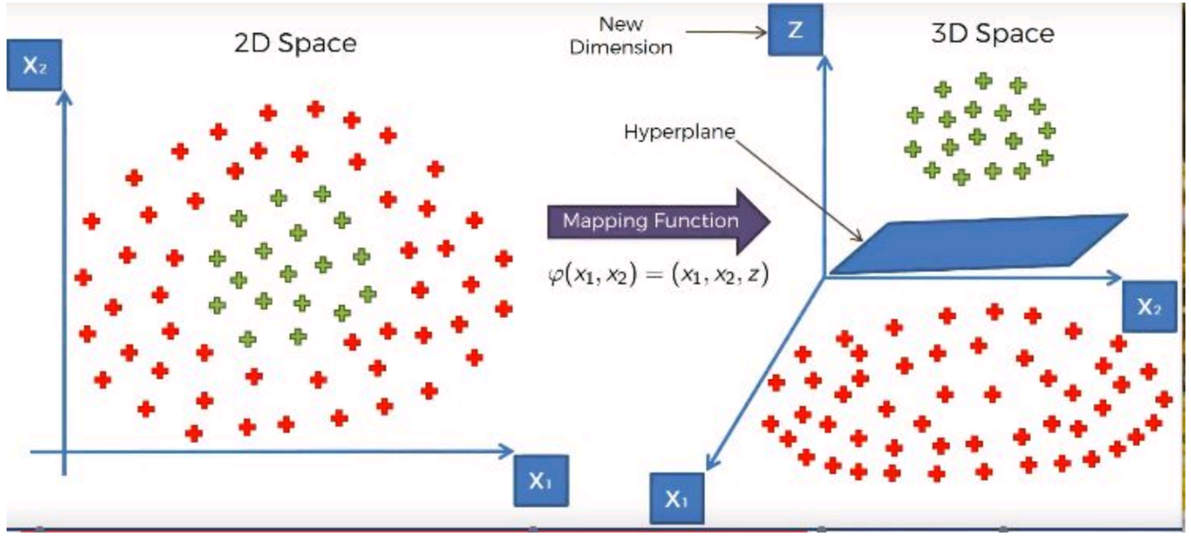

# Support Vector Machine

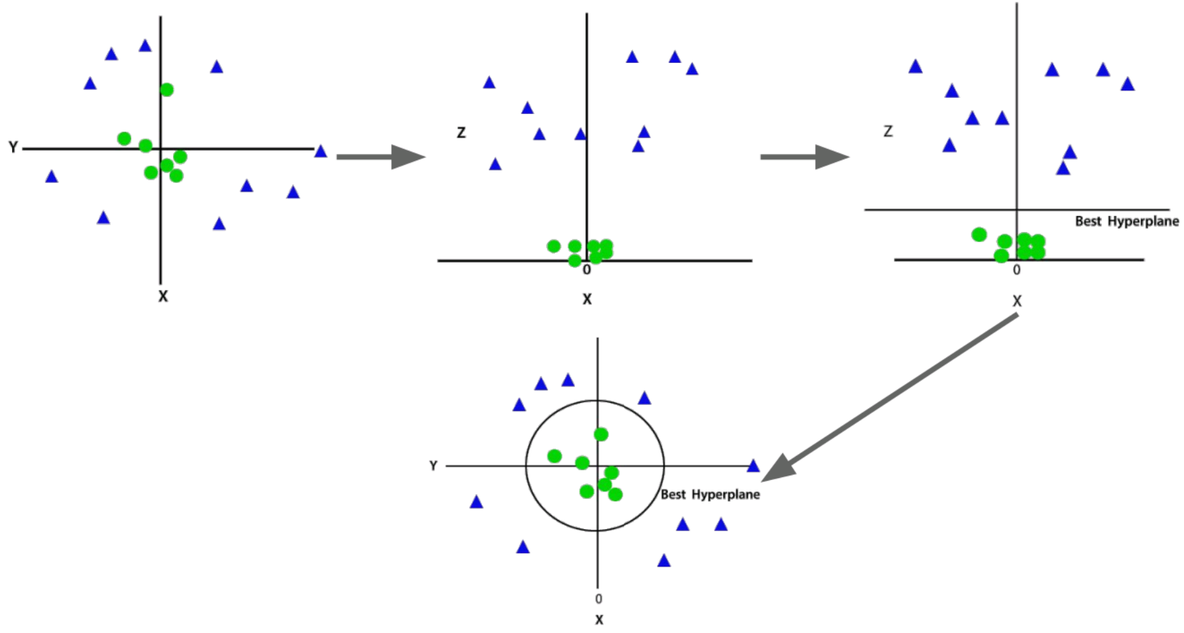

# K-Nearest-Neighbour

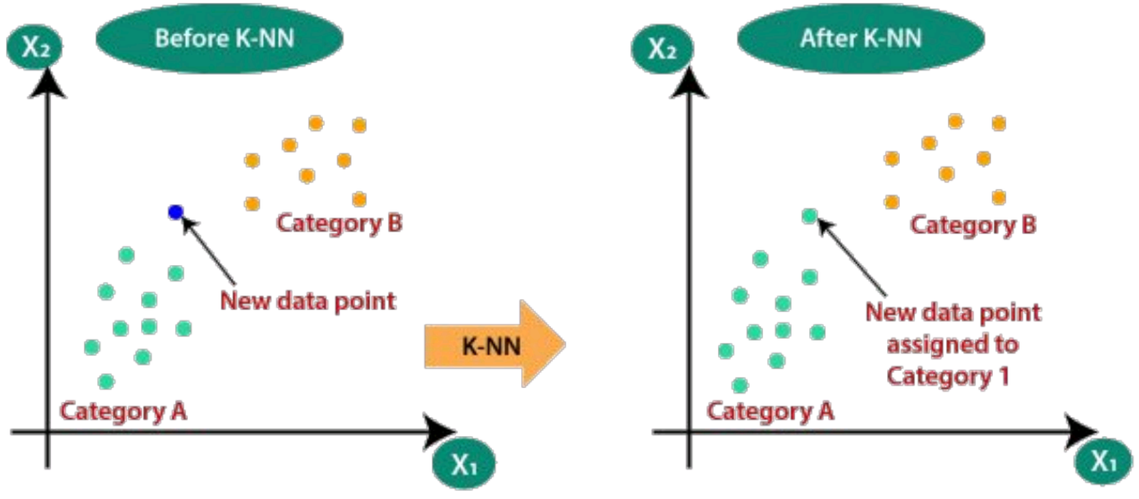

# Decision Tree

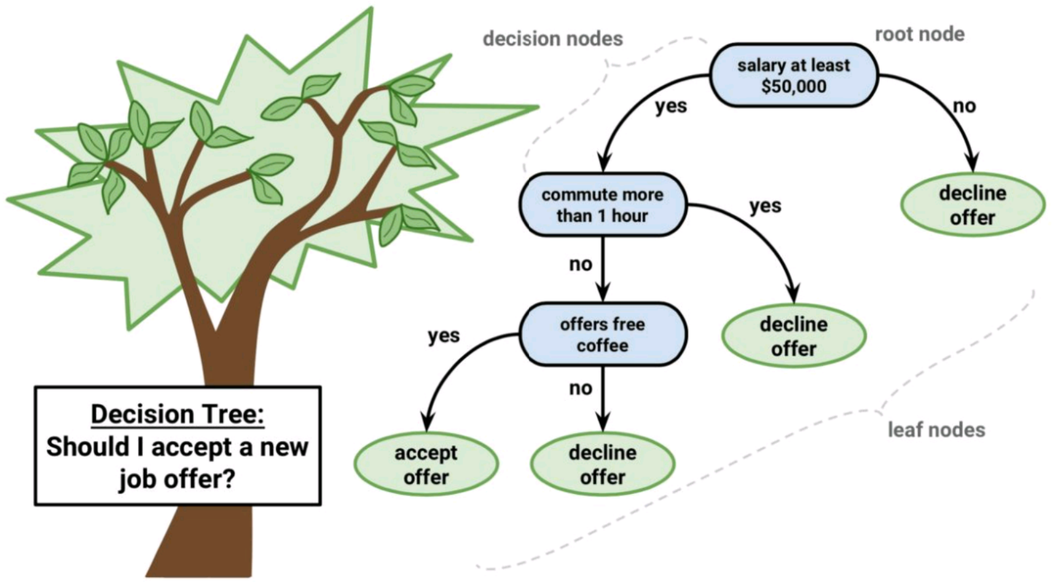

# Decision Tree

$$Gini = 1 - \sum_{i=1}^{C} (p_i)^2$$

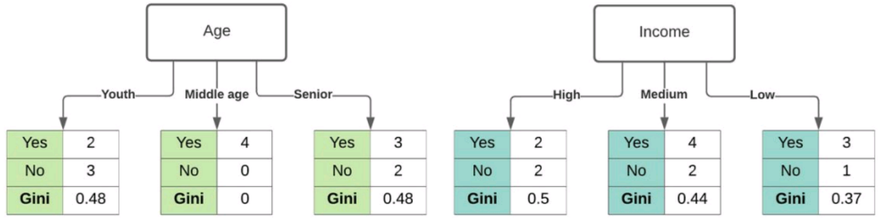

# Random Forest

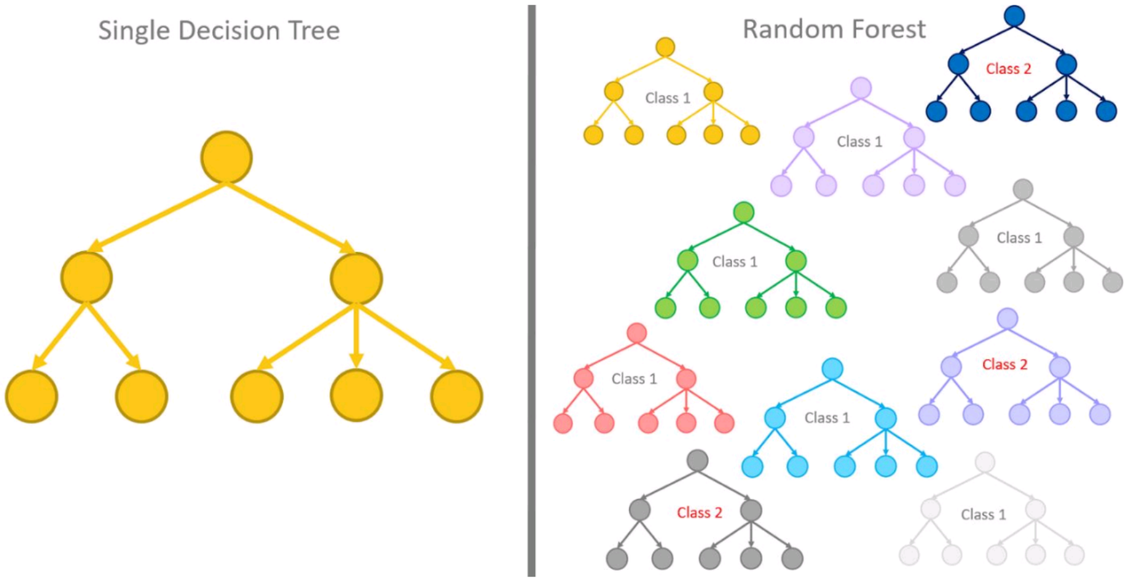

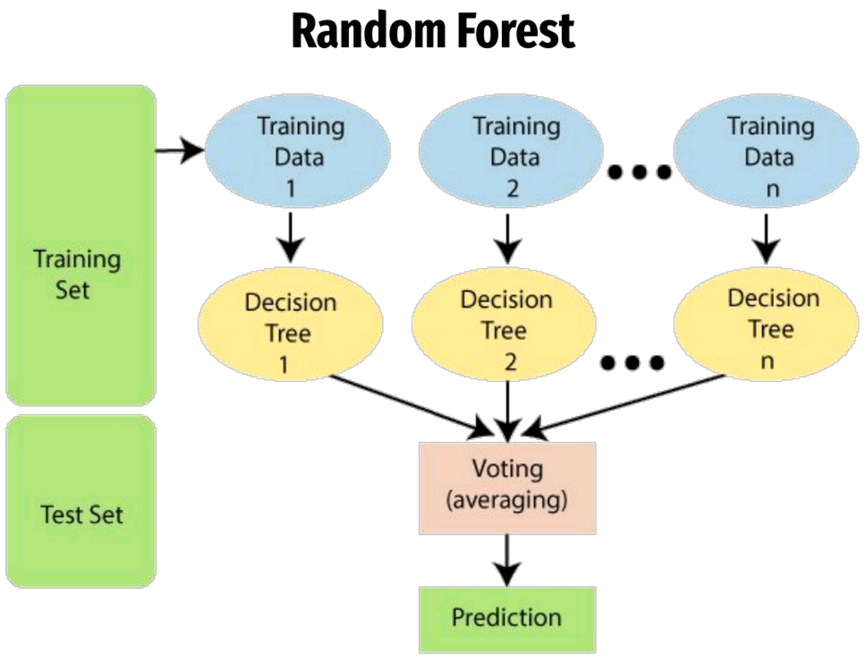
Random Forest
Training Set
Test Set
Training Data 1
Training Data 2
Training Data n
Decision Tree 1
Decision Tree 2
Decision Tree n
Voting (averaging)
Prediction

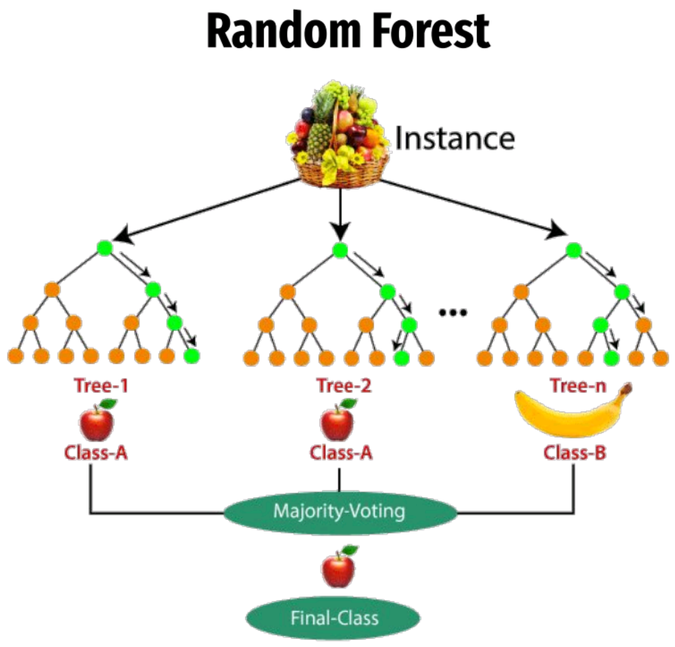
Random Forest
Instance
Tree-1
Tree-2
Tree-n
Class-A
Class-A
Class-B
Majority-Voting
Final-Class

# Unsupervised Learning algorithms

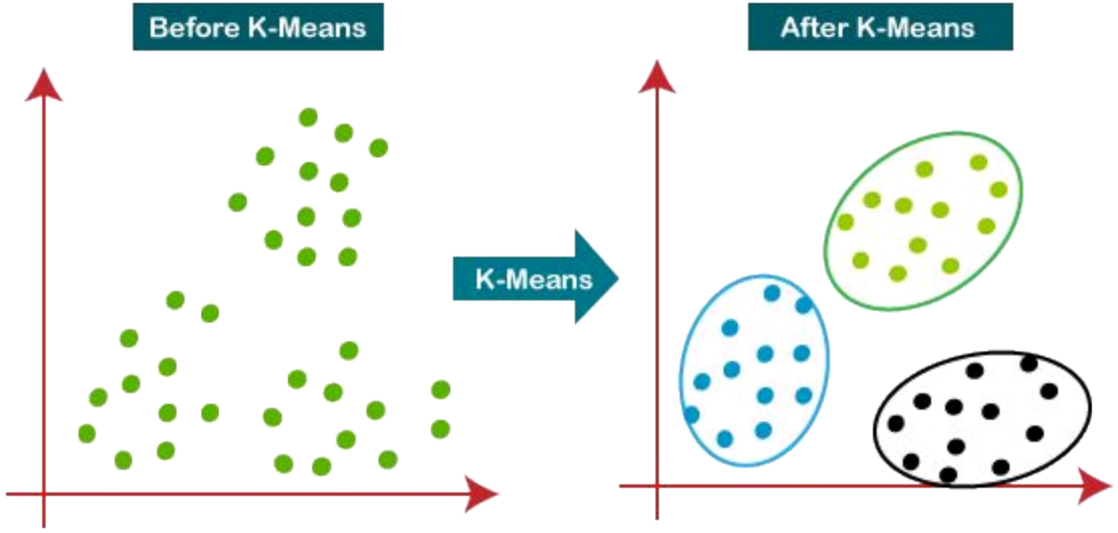

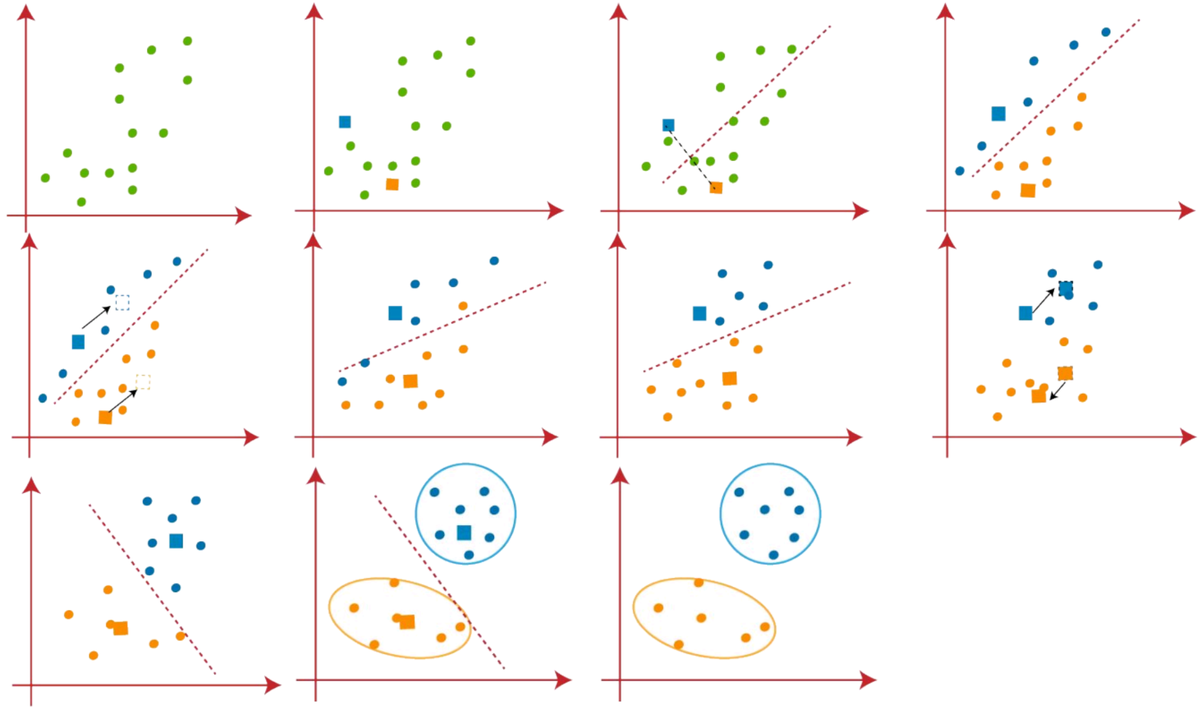

# Natural Language Processing

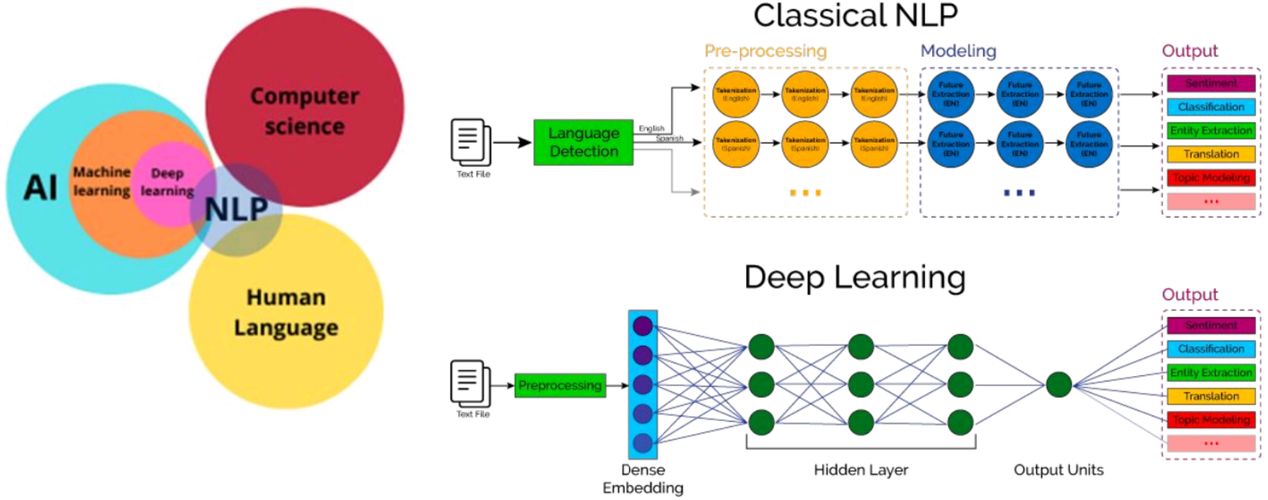

# Natural Language Processing

## The Bag of Words Representation

I love this movie! It's sweet, but with satirical humor. The dialogue is great and the adventure scenes are fun... It manages to be whimsical and romantic while laughing at the conventions of the fairy tale genre. I would recommend it to just about anyone. I've seen it several times, and I'm always happy to see it again whenever I have a friend who hasn't seen it yet!

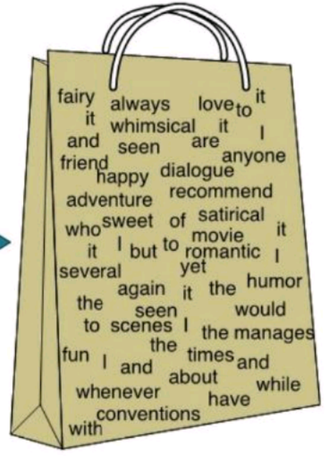


| | |
|---|---|
| it | 6 |
| I | 5 |
| the | 4 |
| to | 3 |
| and | 3 |
| seen | 2 |
| yet | 1 |
| would | 1 |
| whimsical | 1 |
| times | 1 |
| sweet | 1 |
| satirical | 1 |
| adventure | 1 |
| genre | 1 |
| fairy | 1 |
| humor | 1 |
| have | 1 |
| great | 1 |
| … | … |

# Bag of words

```
corpus = [
    "This is the best book I have ever read",
    "Reading books is the best way to gain knowledge",
    "Which book you prefer. This one or the another one?",
    "Is this the book you love most?"
]
```

**Make vocabulary**

| 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 | 16 | 17 | 18 | 19 | 20 | 21 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| another | best | book | books | ever | gain | have | is | knowledge | love | most | one | or | prefer | read | reading | the | this | to | way | which | you |

**Score assignment**

| 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 | 16 | 17 | 18 | 19 | 20 | 21 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 1 | 1 | 0 | 1 | 0 | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 0 | 1 | 1 | 0 | 0 | 0 | 0 |
| 0 | 1 | 0 | 1 | 0 | 1 | 0 | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 1 | 0 | 1 | 1 | 0 | 0 |
| 1 | 0 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 2 | 1 | 1 | 0 | 0 | 1 | 1 | 0 | 0 | 1 | 1 |
| 0 | 0 | 1 | 0 | 0 | 0 | 0 | 1 | 0 | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 1 | 1 | 0 | 0 | 0 | 1 |

## CountVectorizer

```python
from sklearn.feature_extraction.text import CountVectorizer

corpus = [
    "This is the best book I have ever read",
    "Reading books is the best way to gain knowledge",
    "Which book you prefer. This one or the another one?",
    "Is this the book you love most?"
]
vectorizer = CountVectorizer()
data = vectorizer.fit_transform(corpus)
vocabulary = vectorizer.get_feature_names_out()
print("Vocabulary:")
print(vocabulary)
result = data.toarray()
print("Bag of words:")
print(result)
```

```
example
C:\Users\Viet\anaconda3\envs\basic\python.exe C:\Users\Viet\PycharmProjects\basic\example.py
Vocabulary:
['another' 'best' 'book' 'books' 'ever' 'gain' 'have' 'is' 'knowledge'
 'love' 'most' 'one' 'or' 'prefer' 'read' 'reading' 'the' 'this' 'to'
 'way' 'which' 'you']
Bag of words:
[[0 1 1 0 1 0 1 1 0 0 0 0 0 0 1 0 1 1 0 0 0 0]
 [0 1 0 1 0 1 0 1 1 0 0 0 0 0 0 1 1 0 1 1 0 0]
 [1 0 1 0 0 0 0 0 0 0 0 2 1 1 0 0 1 1 0 0 1 1]
 [0 0 1 0 0 0 0 1 0 1 1 0 0 0 0 0 1 1 0 0 0 1]]
```

# Text preprocessing

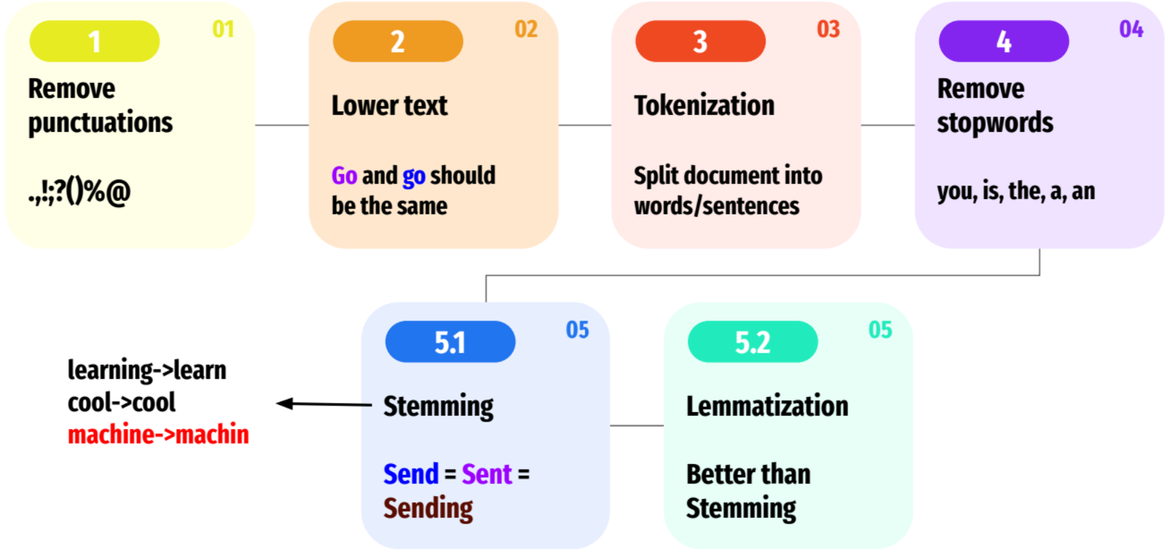

# Bag of words

| Document | Vocabulary (no stopwords) | Bag of words' vector |
|---|---|---|
| This is a good job. I will not ignore it | Good, job, not, ignore, take | 1,1,1,1,0 |
| This is not a good job. I will ignore it | | 1,1,1,1,0 |
| This is a good job. I will take it | | 1,1,0,0,1 |

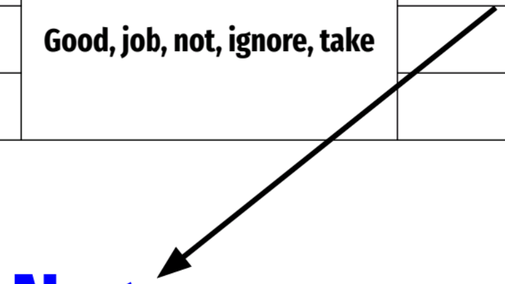

**N-grams**

# N-grams

## This is Big Data AI Book

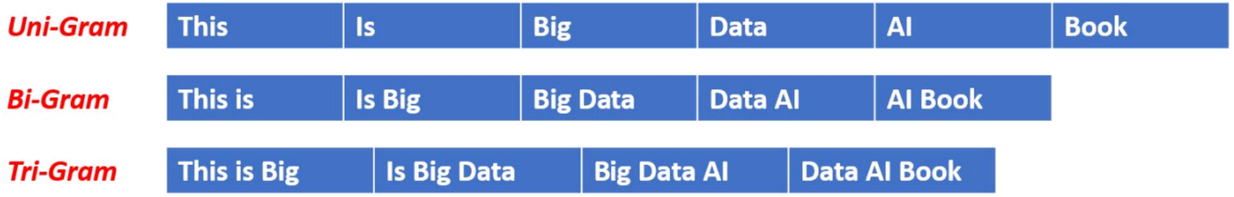

## CountVectorizer

```python
from sklearn.feature_extraction.text import CountVectorizer

corpus = [
    "This is the best book I have ever read",
    "Reading books is the best way to gain knowledge",
    "Which book you prefer. This one or the another one?",
    "Is this the book you love most?"
]
vectorizer = CountVectorizer(ngram_range=(1, 2), stop_words="english")
```

```
BoW
Vocabulary:
['another' 'another one' 'best' 'best book' 'best way' 'book' 'book have'
 'book you' 'books' 'books is' 'ever' 'ever read' 'gain' 'gain knowledge'
 'have' 'have ever' 'is' 'is the' 'is this' 'knowledge' 'love' 'love most'
 'most' 'one' 'one or' 'or' 'or the' 'prefer' 'prefer this' 'read'
 'reading' 'reading books' 'the' 'the another' 'the best' 'the book'
 'this' 'this is' 'this one' 'this the' 'to' 'to gain' 'way' 'way to'
 'which' 'which book' 'you' 'you love' 'you prefer']
Bag of words:
[[0 0 1 1 0 1 1 0 0 0 1 1 0 0 1 1 1 1 0 0 0 0 0 0 0 0 0 0 0 1 0 0 1 0 1 0
  1 1 0 0 0 0 0 0 0 0 0 0 0]
 [0 0 1 0 1 0 0 0 1 1 0 0 1 1 0 0 1 1 0 1 0 0 0 0 0 0 0 0 0 1 1 1 0 1 0
  0 0 0 0 1 1 1 1 0 0 0 0 0]
 [1 1 0 0 0 1 0 1 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 2 1 1 1 1 1 0 0 0 1 1 0 0
  1 0 1 0 0 0 0 0 1 1 1 0 1]
 [0 0 0 0 0 1 0 1 0 0 0 0 0 0 0 0 1 0 1 0 1 1 1 0 0 0 0 0 0 0 0 0 1 0 0 1
  1 0 0 1 0 0 0 0 0 0 1 1 0]]
```

# Term Frequency-Inverse Document Frequency

$$TF = \frac{Number\ of\ times\ a\ word\ "X"\ appears\ in\ a\ Document}{Number\ of\ words\ present\ in\ a\ Document}$$

$$IDF = log\left(\frac{Number\ of\ Documents\ present\ in\ a\ Corpus}{Number\ of\ Documents\ where\ word\ "X"\ has\ appeared}\right)$$

$$TF\ IDF\ =\ TF * IDF$$

**Term Frequency (TF)**

Tần số xuất hiện của 1 word trong 1 document

**Inverse Document Frequency (IDF)**

Mức độ phổ biến/hiếm của 1 word trong toàn bộ các documents

# Time series forecasting

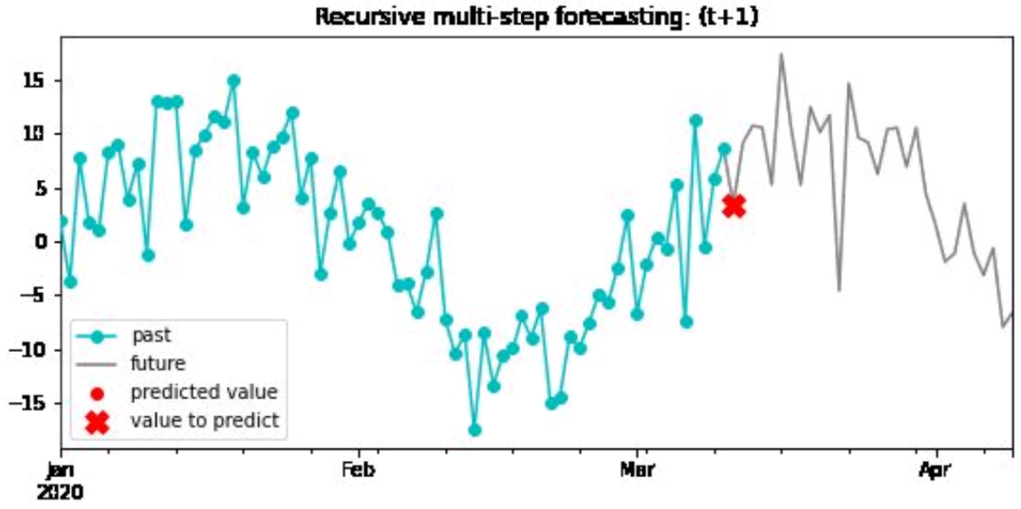

# Time series data

| date | charter_foreign | total_foreign | charter_domestic | total_domestic |
|---|---|---|---|---|
| date | bigint | bigint | bigint | bigint |
| Date | integer | integer | integer | integer |
| 2008-01-01T00:00:00.000Z | 57463 | 5642057 | 174692 | 7394181 |
| 2008-02-01T00:00:00.000Z | 56651 | 5053435 | 142931 | 6837201 |
| 2008-03-01T00:00:00.000Z | 95878 | 6071551 | 176906 | 8439191 |
| 2008-04-01T00:00:00.000Z | 100198 | 5731709 | 103054 | 7467710 |
| 2008-05-01T00:00:00.000Z | 130720 | 6003335 | 88631 | 7840260 |
| 2008-06-01T00:00:00.000Z | 196656 | 6467543 | 99579 | 8274573 |
| 2008-07-01T00:00:00.000Z | 195873 | 6861571 | 130766 | 8971734 |
| 2008-08-01T00:00:00.000Z | 152848 | 6895232 | 77253 | 8717085 |
| 2008-09-01T00:00:00.000Z | 88267 | 5539617 | 40070 | 6371669 |
| 2008-10-01T00:00:00.000Z | 76723 | 5564387 | 43003 | 6520788 |
| 2008-11-01T00:00:00.000Z | 26671 | 5128350 | 50322 | 6223857 |
| 2008-12-01T00:00:00.000Z | 30963 | 5624131 | 54894 | 6959043 |
| 2009-01-01T00:00:00.000Z | 35174 | 5399479 | 60652 | 6805171 |

| | Jan-17 | Feb-17 | Mar-17 | Apr-17 | May-17 | Jun-17 | Jul-17 | Aug-17 | Sep-17 | Oct-17 | Nov-17 | Dec-17 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Store 1 | 20 809 | 23 832 | 22 542 | 18 736 | 15 347 | 12 190 | 11 049 | 10 913 | 9 019 | 9 803 | 3 172 | 7 768 |
| Store 2 | 14 834 | 14 170 | 13 109 | 7 560 | 6 388 | 8 124 | 6 719 | 3 847 | 3 187 | 8 145 | 10 007 | 10 036 |
| Store 3 | 14 453 | 12 816 | 14 260 | 12 954 | 12 596 | 11 200 | 8 374 | 9 725 | 10 853 | 11 609 | 13 897 | 19 628 |
| Store 4 | 8 590 | 8 822 | 13 497 | 13 073 | 13 278 | 14 705 | 13 550 | 13 962 | 14 783 | 11 712 | 13 234 | 17 790 |
| Store 5 | 16 647 | 12 851 | 13 433 | 13 486 | 13 767 | 10 482 | 11 476 | 13 024 | 14 459 | 14 672 | 12 885 | 16 681 |
| Store 6 | 7 323 | 5 043 | 4 857 | 2 584 | 6 990 | 4 130 | 45 110 | 4 895 | 5 708 | 5 106 | 4 334 | 10 741 |
| Store 7 | 8 735 | 4 645 | 4 905 | 4 536 | 5 385 | 5 040 | 6 341 | 9 403 | 9 904 | 9 521 | 13 473 | 7 077 |
| Store 8 | 965 | 1 254 | 1 937 | 1 940 | 1 756 | 1 690 | 1 536 | 2 502 | 2 806 | 4 087 | 3 704 | 5 478 |
| Store 9 | 188 | 4 375 | 5 109 | 5 255 | 5 667 | 6 331 | 9 182 | 9 867 | 8 948 | 10 096 | 10 860 | 10 951 |
| Store 10 | 14 033 | 30 900 | 18 864 | 12 828 | 10 269 | 8 464 | 7 674 | 4 160 | 5 497 | 9 608 | 16 177 | 15 798 |
| Store 11 | 8 185 | 9 090 | 12 560 | 13 682 | 10 061 | 8 172 | 8 045 | 6 622 | 7 240 | 9 923 | 9 403 | 10 768 |
| Store 12 | 911 | 384 | 658 | 949 | 1 236 | 1 405 | 1 366 | 1 433 | 1 282 | 1 515 | 1 457 | 2 933 |
| Store 13 | 2 361 | 2 830 | 2 892 | 2 953 | 2 929 | 2 982 | 6 361 | 25 969 | 22 952 | 27 171 | 27 199 | 35 298 |
| Store 14 | 9 805 | 8 436 | 12 878 | 9 580 | 6 665 | 5 069 | 6 003 | 6 139 | 10 987 | 11 039 | 11 252 | 13 844 |

| Code | Name | Population\|1990 | Population\|2000 | Population\|2010 | Population Change\|1980-1990 | Population Change\|1990-2000 |
|---|---|---|---|---|---|---|
| AK | Alaska | 550043 | 626932 | 710231 | 36.9 | 14 |
| AL | Alabama | 4040587 | 4447100 | 4779736 | 3.8 | 10.1 |
| AR | Arkansas | 2350725 | 2673400 | 2915918 | 2.8 | 13.7 |
| AZ | Arizona | 3665228 | 5130632 | 6392017 | 34.8 | 40 |
| CA | California | 29760021 | 33871648 | 37253956 | 25.7 | 13.8 |
| CO | Colorado | 3294394 | 4301261 | 5029196 | 14 | 30.6 |
| CT | Connecticut | 3287116 | 3405565 | 3574097 | 5.8 | 3.6 |
| DC | District of Columbia | 606900 | 572059 | 601723 | -4.9 | -5.7 |
| DE | Delaware | 666168 | 783600 | 897934 | 12.1 | 17.6 |
| FL | Florida | 12937926 | 15982378 | 18801310 | 32.7 | 23.5 |
| GA | Georgia | 6478216 | 8186453 | 9687653 | 18.6 | 26.4 |
| HI | Hawaii | 1108229 | 1211537 | 1360301 | 14.9 | 9.3 |
| IA | Iowa | 2776755 | 2926324 | 3046355 | -4.7 | 5.4 |
| ID | Idaho | 1006749 | 1293953 | 1567582 | 6.7 | 28.5 |
| IL | Illinois | 11430602 | 12419293 | 12830632 | 0 | 8.6 |
| IN | Indiana | 5544159 | 6080485 | 6483802 | 1 | 9.7 |
| KS | Kansas | 2477574 | 2688418 | 2853118 | 4.8 | 8.5 |
| KY | Kentucky | 3685296 | 4041769 | 4339367 | 0.7 | 9.7 |
| LA | Louisiana | 4219973 | 4468976 | 4533372 | 0.3 | 5.9 |

# Time series data

| 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|---|---|---|---|---|---|---|---|---|---|

Time series

| 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|---|---|---|---|---|---|---|---|---|---|

Exogenous variable

| a | b | c | d | e | f | g | h | i | j |
|---|---|---|---|---|---|---|---|---|---|

| X | | | | | | y |
|---|---|---|---|---|---|---|
| 1 | 2 | 3 | 4 | 5 | f | 6 |
| 2 | 3 | 4 | 5 | 6 | g | 7 |
| 3 | 4 | 5 | 6 | 7 | h | 8 |
| 4 | 5 | 6 | 7 | 8 | i | 9 |
| 5 | 6 | 7 | 8 | 9 | j | 10 |

# Recursive multi-step Time series Forecasting

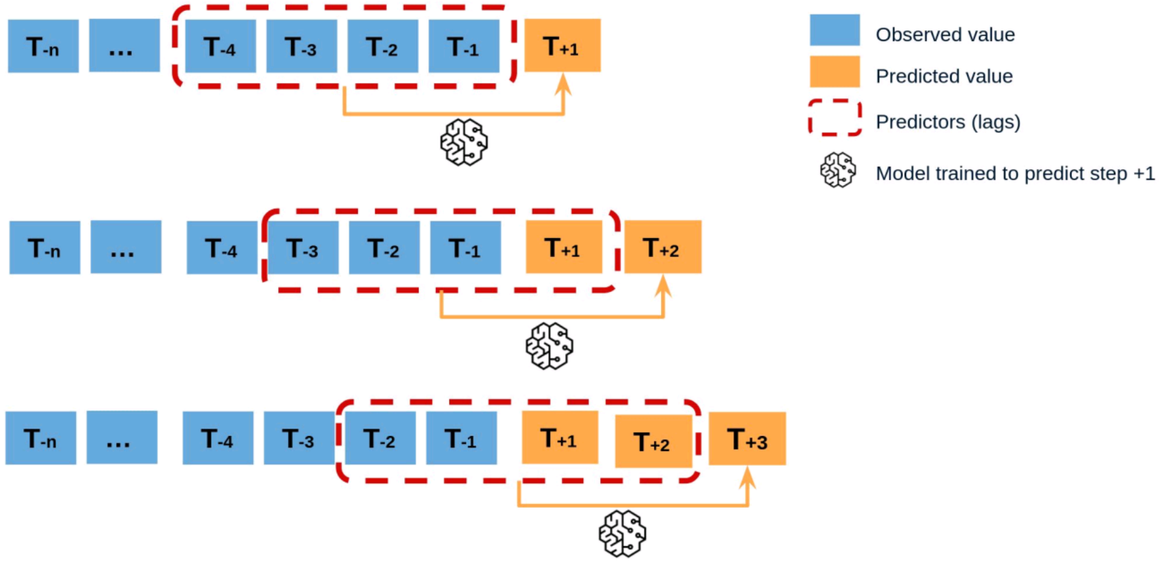

# Direct multi-step Time series Forecasting

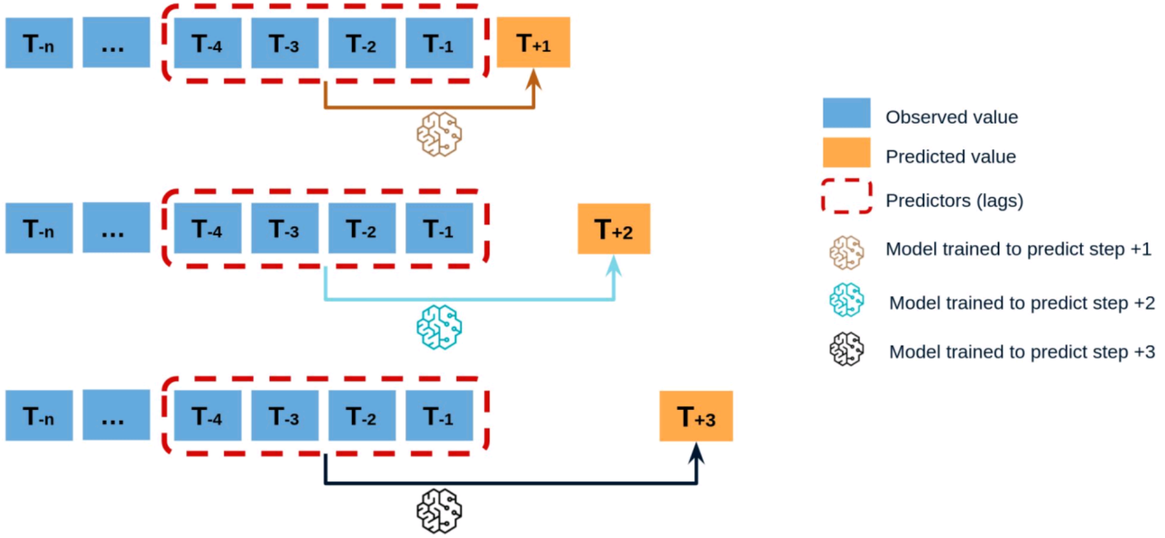

# Error in Machine Learning

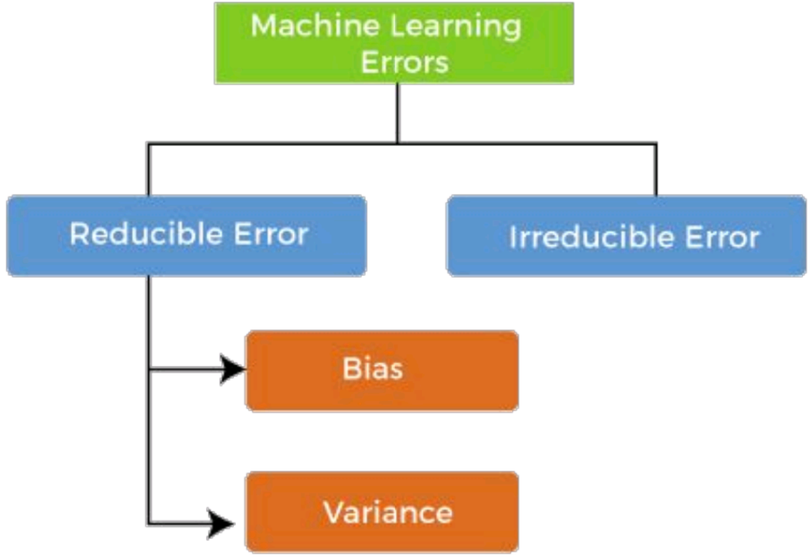

# Error in Machine Learning

## Bias

- Sai lệch giữa prediction và actual label
- Cho ta biết khả năng dự đoán chính xác của mô hình
- Bias càng bé càng tốt
- High bias means:
  - Overly-simplified model
  - Under-fitting
  - High error on both training and test sets

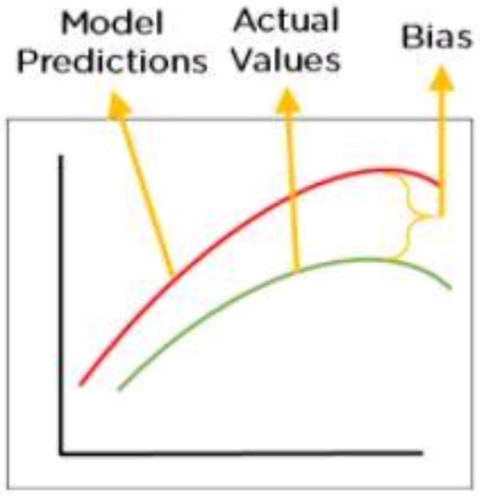

# Error in Machine Learning

## Variance

- Mức độ thay đổi của độ chính xác của prediction nếu input thay đổi
- Cho ta biết khả năng tổng quát hóa của mô hình
- Variance càng bé càng tốt
- High variance means:
  - Overly-complex model
  - Over-fitting
  - Low error on training set but high error on test set

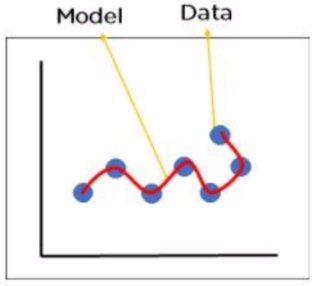


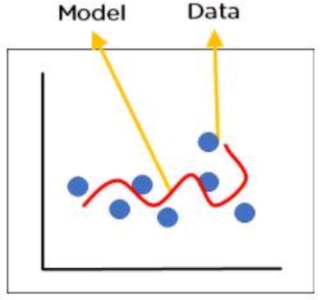

# Bias-Variance tradeoff

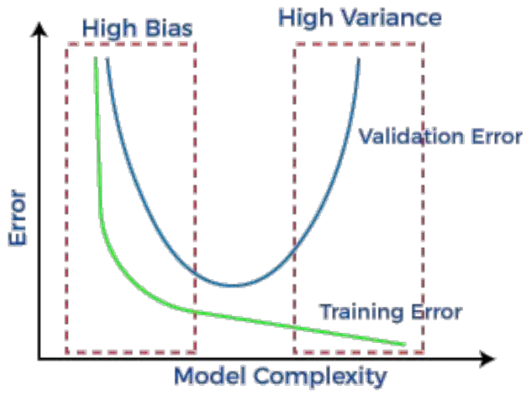


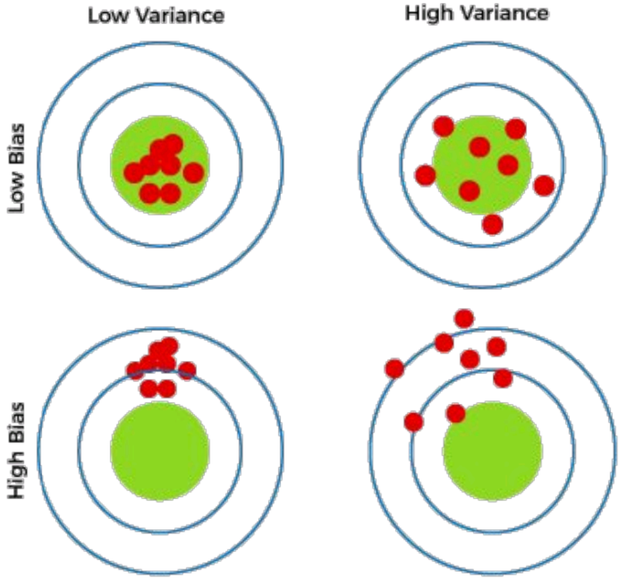

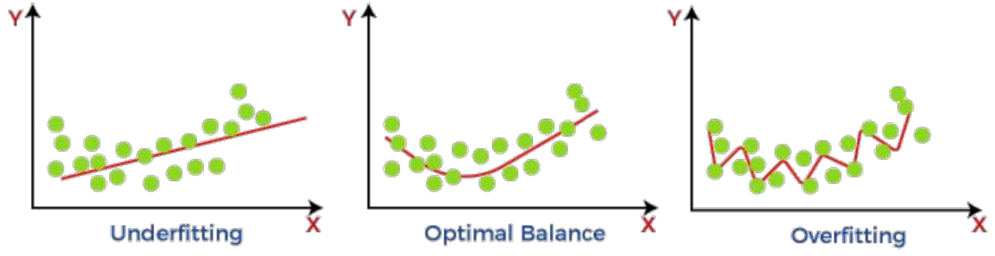
Y
X
Underfitting
Y
X
Optimal Balance
Y
X
Overfitting

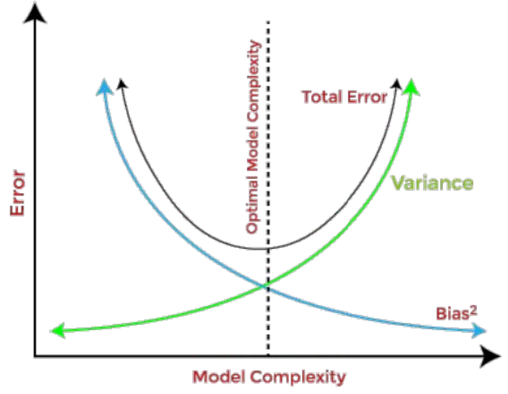
Error
Optimal Model Complexity
Total Error
Variance
Bias²
Model Complexity

# Choose Machine Learning model based on data

## Low bias + high variance

- Decision tree
- Random Forest
- K-nearest neighbours
- Kernel SVM

-> Phù hợp khi có nhiều data và ít features

## High bias + low variance

- Linear regression
- Logistic regression
- Linear SVM

-> Phù hợp khi có ít data và nhiều features

## Extra

Nếu có nhiều data và nhiều features

- Giảm chiều dữ liệu (e.g. PCA)
- Sử dụng Neural network

# Choose Machine Learning model based on business domain

- **Which metric is important?**
  - Accuracy, precision, recall, F1, ...
- **What is the priority?**
  - Speed: self-driving car app need to be realtime -> fast
  - Memory: Model deployed in embedded device needs to be small
  - Accuracy: In medical field, accuracy is the most important factor
- **Interpretability ?**
  - Do you need to explain result?
  - Do you need to find out which features are important?

# Machine Learning algorithm's interpretability

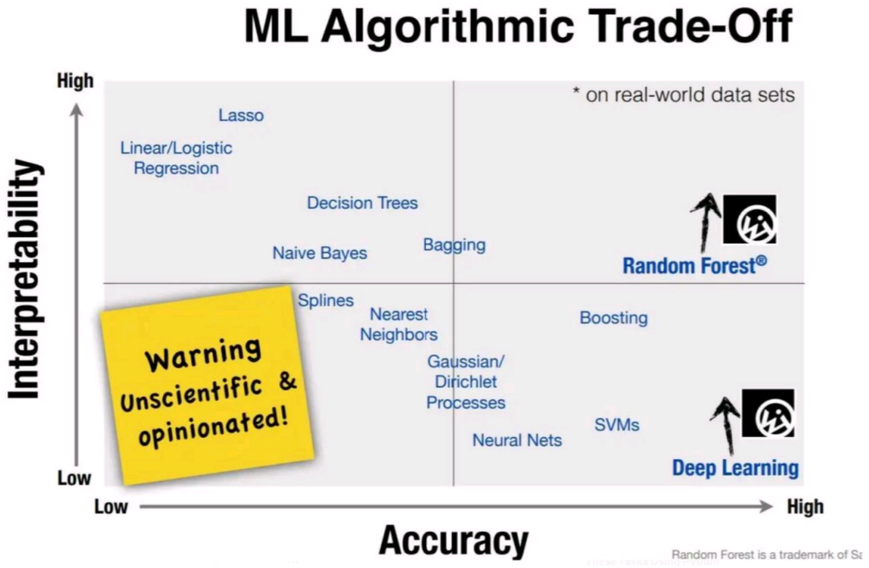

# Tips for choosing Machine Learning model

- Start with a simple model
  - Choose the simplest model first
  - If it is good enough, you even do not need to try another model
- Try different models and shortlist the best ones?
- Do Hyperparameter Tuning for each models?
  - GridSearchCV if the number of combinations is small
  - RandomizedSearchCV if the number of combination is large
- Compare amongst the best models with best hyperparameters to pick up the best one

# Underfitting and Overfitting

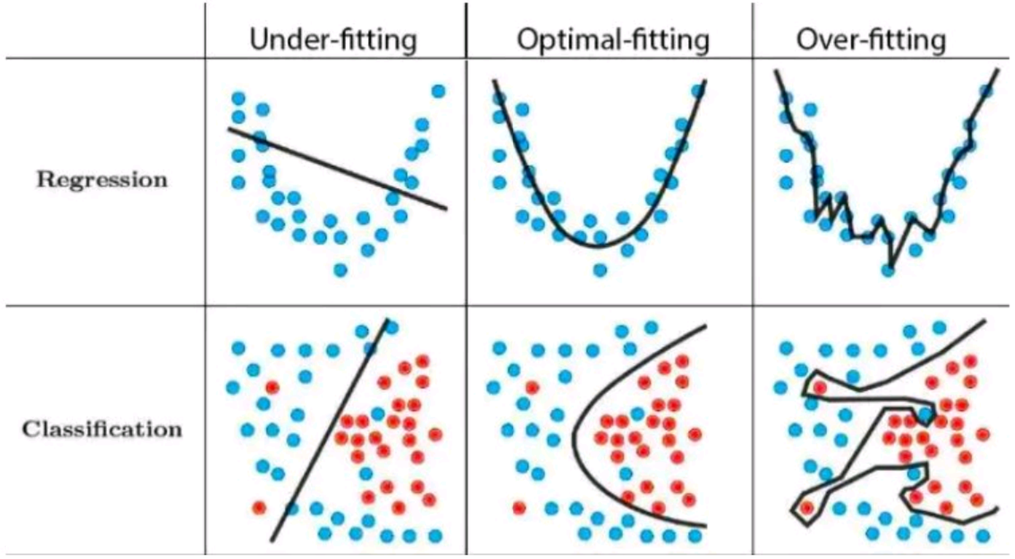

# Regularization

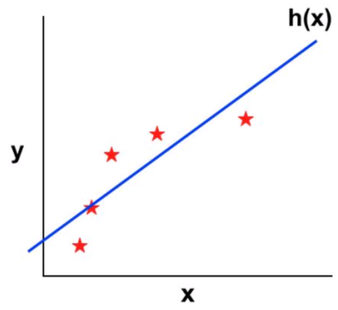


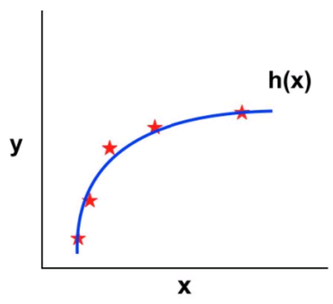


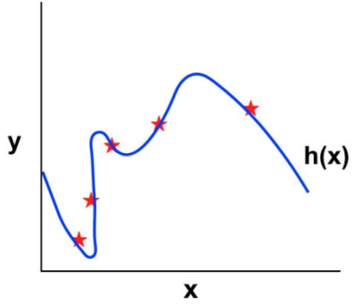


$$L(x,y) = \sum_{i=1}^{n} (y_i - f(x_i))^2$$

$$f(x_i) = h_\theta x = \theta_0 + \theta_1 x_1 + \theta_2 x_2^2 + \theta_3 x_3^3 + \theta_4 x_4^4$$

$$f(x_i) = h_\theta x = \theta_0 + \theta_1 x_1 + \theta_2 x_2^2 + \theta_3 x_3^3 + \theta_4 x_4^4$$

$$f(x_i) = h_\theta x = \theta_0 + \theta_1 x_1 + \theta_2 x_2^2$$

# Regularization

L1 Regularization

$$\text{Cost} = \sum_{i=0}^{N}(y_i - \sum_{j=0}^{M} x_{ij}W_j)^2 + \lambda \sum_{j=0}^{M} |W_j|$$

L2 Regularization

$$\text{Cost} = \sum_{i=0}^{N}(y_i - \sum_{j=0}^{M} x_{ij}W_j)^2 + \lambda \sum_{j=0}^{M} W_j^2$$

Loss function

Regularization Term

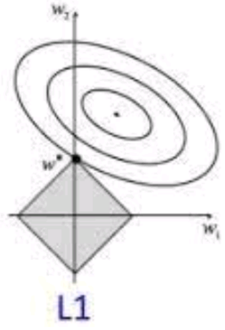

L1

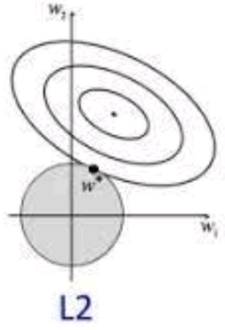

L2

# Regularization

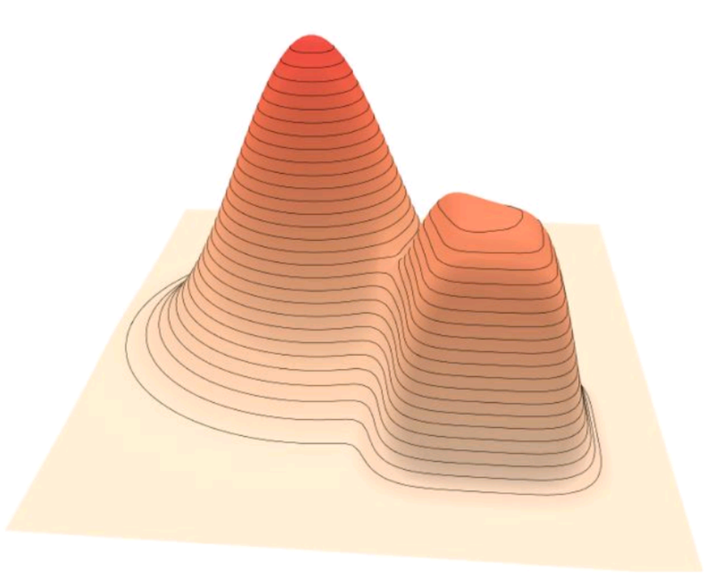

# Regularization

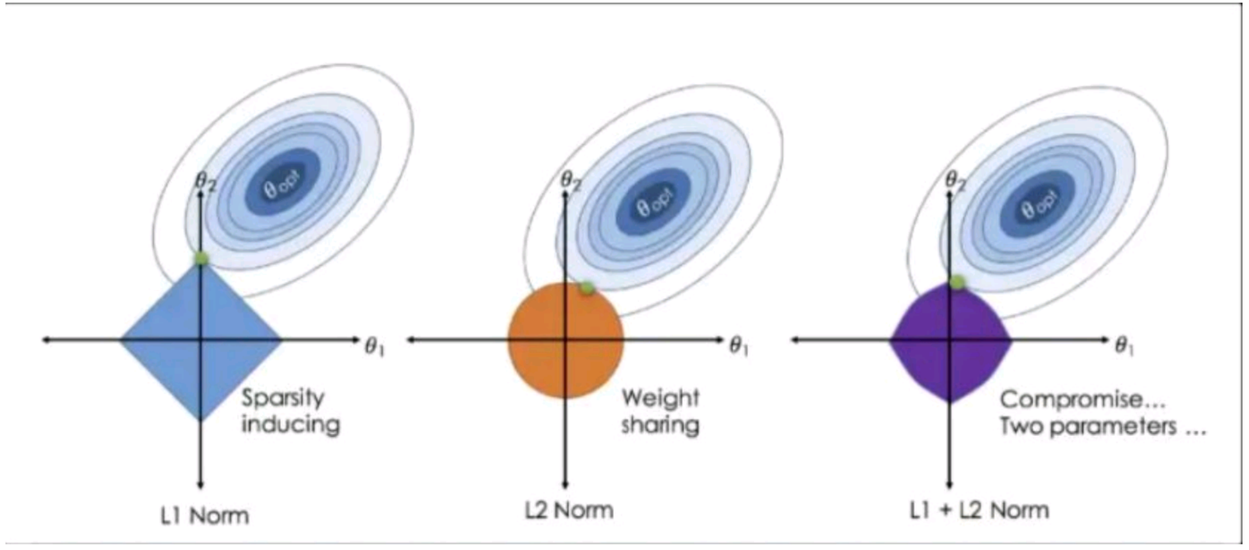

# Regularization Example

```python
import pandas as pd
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline

data = pd.read_csv("diabetes.csv")
x = data.drop("Outcome", axis=1)
y = data["Outcome"]
cls = Pipeline(steps=[
    ('scaler', StandardScaler()),
    ('model', LogisticRegression(penalty="l1", solver="liblinear"))
])
cls.fit(x, y)
for i, j in zip(x.columns, cls["model"].coef_[0]):
    print("{} is with coefficient of {}".format(i, j))
```

```
C:\Users\Viet\anaconda3\envs\basic\python.exe C:\Users\Viet\PycharmPr
Pregnancies is with coefficient of 0.4047757715484604
Glucose is with coefficient of 1.1020534150332097
BloodPressure is with coefficient of -0.23905878835657515
SkinThickness is with coefficient of 0.0
Insulin is with coefficient of -0.12014123606887196
BMI is with coefficient of 0.6883338771775394
DiabetesPedigreeFunction is with coefficient of 0.30157785094254597
Age is with coefficient of 0.16766878675897076
```

```python
import pandas as pd
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline

data = pd.read_csv("diabetes.csv")
x = data.drop("Outcome", axis=1)
y = data["Outcome"]
cls = Pipeline(steps=[
    ('scaler', StandardScaler()),
    ('model', LogisticRegression(penalty="l2", solver="lbfgs"))
])
cls.fit(x, y)
for i, j in zip(x.columns, cls["model"].coef_[0]):
    print("{} is with coefficient of {}".format(i, j))
```

```
C:\Users\Viet\anaconda3\envs\basic\python.exe C:\Users\Viet\PycharmP
Pregnancies is with coefficient of 0.4086468712956544
Glucose is with coefficient of 1.107111971571363
BloodPressure is with coefficient of -0.2508680388517632
SkinThickness is with coefficient of 0.00905045508333392
Insulin is with coefficient of -0.13083627394872085
BMI is with coefficient of 0.6963087173103848
DiabetesPedigreeFunction is with coefficient of 0.3088372414180195
Age is with coefficient of 0.1764978217442397
```

# Dimensionality Reduction

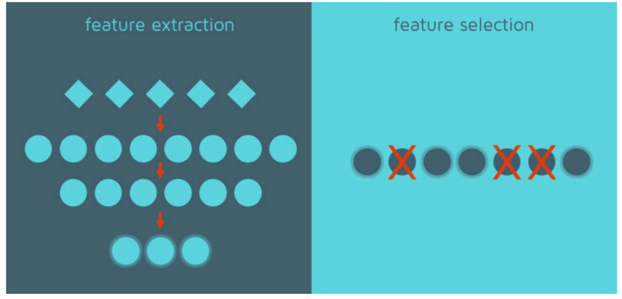


**01** **Feature Selection**

Original features are maintained

**Keep most important features**

**02** **Feature Extraction**

Features are transformed to a new space

# Curse of Dimensionality

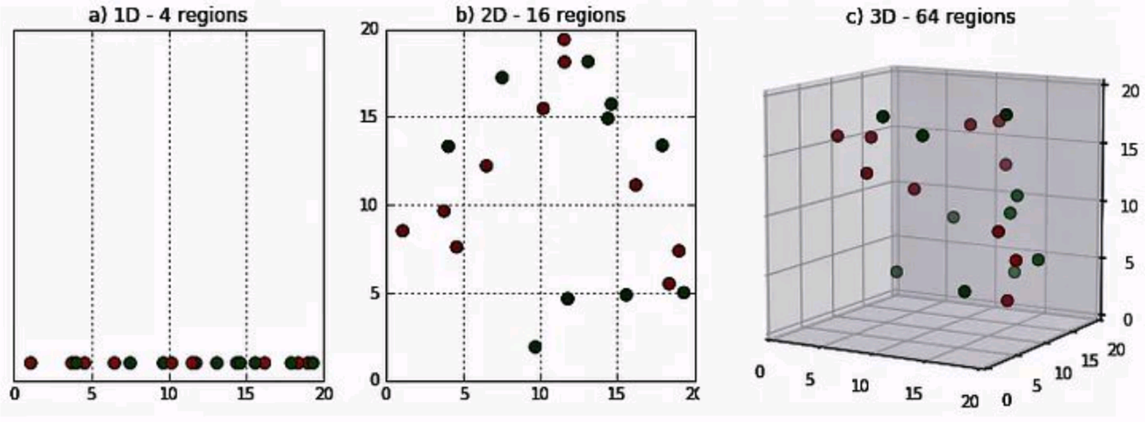

# Feature Selection

# Feature Selection - Correlation Coefficient

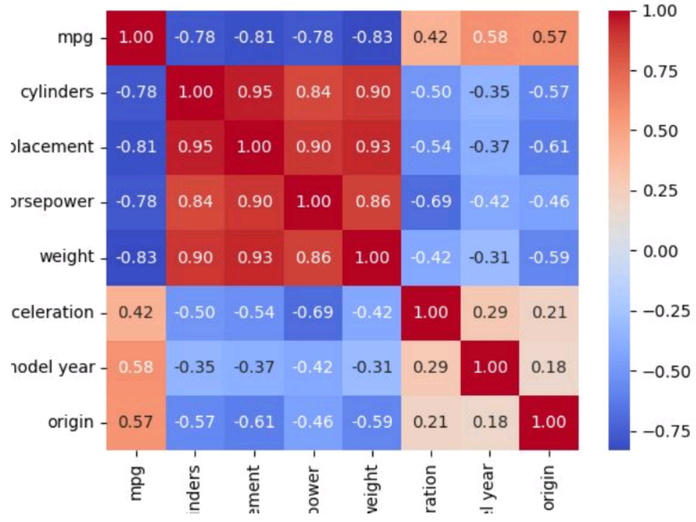

# Feature Selection - Variance Threshold

```python
import pandas as pd
from sklearn.feature_selection import VarianceThreshold

data = pd.read_csv("diabetes.csv", usecols=[i for i in range(8)])
variance_threshold = VarianceThreshold(threshold=1)
variance_threshold.fit(data)
print(variance_threshold.variances_)
print(variance_threshold.get_support())
```

```
fuel_viz
C:\Users\Viet\anaconda3\envs\basic\python.exe C:\Users\Viet\Pycharm
[1.13392724e+01 1.02091726e+03 3.74159449e+02 2.54141900e+02
 1.32638869e+04 6.20790465e+01 1.09635697e-01 1.38122964e+02]
[ True  True  True  True  True  True False  True]
```

# Feature Selection - Lasso (L1)

```python
import pandas as pd
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline

data = pd.read_csv("diabetes.csv")
x = data.drop("Outcome", axis=1)
y = data["Outcome"]
cls = Pipeline(steps=[
    ('scaler', StandardScaler()),
    ('model', LogisticRegression(penalty="l1", solver="liblinear"))
])
cls.fit(x, y)
for i, j in zip(x.columns, cls["model"].coef_[0]):
    print("{} is with coefficient of {}".format(i, j))
```

```
fuel_viz
C:\Users\Viet\anaconda3\envs\basic\python.exe C:\Users\Viet\PycharmPr
Pregnancies is with coefficient of 0.4047757715484604
Glucose is with coefficient of 1.1020534150332097
BloodPressure is with coefficient of -0.23905878835657515
SkinThickness is with coefficient of 0.0
Insulin is with coefficient of -0.12014123606887196
BMI is with coefficient of 0.6883338771775394
DiabetesPedigreeFunction is with coefficient of 0.30157785094254597
Age is with coefficient of 0.16766878675897076
```

```python
import pandas as pd
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline

data = pd.read_csv("diabetes.csv")
x = data.drop("Outcome", axis=1)
y = data["Outcome"]
cls = Pipeline(steps=[
    ('scaler', StandardScaler()),
    ('model', LogisticRegression(penalty="l2", solver="lbfgs"))
])
cls.fit(x, y)
for i, j in zip(x.columns, cls["model"].coef_[0]):
    print("{} is with coefficient of {}".format(i, j))
```

```
fuel_viz
C:\Users\Viet\anaconda3\envs\basic\python.exe C:\Users\Viet\PycharmF
Pregnancies is with coefficient of 0.4086468712956544
Glucose is with coefficient of 1.107111971571363
BloodPressure is with coefficient of -0.2508680388517632
SkinThickness is with coefficient of 0.00905045508333392
Insulin is with coefficient of -0.13083627394872085
BMI is with coefficient of 0.6963087173103848
DiabetesPedigreeFunction is with coefficient of 0.3088372414180195
Age is with coefficient of 0.1764978217442397
```

# Feature Selection - RandomForest

```python
import pandas as pd
from sklearn.ensemble import RandomForestClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline

data = pd.read_csv("diabetes.csv")
x = data.drop("Outcome", axis=1)
y = data["Outcome"]
cls = Pipeline(steps=[
    ('scaler', StandardScaler()),
    ('model', RandomForestClassifier())
])
cls.fit(x, y)
print(cls["model"].feature_importances_)
```

```
fuel_viz
C:\Users\Viet\anaconda3\envs\basic\python.exe C:\Users\Viet\Pycharm
[0.08485069 0.26544363 0.09088871 0.07260613 0.07047188 0.15482689
 0.12826565 0.13264643]
```

# Feature Extraction

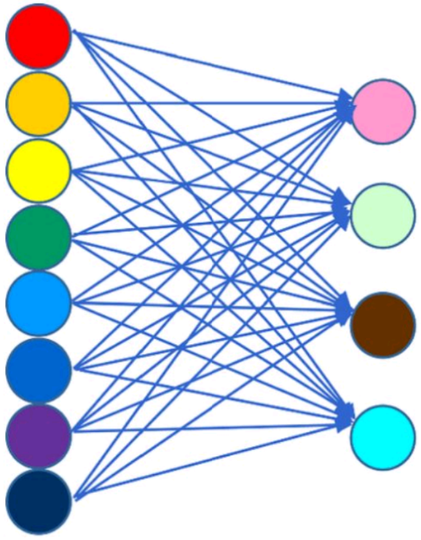

# Feature Extraction - Principle Component Analyst

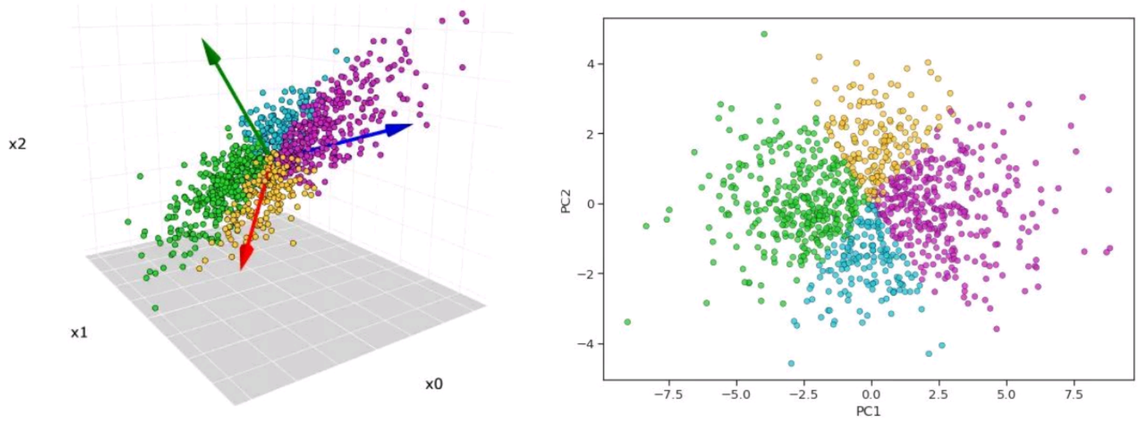

# Variance in data

$$
\begin{aligned}
\operatorname{Var}(X) &= \mathrm{E}\left[(X - \mathrm{E}[X])^2\right] \\
&= \mathrm{E}\left[X^2 - 2X\,\mathrm{E}[X] + \mathrm{E}[X]^2\right] \\
&= \mathrm{E}\left[X^2\right] - 2\,\mathrm{E}[X]\,\mathrm{E}[X] + \mathrm{E}[X]^2 \\
&= \mathrm{E}\left[X^2\right] - \mathrm{E}[X]^2
\end{aligned}
$$

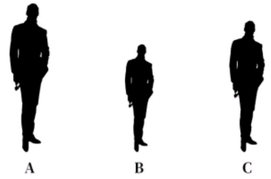


| Person | Height (cm) |
|---|---|
| Alex | 145 |
| Ben | 160 |
| Chris | 185 |

| Person | Height (cm) |
|---|---|
| Daniel | 172 |
| Elsa | 173 |
| Fernandez | 171 |

# Covariance vs Correlation

$$\begin{aligned}\operatorname{Var}(X) &= \mathrm{E}\left[(X - \mathrm{E}[X])^2\right] \\ &= \mathrm{E}\left[X^2 - 2X\,\mathrm{E}[X] + \mathrm{E}[X]^2\right] \\ &= \mathrm{E}\left[X^2\right] - 2\,\mathrm{E}[X]\,\mathrm{E}[X] + \mathrm{E}[X]^2 \\ &= \mathrm{E}\left[X^2\right] - \mathrm{E}[X]^2\end{aligned}$$

$$\begin{aligned}\operatorname{cov}(X,Y) &= \mathrm{E}[(X - \mathrm{E}[X])\,(Y - \mathrm{E}[Y])] \\ &= \mathrm{E}[XY - X\,\mathrm{E}[Y] - \mathrm{E}[X]Y + \mathrm{E}[X]\,\mathrm{E}[Y]] \\ &= \mathrm{E}[XY] - \mathrm{E}[X]\,\mathrm{E}[Y] - \mathrm{E}[X]\,\mathrm{E}[Y] + \mathrm{E}[X]\,\mathrm{E}[Y] \\ &= \mathrm{E}[XY] - \mathrm{E}[X]\,\mathrm{E}[Y],\end{aligned}$$

$$\mathrm{Corr}(X,Y) = \frac{\mathrm{Cov}(X,Y)}{\sigma_x \sigma_y}$$

- $\mathrm{Corr}(X,Y)$: Correlation between X and Y
- $\mathrm{Cov}(X,Y)$: Covarianced normalized by Standard Deviation
- $\sigma_x$: Standard deviation of X
- $\sigma_y$: Standard deviation of Y

**Standard Deviation** $= \sqrt{Variance}$

# Covariance vs Correlation

| Covariance | Correlation |
| --- | --- |
| Indicates the direction of the linear relationship between variables | Indicates both the strength and direction of the linear relationship between two variables |
| Covariance values are not standard | Correlation values are standardized |
| Positive number being positive relationship and negative number being negative relationship | 1 being strong positive correlation, -1 being strong negative correlation |
| Value between positive infinity to negative infinity | Value is strictly between -1 to 1 |

# PCA: step 1 - Standardize the dataset

| f1 | f2 | f3 | f4 |
|---|---|---|---|
| 1 | 2 | 3 | 4 |
| 5 | 5 | 6 | 7 |
| 1 | 4 | 2 | 3 |
| 5 | 3 | 2 | 1 |
| 8 | 1 | 2 | 2 |

$$x_{new} = \frac{x - \mu}{\sigma}$$

| | | f1 | f2 | f3 | f4 |
|---|---|---|---|---|---|
| μ | = | 4 | 3 | 3 | 3.4 |
| σ | = | 3 | 1.58114 | 1.73205 | 2.30217 |

| f1 | f2 | f3 | f4 |
|---|---|---|---|
| -1 | -0.63246 | 0 | 0.26062 |
| 0.33333 | 1.26491 | 1.73205 | 1.56374 |
| -1 | 0.63246 | -0.57735 | -0.17375 |
| 0.33333 | 0 | -0.57735 | -1.04249 |
| 1.33333 | -1.26491 | -0.57735 | -0.60812 |

# PCA: step 2 - Calculate the covariance matrix

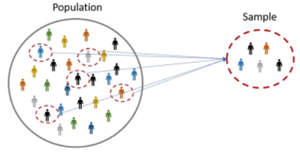


| f1 | f2 | f3 | f4 |
|---|---|---|---|
| -1 | -0.63246 | 0 | 0.26062 |
| 0.33333 | 1.26491 | 1.73205 | 1.56374 |
| -1 | 0.63246 | -0.57735 | -0.17375 |
| 0.33333 | 0 | -0.57735 | -1.04249 |
| 1.33333 | -1.26491 | -0.57735 | -0.60812 |

**For Population**

$$Cov(x,y) = \frac{\Sigma (x_i - \bar{x}) * (y_i - \bar{y})}{N}$$

**For Sample**

$$Cov(x,y) = \frac{\Sigma (x_i - \bar{x}) * (y_i - \bar{y})}{(N-1)}$$

| | f1 | f2 | f3 | f4 |
|---|---|---|---|---|
| f1 | var(f1) | cov(f1,f2) | cov(f1,f3) | cov(f1,f4) |
| f2 | cov(f2,f1) | var(f2) | cov(f2,f3) | cov(f2,f4) |
| f3 | cov(f3,f1) | cov(f3,f2) | var(f3) | cov(f3,f4) |
| f4 | cov(f4,f1) | cov(f4,f2) | cov(f4,f3) | var(f4) |

| | f1 | f2 | f3 | f4 |
|---|---|---|---|---|
| f1 | 0.8 | -0.25298 | 0.03849 | -0.14479 |
| f2 | -0.25298 | 0.8 | 0.51121 | 0.4945 |
| f3 | 0.03849 | 0.51121 | 0.8 | 0.75236 |
| f4 | -0.14479 | 0.4945 | 0.75236 | 0.8 |

# PCA: step 3 - Calculate eigenvector and eigenvalue

⚠ **Definition.** Let $A$ be an $n \times n$ matrix.

1. An ***eigenvector*** of $A$ is a *nonzero* vector $v$ in $\mathrm{R}^n$ such that $Av = \lambda v$, for some scalar $\lambda$.
2. An ***eigenvalue*** of $A$ is a scalar $\lambda$ such that the equation $Av = \lambda v$ has a *nontrivial* solution.

If $Av = \lambda v$ for $v \neq 0$, we say that $\lambda$ is the ***eigenvalue for*** $v$, and that $v$ is an ***eigenvector for*** $\lambda$.

$$A = \begin{bmatrix} 1 & 4 \\ 3 & 2 \end{bmatrix}$$

$$\det \begin{bmatrix} a & b \\ c & d \end{bmatrix} = ad - bc$$

$$\det(A - \lambda I) = 0$$

$$\det\left(\begin{bmatrix} 1 & 4 \\ 3 & 2 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}\right) = 0$$

$$\det\left(\begin{bmatrix} 1-\lambda & 4 \\ 3 & 2-\lambda \end{bmatrix}\right) = 0$$

$$(1-\lambda)(2-\lambda) - 12 = 0$$

$$\lambda^2 - 3\lambda - 10 = 0$$

$$(\lambda - 5)(\lambda + 2) = 0$$

$$\lambda = 5, -2$$

# PCA: step 3 - Calculate eigenvector and eigenvalue

| | f1 | f2 | f3 | f4 |
|---|---|---|---|---|
| f1 | 0.8 | -0.25298 | 0.03849 | -0.14479 |
| f2 | -0.25298 | 0.8 | 0.51121 | 0.4945 |
| f3 | 0.03849 | 0.51121 | 0.8 | 0.75236 |
| f4 | -0.14479 | 0.4945 | 0.75236 | 0.8 |

→

| | f1 | f2 | f3 | f4 |
|---|---|---|---|---|
| f1 | 0.8 - λ | -0.25298 | 0.03849 | -0.14479 |
| f2 | -0.25298 | 0.8- λ | 0.51121 | 0.4945 |
| f3 | 0.03849 | 0.51121 | 0.8 - λ | 0.75236 |
| f4 | -0.14479 | 0.4945 | 0.75236 | 0.8 - λ |

↓

| λ | 0.393 | 1.065 | 2.515 | 0.025 |
|---|---|---|---|---|

↓

| | | | | |
|---|---|---|---|---|
| v | -0.307 | -0.917 | 0.161 | 0.196 |
| | -0.817 | 0.206 | -0.524 | 0.120 |
| | 0.188 | -0.320 | -0.585 | -0.720 |
| | 0.449 | -0.115 | -0.596 | 0.654 |

# PCA: step 4 - Sort eigenvalues & corresponding eigenvectors

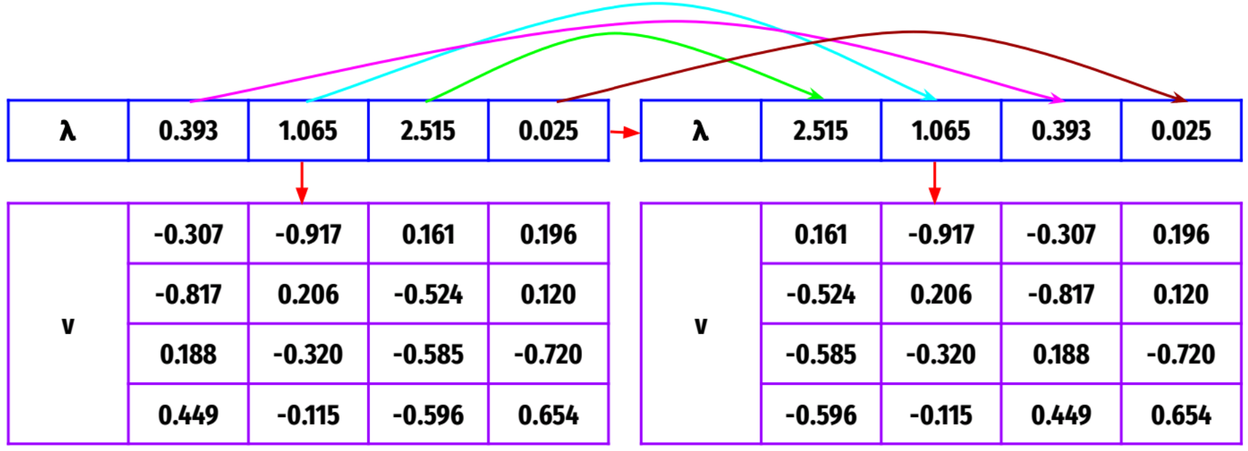

# PCA: step 5 - Pick k eigenvalues and form a matrix

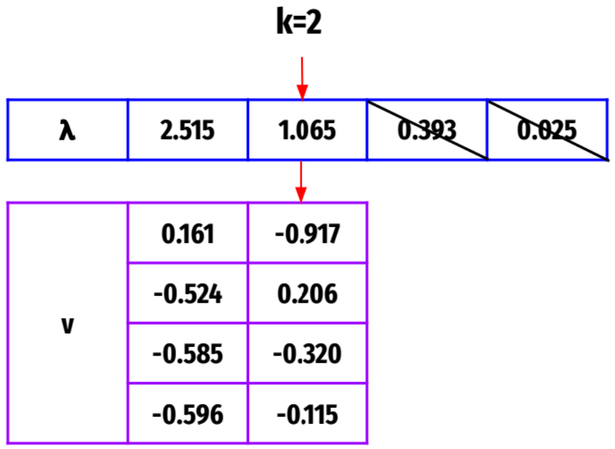

# PCA: step 6 - Transform feature matrix

Nx4 matrix x

| | |
|---|---|
| 0.161 | -0.917 |
| -0.524 | 0.206 |
| -0.585 | -0.320 |
| -0.596 | -0.115 |

= Nx2 matrix

# PCA visualization

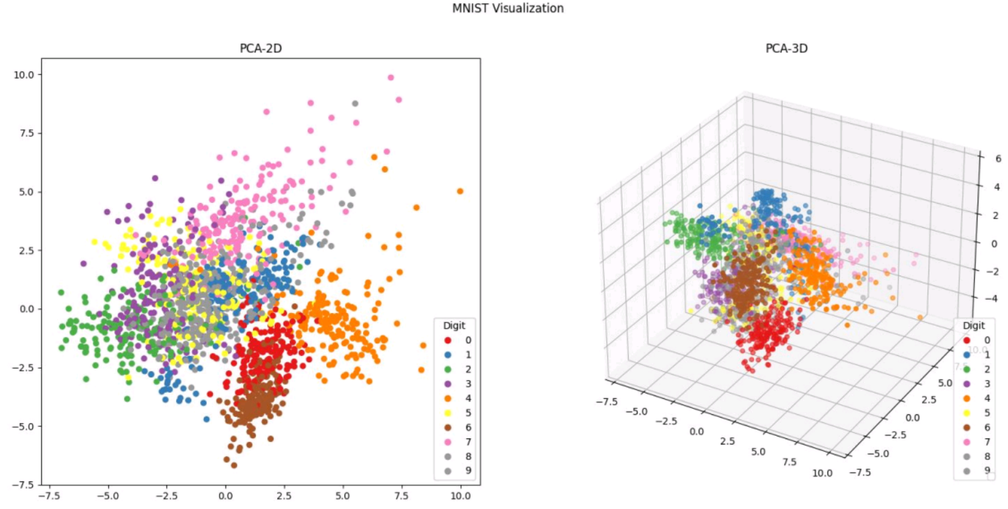

# Recommendation systems

# What is recommendation systems

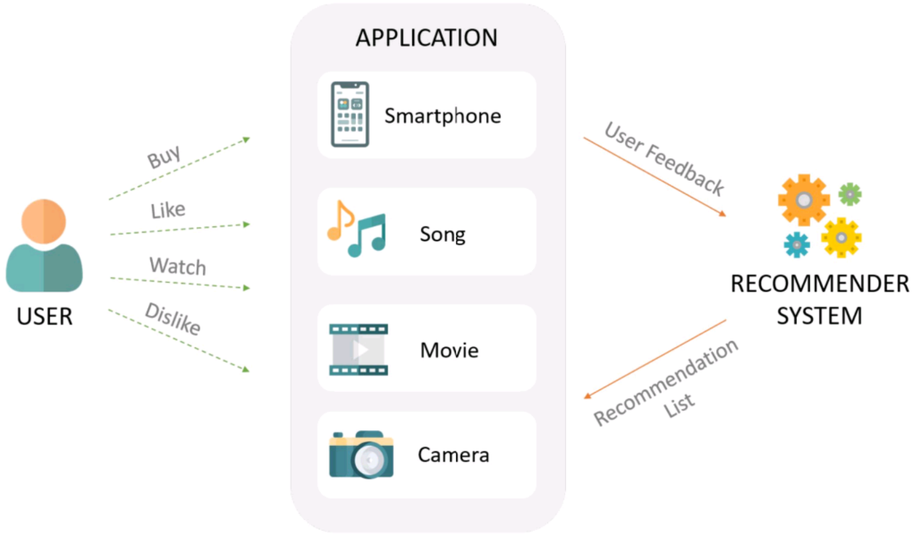

# Types of recommendation systems

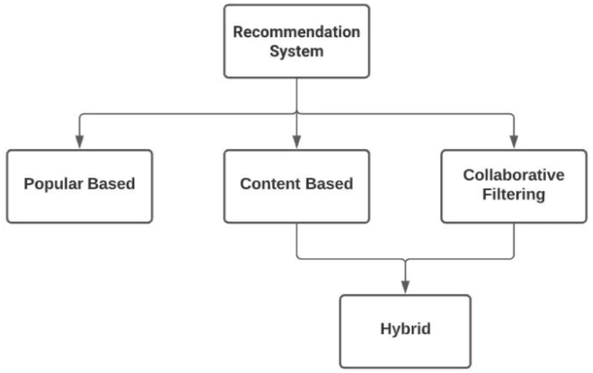


Collaborative Filtering

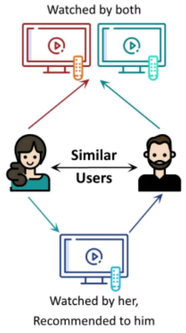


Content-Based Filtering

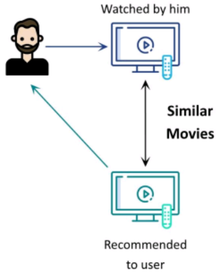

# Popularity-based recommendation systems

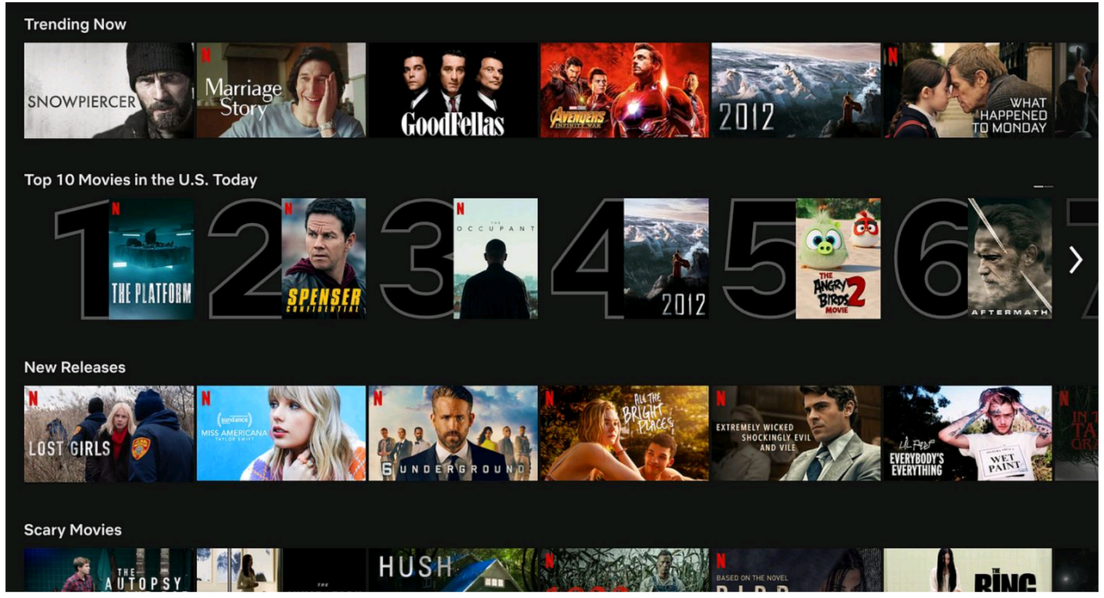

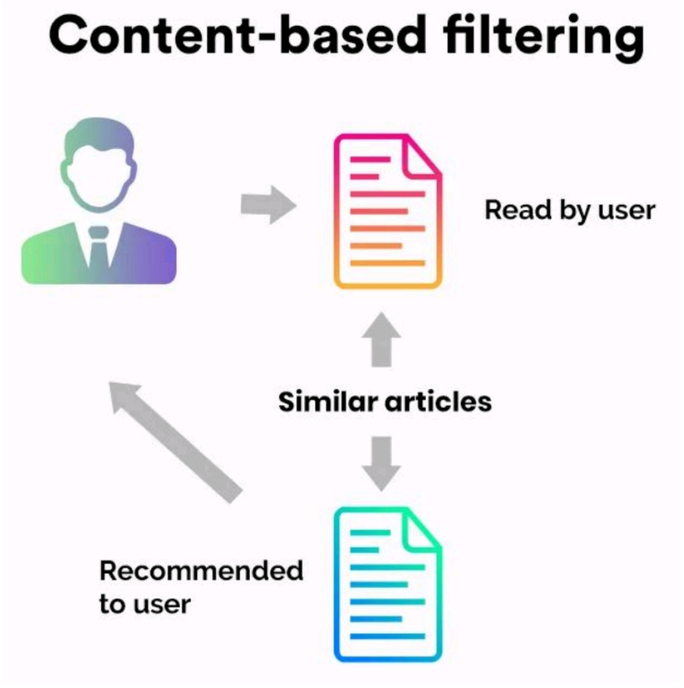
Content-based filtering
Read by user
Similar articles
Recommended
to user

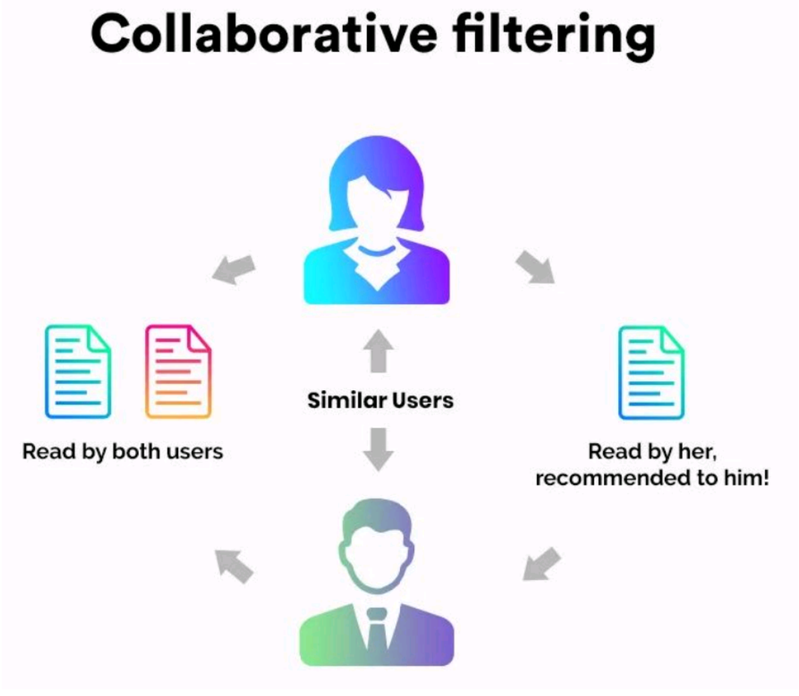
Collaborative filtering
Similar Users
Read by both users
Read by her,
recommended to him!

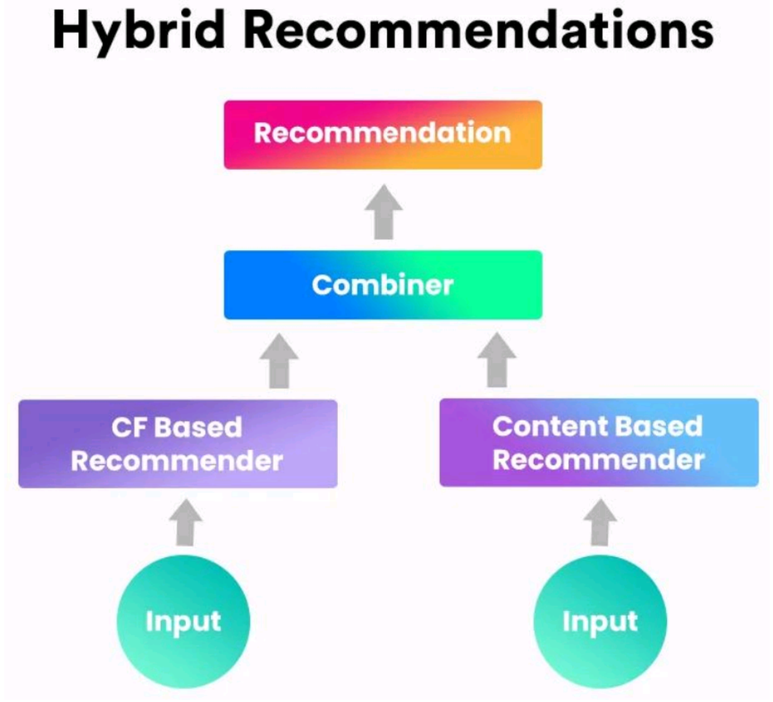
Hybrid Recommendations
Recommendation
Combiner
CF Based Recommender
Content Based Recommender
Input
Input

## Utility matrix

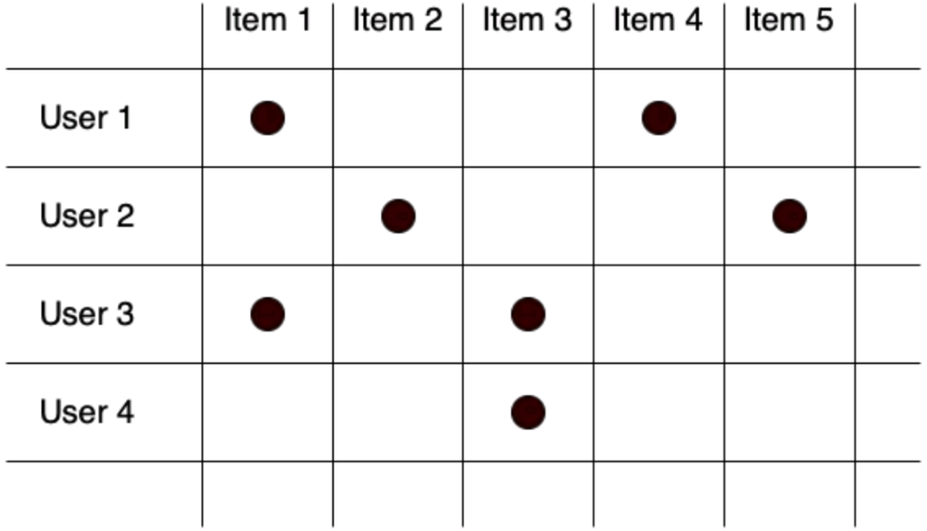

# Kiểm định giả thuyết

# Phân phối chuẩn (Normal/Gaussian distribution)

expectation

variance

$$X \sim \mathcal{N}(\mu, \sigma^2) \qquad f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

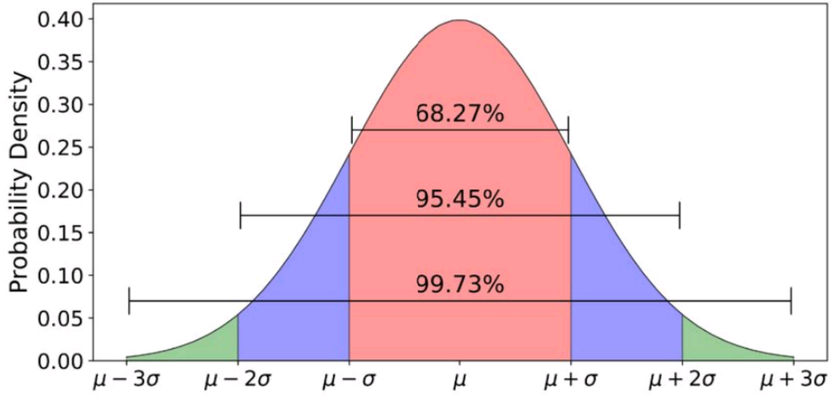

# Quy tắc 3σ

***Nếu biến ngẫu nhiên X có phân phối chuẩn thì hầu như chắc chắn rằng X có giá trị nằm trong khoảng (μ-3σ,μ+3σ)***

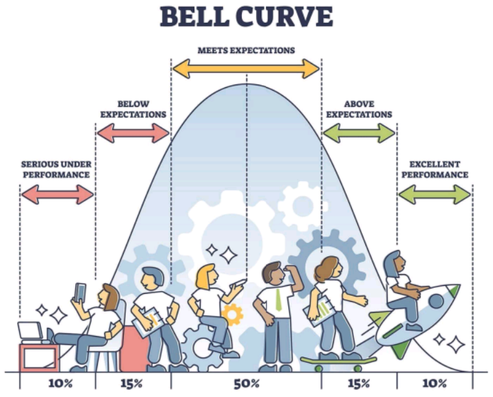

# Phân phối chuẩn (Normal/Gaussian distribution)

$$P(a \le X \le b) = \frac{1}{\sigma\sqrt{2\pi}} \int_a^b e^{\frac{(x-\mu)^2}{2\sigma^2}} dx = P\left(\frac{a-\mu}{\sigma} \le Y \le \frac{b-\mu}{\sigma}\right) = \phi_0\left(\frac{b-\mu}{\sigma}\right) - \phi_0\left(\frac{a-\mu}{\sigma}\right)$$

## *Bảng giá trị hàm Laplace*

| | 0.00 | 0.01 | 0.02 | 0.03 | 0.04 | 0.05 | 0.06 | 0.07 | 0.08 | 0.09 |
|---|---|---|---|---|---|---|---|---|---|---|
| 0.0 | 0.5000 | 0.5040 | 0.5080 | 0.5120 | 0.5160 | 0.5199 | 0.5239 | 0.5279 | 0.5319 | 0.5359 |
| 0.1 | 0.5398 | 0.5438 | 0.5478 | 0.5517 | 0.5557 | 0.5596 | 0.5636 | 0.5675 | 0.5714 | 0.5753 |
| 0.2 | 0.5793 | 0.5832 | 0.5871 | 0.5910 | 0.5948 | 0.5987 | 0.6026 | 0.6064 | 0.6103 | 0.6141 |
| 0.3 | 0.6179 | 0.6217 | 0.6255 | 0.6293 | 0.6331 | 0.6368 | 0.6406 | 0.6443 | 0.6480 | 0.6517 |
| 0.4 | 0.6554 | 0.6591 | 0.6628 | 0.6664 | 0.6700 | 0.6736 | 0.6772 | 0.6808 | 0.6844 | 0.6879 |
| 0.5 | 0.6915 | 0.6950 | 0.6985 | 0.7019 | 0.7054 | 0.7088 | 0.7123 | 0.7157 | 0.7190 | 0.7224 |
| 0.6 | 0.7257 | 0.7291 | 0.7324 | 0.7357 | 0.7389 | 0.7422 | 0.7454 | 0.7486 | 0.7517 | 0.7549 |
| 0.7 | 0.7580 | 0.7611 | 0.7642 | 0.7673 | 0.7704 | 0.7734 | 0.7764 | 0.7794 | 0.7823 | 0.7852 |
| 0.8 | 0.7881 | 0.7910 | 0.7939 | 0.7967 | 0.7995 | 0.8023 | 0.8051 | 0.8078 | 0.8106 | 0.8133 |
| 0.9 | 0.8159 | 0.8186 | 0.8212 | 0.8238 | 0.8264 | 0.8289 | 0.8315 | 0.8340 | 0.8365 | 0.8389 |
| 1.0 | 0.8413 | 0.8438 | 0.8461 | 0.8485 | 0.8508 | 0.8531 | 0.8554 | 0.8577 | 0.8599 | 0.8621 |
| 1.1 | 0.8643 | 0.8665 | 0.8686 | 0.8708 | 0.8729 | 0.8749 | 0.8770 | 0.8790 | 0.8810 | 0.8830 |
| 1.2 | 0.8849 | 0.8869 | 0.8888 | 0.8907 | 0.8925 | 0.8944 | 0.8962 | 0.8980 | 0.8997 | 0.9015 |
| 1.3 | 0.9032 | 0.9049 | 0.9066 | 0.9082 | 0.9099 | 0.9115 | 0.9131 | 0.9147 | 0.9162 | 0.9177 |
| 1.4 | 0.9192 | 0.9207 | 0.9222 | 0.9236 | 0.9251 | 0.9265 | 0.9279 | 0.9292 | 0.9306 | 0.9319 |
| 1.5 | 0.9332 | 0.9345 | 0.9357 | 0.9370 | 0.9382 | 0.9394 | 0.9406 | 0.9418 | 0.9429 | 0.9441 |
| 1.6 | 0.9452 | 0.9463 | 0.9474 | 0.9484 | 0.9495 | 0.9505 | 0.9515 | 0.9525 | 0.9535 | 0.9545 |
| 1.7 | 0.9554 | 0.9564 | 0.9573 | 0.9582 | 0.9591 | 0.9599 | 0.9608 | 0.9616 | 0.9625 | 0.9633 |
| 1.8 | 0.9641 | 0.9649 | 0.9656 | 0.9664 | 0.9671 | 0.9678 | 0.9686 | 0.9693 | 0.9699 | 0.9706 |
| 1.9 | 0.9713 | 0.9719 | 0.9726 | 0.9732 | 0.9738 | 0.9744 | 0.9750 | 0.9756 | 0.9761 | 0.9767 |
| 2.0 | 0.9772 | 0.9778 | 0.9783 | 0.9788 | 0.9793 | 0.9798 | 0.9803 | 0.9808 | 0.9812 | 0.9817 |
| 2.1 | 0.9821 | 0.9826 | 0.9830 | 0.9834 | 0.9838 | 0.9842 | 0.9846 | 0.9850 | 0.9854 | 0.9857 |
| 2.2 | 0.9861 | 0.9864 | 0.9868 | 0.9871 | 0.9875 | 0.9878 | 0.9881 | 0.9884 | 0.9887 | 0.9890 |
| 2.3 | 0.9893 | 0.9896 | 0.9898 | 0.9901 | 0.9904 | 0.9906 | 0.9909 | 0.9911 | 0.9913 | 0.9916 |
| 2.4 | 0.9918 | 0.9920 | 0.9922 | 0.9925 | 0.9927 | 0.9929 | 0.9931 | 0.9932 | 0.9934 | 0.9936 |
| 2.5 | 0.9938 | 0.9940 | 0.9941 | 0.9943 | 0.9945 | 0.9946 | 0.9948 | 0.9949 | 0.9951 | 0.9952 |
| 2.6 | 0.9953 | 0.9955 | 0.9956 | 0.9957 | 0.9959 | 0.9960 | 0.9961 | 0.9962 | 0.9963 | 0.9964 |
| 2.7 | 0.9965 | 0.9966 | 0.9967 | 0.9968 | 0.9969 | 0.9970 | 0.9971 | 0.9972 | 0.9973 | 0.9974 |
| 2.8 | 0.9974 | 0.9975 | 0.9976 | 0.9977 | 0.9977 | 0.9978 | 0.9979 | 0.9979 | 0.9980 | 0.9981 |
| 2.9 | 0.9981 | 0.9982 | 0.9982 | 0.9983 | 0.9984 | 0.9984 | 0.9985 | 0.9985 | 0.9986 | 0.9986 |
| 3.0 | 0.9987 | 0.9987 | 0.9987 | 0.9988 | 0.9988 | 0.9989 | 0.9989 | 0.9989 | 0.9990 | 0.9990 |

# Định lý giới hạn trung tâm (Central Limit theorem)

***Nếu chọn 1 tập mẫu có kích thước n đủ lớn (n ≥ 30) thì giá trị trung bình của tập mẫu này sẽ xấp xỉ giá trị trung bình của tập tổng thể. Ngoài ra phân phối của giá trị trung bình của tập mẫu sẽ tiệm cận phân phối chuẩn, bất kể phân phối của tập tổng thể là gì***

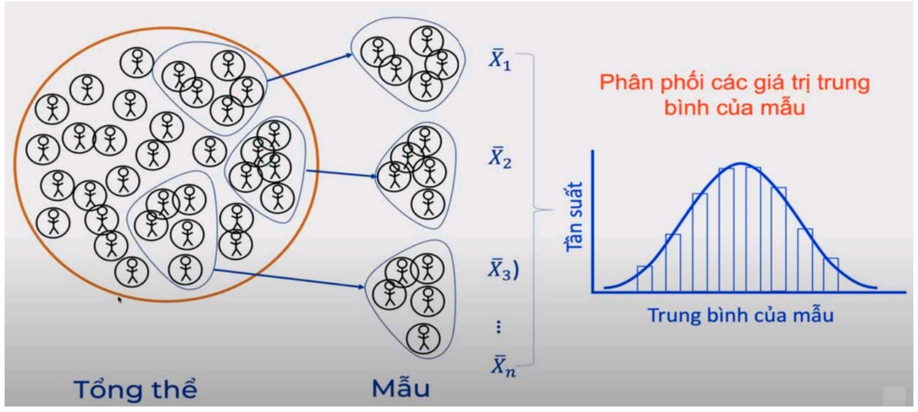

# Định lý giới hạn trung tâm (Central Limit theorem)

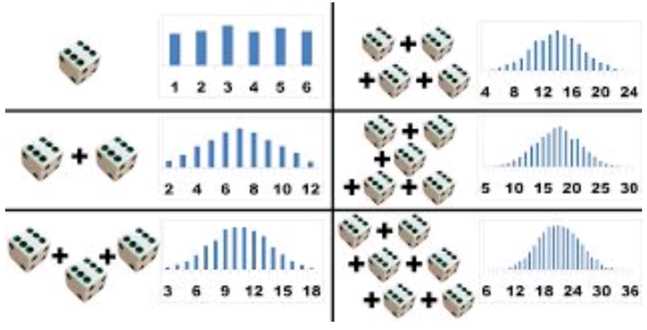


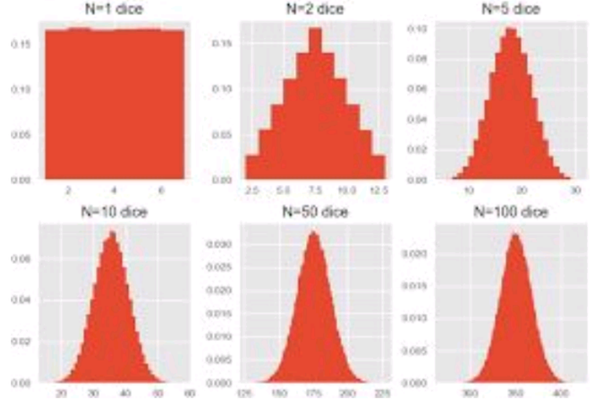

# Định lý giới hạn trung tâm (Central Limit theorem)

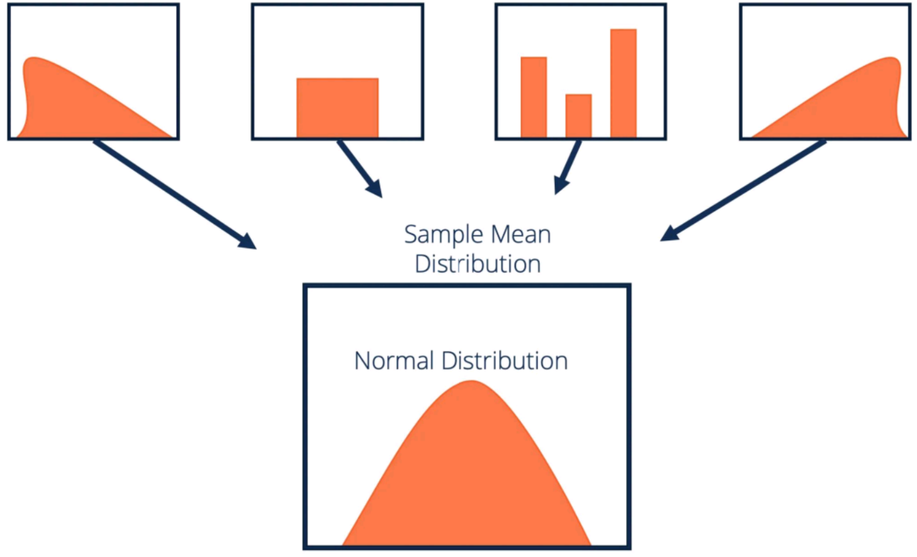

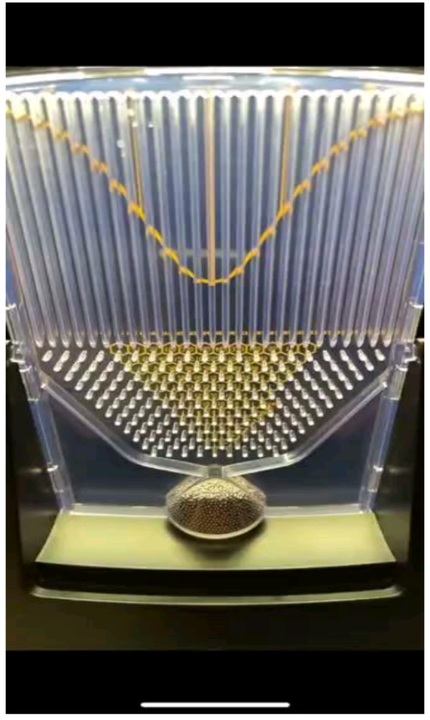

# Tổng quát

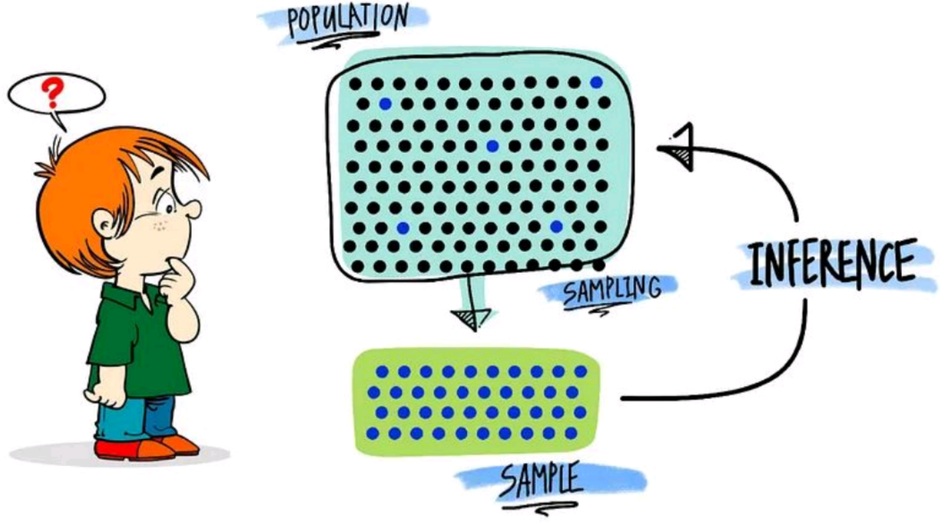

# Các khái niệm

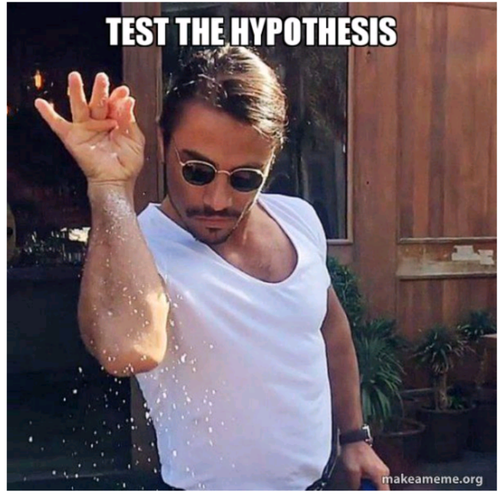


**Hypothesis (Giả thuyết):** 1 mệnh đề được đưa ra, đang cần phải kiểm định tính đúng/sai

**Statistical hypothesis (Giả thuyết thống kê):** Là giả thuyết về 1 biến ngẫu nhiên. Có 2 loại chính:

- **Tham số:** Giả thuyết về tham số của biến ngẫu nhiên (Kỳ vọng, phương sai, xác suất ...)
- **Phi tham số:** Giả thuyết về phân phối hoặc tính chất của biến ngẫu nhiên

**Hypothesis testing (Kiểm định giả thuyết):** Kiểm định tính đúng hay sai của 1 giả thuyết nào đó

# Giả thuyết thống kê

**$H_0$: Giả thuyết gốc/cơ bản/không**

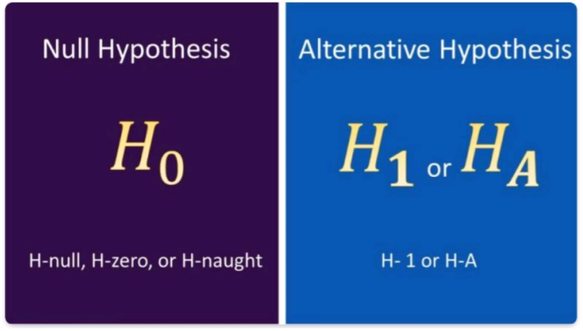


$H_0$ : $\theta = \theta_0$ (Tuổi trung bình người VN = 65)
$H_1/H_A$: $\theta \neq \theta_0$ (Tuổi trung bình người VN ≠ 65)

$H_0$ : $\theta = \theta_0 (\theta \leq \theta_0)$ (Tuổi trung bình người VN =/≤ 65)
$H_1/H_A$: $\theta > \theta_0$ (Tuổi trung bình người VN > 65)

$H_0$ : $\theta = \theta_0 (\theta \geq \theta_0)$ (Tuổi trung bình người VN =/≥ 65)
$H_1/H_A$: $\theta < \theta_0$ (Tuổi trung bình người VN < 65)

**$H_1/H_A$: Giả thuyết đối/đối thuyết**

# Ví dụ

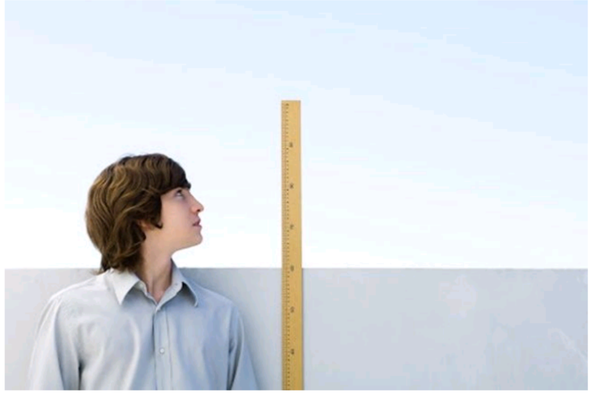

Theo nghiên cứu thì chiều cao trung bình của người Anh là 1m75. Đo ngẫu nhiên 50 người Anh bất kì thì thấy chiều cao trung bình của họ là 1m72. Liệu có thể cho rằng nghiên cứu bị sai hay không?

$\theta$: Chiều cao trung bình của người Anh (cm)

$H_0$ : $\theta = 175$

$H_1/H_A$: $\theta \neq 175$

# Ví dụ

**Theo thống kê nội bộ của 1 công ty thì lương trung bình của nhân viên là 10 triệu/tháng. Hỏi ngẫu nhiên 20 nhân viên của công ty thì lương trung bình của họ chỉ là 9.5 triệu/tháng mà thôi. Liệu có thể kết luận công ty không minh bạch trong trả lương hay không?**

$\theta$: Lương trung bình của nhân viên (triệu/tháng)

$H_0$ : $\theta = 10$

$H_1/H_A$: $\theta < 10$

# Các quyết định và sai lầm - Part 1

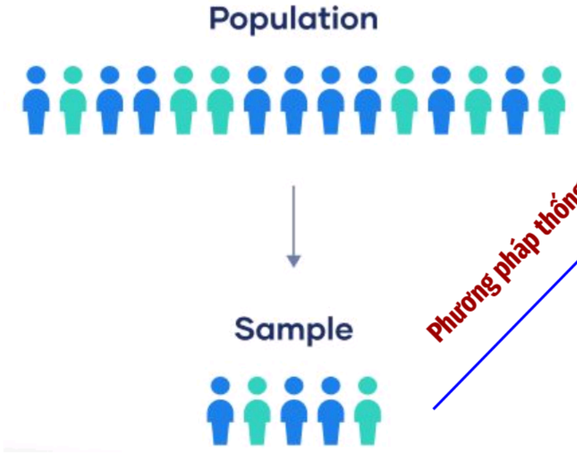


Phương pháp thống kê

**Đưa ra kết luận:**

- **Bác bỏ $H_0$**
- **Không đủ cơ sở để bác bỏ $H_0$**

# Vì sao ???

**Vì sao không nói là chấp nhận $H_0$ mà lại nói Không đủ cơ sở để bác bỏ $H_0$ ?**

*Australian Tree Lobsters*

$\theta$: Số lượng cá thể tôm hùm cây Úc còn tồn tại

$H_0$ : $\theta = 0$ Tôm hùm cây Úc đã tuyệt chủng

$H_1/H_A$: $\theta \neq 0$ Tôm hùm cây Úc chưa tuyệt chủng

$\theta$: Bị cáo

$H_0$ : Bị cáo vô tội

$H_1/H_A$: Bị cáo có tội

# Nguyên lý xác suất nhỏ (The principle of small probability)

***Nếu một biến ngẫu nhiên có xác suất rất nhỏ thì thực tế có thể cho rằng trong một phép thử biến đó sẽ không xảy ra.***

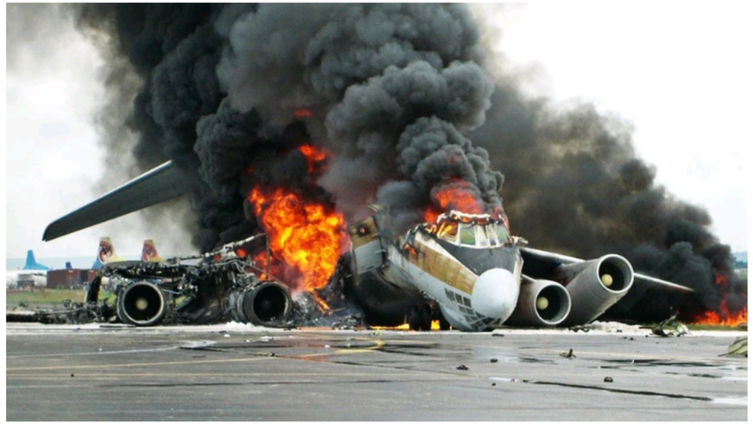

# Phương pháp phản chứng

***Để chứng minh 1 mệnh đề A là đúng: Giả sử A không đúng, từ đó suy ra 1 điều vô lý/mâu thuẫn với thực tế***

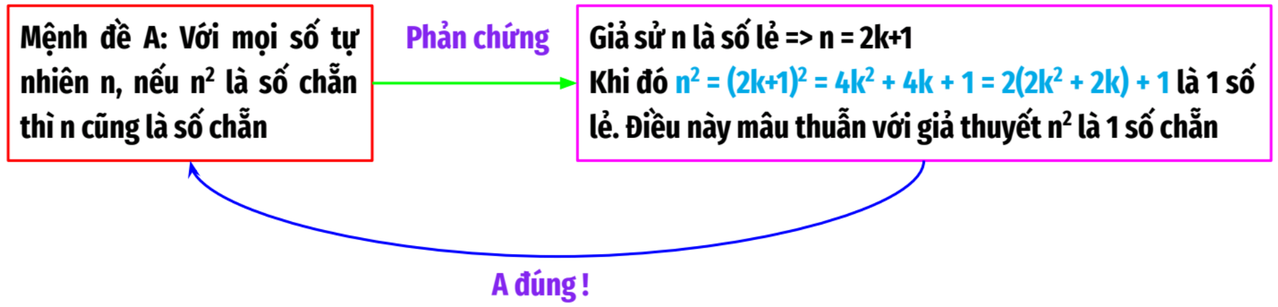

# Các quyết định và sai lầm - Part 2

| Thực tế / Quyết định | $H_0$ đúng | $H_0$ sai |
|---|---|---|
| Bác bỏ $H_0$ | Sai lầm loại I<br>Xác suất bằng $\alpha$ | Quyết định đúng<br>Xác suất bằng $1-\beta$ |
| Không bác bỏ $H_0$ | Quyết định đúng<br>Xác suất bằng $1-\alpha$ | Sai lầm loại II<br>Xác suất bằng $\beta$ |

***α*** **: Mức ý nghĩa**

**1 - β : Lực lượng kiểm định**

# Các bước tiến hành kiểm định giả thuyết

## Bước 1: Thành lập cặp giả thuyết $H_0$ và $H_1$

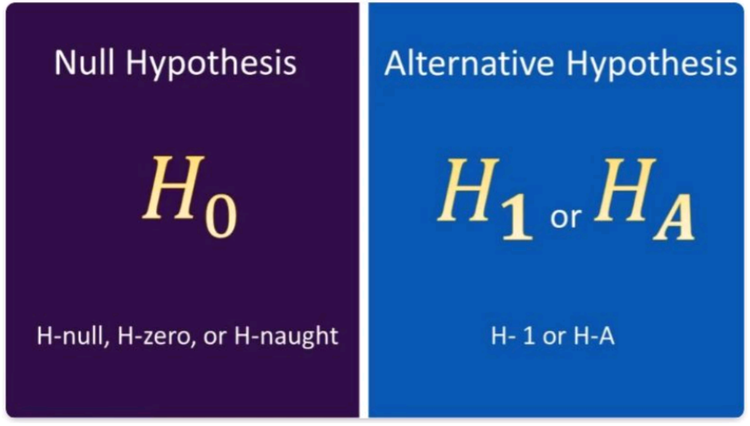

# Bước 2: Chọn 1 thống kê Z có liên quan đến biến X

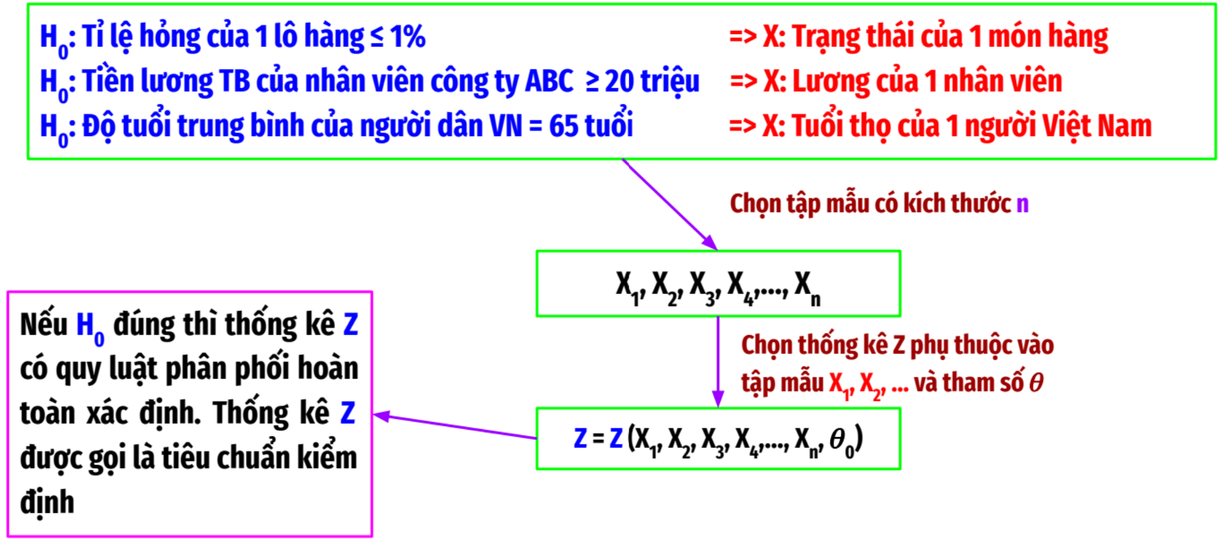

# Bước 2: Ví dụ về chọn thống kê Z về giá trị trung bình

$X \sim (\mu, \sigma^2)$, đã biết phương sai $\sigma^2$ và ta muốn kiểm định kỳ vọng $\mu$

Chọn tập mẫu có kích thước n

$X_1, X_2, X_3, X_4, \ldots, X_n$

Chọn thống kê Z phụ thuộc vào tập mẫu $X_1, X_2, \ldots$ và tham số $\theta$

$$Z = \frac{\left(\overline{X} - \mu_0\right)\sqrt{n}}{\sigma}$$

Nếu $H_0$ đúng thì $Z \sim \mathcal{N}(0,1)$

Chú ý: 1 trong 2 điều kiện sau phải được thỏa mãn:

- X có phân phối chuẩn
- n > 30

Ngoài ra: $X_1, X_2, \ldots$ độc lập với nhau

# Bước 3: Xác định miền bác bỏ (rejection area) giả thuyết $H_0$

**Hàm mật độ xác suất (pdf) của Z**

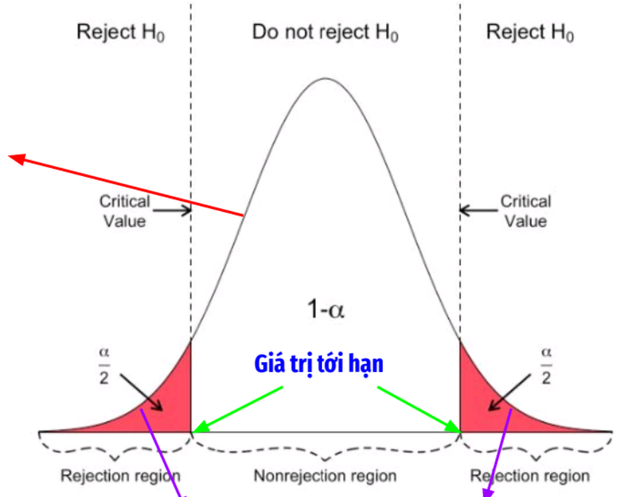


**Miền bác bỏ $W_\alpha$ với mức ý nghĩa $\alpha$**

# Bước 3: Xác định miền bác bỏ (rejection area) giả thuyết $H_0$

| One-Tailed Test (Left Tail) | Two-Tailed Test | One-Tailed Test (Right Tail) |
|---|---|---|
| $H_0 : \mu_X = \mu_0$<br>$H_1 : \mu_X < \mu_0$ | $H_0 : \mu_X = \mu_0$<br>$H_1 : \mu_X \neq \mu_0$ | $H_0 : \mu_X = \mu_0$<br>$H_1 : \mu_X > \mu_0$ |
| | | |

$$P(Z \in W_\alpha | H_0) = \alpha$$

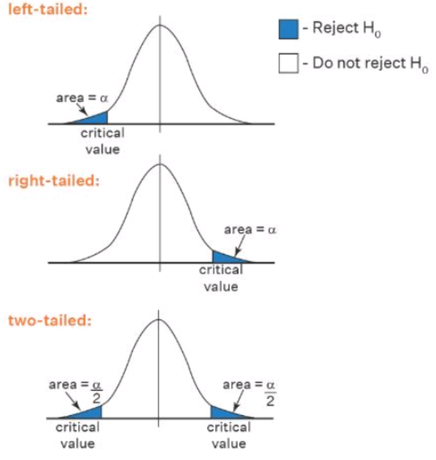


Giá trị tới hạn (critical value) mức $\alpha$ và $\alpha/2$ có thể được kí hiệu là $Z_\alpha$ hay $Z_{\alpha/2}$

# Bước 3: Xác định miền bác bỏ (rejection area) giả thuyết $H_0$

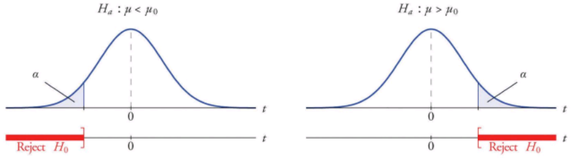


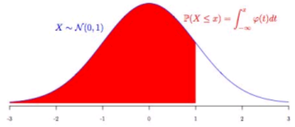


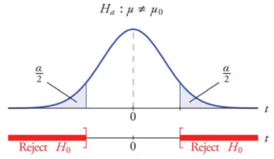


**Xác định 1 - $\alpha$/2 (kiểm định 2 phía)**
**hoặc 1 - $\alpha$ (kiểm định 1 phía).**
**Ví dụ: kiểm định 2 phía với $\alpha$ = 0.05**
**=> 1 - $\alpha$/2 = 0.975**

| | 0.00 | 0.01 | 0.02 | 0.03 | 0.04 | 0.05 | 0.06 | 0.07 | 0.08 | 0.09 |
|---|---|---|---|---|---|---|---|---|---|---|
| 0.0 | 0.5000 | 0.5040 | 0.5080 | 0.5120 | 0.5160 | 0.5199 | 0.5239 | 0.5279 | 0.5319 | 0.5359 |
| 0.1 | 0.5398 | 0.5438 | 0.5478 | 0.5517 | 0.5557 | 0.5596 | 0.5636 | 0.5675 | 0.5714 | 0.5753 |
| 0.2 | 0.5793 | 0.5832 | 0.5871 | 0.5910 | 0.5948 | 0.5987 | 0.6026 | 0.6064 | 0.6103 | 0.6141 |
| 0.3 | 0.6179 | 0.6217 | 0.6255 | 0.6293 | 0.6331 | 0.6368 | 0.6406 | 0.6443 | 0.6480 | 0.6517 |
| 0.4 | 0.6554 | 0.6591 | 0.6628 | 0.6664 | 0.6700 | 0.6736 | 0.6772 | 0.6808 | 0.6844 | 0.6879 |
| 0.5 | 0.6915 | 0.6950 | 0.6985 | 0.7019 | 0.7054 | 0.7088 | 0.7123 | 0.7157 | 0.7190 | 0.7224 |
| 0.6 | 0.7257 | 0.7291 | 0.7324 | 0.7357 | 0.7389 | 0.7422 | 0.7454 | 0.7486 | 0.7517 | 0.7549 |
| 0.7 | 0.7580 | 0.7611 | 0.7642 | 0.7673 | 0.7704 | 0.7734 | 0.7764 | 0.7794 | 0.7823 | 0.7852 |
| 0.8 | 0.7881 | 0.7910 | 0.7939 | 0.7967 | 0.7995 | 0.8023 | 0.8051 | 0.8078 | 0.8106 | 0.8133 |
| 0.9 | 0.8159 | 0.8186 | 0.8212 | 0.8238 | 0.8264 | 0.8289 | 0.8315 | 0.8340 | 0.8365 | 0.8389 |
| 1.0 | 0.8413 | 0.8438 | 0.8461 | 0.8485 | 0.8508 | 0.8531 | 0.8554 | 0.8577 | 0.8599 | 0.8621 |
| 1.1 | 0.8643 | 0.8665 | 0.8686 | 0.8708 | 0.8729 | 0.8749 | 0.8770 | 0.8790 | 0.8810 | 0.8830 |
| 1.2 | 0.8849 | 0.8869 | 0.8888 | 0.8907 | 0.8925 | 0.8944 | 0.8962 | 0.8980 | 0.8997 | 0.9015 |
| 1.3 | 0.9032 | 0.9049 | 0.9066 | 0.9082 | 0.9099 | 0.9115 | 0.9131 | 0.9147 | 0.9162 | 0.9177 |
| 1.4 | 0.9192 | 0.9207 | 0.9222 | 0.9236 | 0.9251 | 0.9265 | 0.9279 | 0.9292 | 0.9306 | 0.9319 |
| 1.5 | 0.9332 | 0.9345 | 0.9357 | 0.9370 | 0.9382 | 0.9394 | 0.9406 | 0.9418 | 0.9429 | 0.9441 |
| 1.6 | 0.9452 | 0.9463 | 0.9474 | 0.9484 | 0.9495 | 0.9505 | 0.9515 | 0.9525 | 0.9535 | 0.9545 |
| 1.7 | 0.9554 | 0.9564 | 0.9573 | 0.9582 | 0.9591 | 0.9599 | 0.9608 | 0.9616 | 0.9625 | 0.9633 |
| 1.8 | 0.9641 | 0.9649 | 0.9656 | 0.9664 | 0.9671 | 0.9678 | 0.9686 | 0.9693 | 0.9699 | 0.9706 |
| 1.9 | 0.9713 | 0.9719 | 0.9726 | 0.9732 | 0.9738 | 0.9744 | 0.9750 | 0.9756 | 0.9761 | 0.9767 |
| 2.0 | 0.9772 | 0.9778 | 0.9783 | 0.9788 | 0.9793 | 0.9798 | 0.9803 | 0.9808 | 0.9812 | 0.9817 |
| 2.1 | 0.9821 | 0.9826 | 0.9830 | 0.9834 | 0.9838 | 0.9842 | 0.9846 | 0.9850 | 0.9854 | 0.9857 |
| 2.2 | 0.9861 | 0.9864 | 0.9868 | 0.9871 | 0.9875 | 0.9878 | 0.9881 | 0.9884 | 0.9887 | 0.9890 |
| 2.3 | 0.9893 | 0.9896 | 0.9898 | 0.9901 | 0.9904 | 0.9906 | 0.9909 | 0.9911 | 0.9913 | 0.9916 |
| 2.4 | 0.9918 | 0.9920 | 0.9922 | 0.9925 | 0.9927 | 0.9929 | 0.9931 | 0.9932 | 0.9934 | 0.9936 |
| 2.5 | 0.9938 | 0.9940 | 0.9941 | 0.9943 | 0.9945 | 0.9946 | 0.9948 | 0.9949 | 0.9951 | 0.9952 |
| 2.6 | 0.9953 | 0.9955 | 0.9956 | 0.9957 | 0.9959 | 0.9960 | 0.9961 | 0.9962 | 0.9963 | 0.9964 |
| 2.7 | 0.9965 | 0.9966 | 0.9967 | 0.9968 | 0.9969 | 0.9970 | 0.9971 | 0.9972 | 0.9973 | 0.9974 |
| 2.8 | 0.9974 | 0.9975 | 0.9976 | 0.9977 | 0.9977 | 0.9978 | 0.9979 | 0.9979 | 0.9980 | 0.9981 |
| 2.9 | 0.9981 | 0.9982 | 0.9982 | 0.9983 | 0.9984 | 0.9984 | 0.9985 | 0.9985 | 0.9986 | 0.9986 |
| 3.0 | 0.9987 | 0.9987 | 0.9987 | 0.9988 | 0.9988 | 0.9989 | 0.9989 | 0.9989 | 0.9990 | 0.9990 |

**$Z_{\alpha/2}$ = 1.96**

# Bước 3: Xác định miền bác bỏ (rejection area) giả thuyết $H_0$

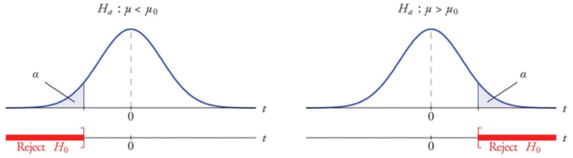


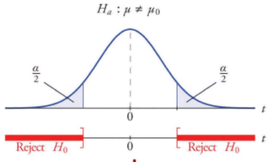


**Xác định 1 - $\alpha$/2 (kiểm định 2 phía)**
**hoặc 1 - $\alpha$ (kiểm định 1 phía).**
**Ví dụ: kiểm định 1 phía với $\alpha$ = 0.05**
**=> 1 - $\alpha$ = 0.95**

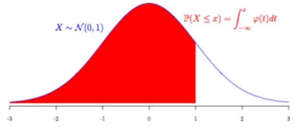


| | 0.00 | 0.01 | 0.02 | 0.03 | 0.04 | 0.05 | 0.06 | 0.07 | 0.08 | 0.09 |
|---|---|---|---|---|---|---|---|---|---|---|
| 0.0 | 0.5000 | 0.5040 | 0.5080 | 0.5120 | 0.5160 | 0.5199 | 0.5239 | 0.5279 | 0.5319 | 0.5359 |
| 0.1 | 0.5398 | 0.5438 | 0.5478 | 0.5517 | 0.5557 | 0.5596 | 0.5636 | 0.5675 | 0.5714 | 0.5753 |
| 0.2 | 0.5793 | 0.5832 | 0.5871 | 0.5910 | 0.5948 | 0.5987 | 0.6026 | 0.6064 | 0.6103 | 0.6141 |
| 0.3 | 0.6179 | 0.6217 | 0.6255 | 0.6293 | 0.6331 | 0.6368 | 0.6406 | 0.6443 | 0.6480 | 0.6517 |
| 0.4 | 0.6554 | 0.6591 | 0.6628 | 0.6664 | 0.6700 | 0.6736 | 0.6772 | 0.6808 | 0.6844 | 0.6879 |
| 0.5 | 0.6915 | 0.6950 | 0.6985 | 0.7019 | 0.7054 | 0.7088 | 0.7123 | 0.7157 | 0.7190 | 0.7224 |
| 0.6 | 0.7257 | 0.7291 | 0.7324 | 0.7357 | 0.7389 | 0.7422 | 0.7454 | 0.7486 | 0.7517 | 0.7549 |
| 0.7 | 0.7580 | 0.7611 | 0.7642 | 0.7673 | 0.7704 | 0.7734 | 0.7764 | 0.7794 | 0.7823 | 0.7852 |
| 0.8 | 0.7881 | 0.7910 | 0.7939 | 0.7967 | 0.7995 | 0.8023 | 0.8051 | 0.8078 | 0.8106 | 0.8133 |
| 0.9 | 0.8159 | 0.8186 | 0.8212 | 0.8238 | 0.8264 | 0.8289 | 0.8315 | 0.8340 | 0.8365 | 0.8389 |
| 1.0 | 0.8413 | 0.8438 | 0.8461 | 0.8485 | 0.8508 | 0.8531 | 0.8554 | 0.8577 | 0.8599 | 0.8621 |
| 1.1 | 0.8643 | 0.8665 | 0.8686 | 0.8708 | 0.8729 | 0.8749 | 0.8770 | 0.8790 | 0.8810 | 0.8830 |
| 1.2 | 0.8849 | 0.8869 | 0.8888 | 0.8907 | 0.8925 | 0.8944 | 0.8962 | 0.8980 | 0.8997 | 0.9015 |
| 1.3 | 0.9032 | 0.9049 | 0.9066 | 0.9082 | 0.9099 | 0.9115 | 0.9131 | 0.9147 | 0.9162 | 0.9177 |
| 1.4 | 0.9192 | 0.9207 | 0.9222 | 0.9236 | 0.9251 | 0.9265 | 0.9279 | 0.9292 | 0.9306 | 0.9319 |
| 1.5 | 0.9332 | 0.9345 | 0.9357 | 0.9370 | 0.9382 | 0.9394 | 0.9406 | 0.9418 | 0.9429 | 0.9441 |
| 1.6 | 0.9452 | 0.9463 | 0.9474 | 0.9484 | 0.9495 | 0.9505 | 0.9515 | 0.9525 | 0.9535 | 0.9545 |
| 1.7 | 0.9554 | 0.9564 | 0.9573 | 0.9582 | 0.9591 | 0.9599 | 0.9608 | 0.9616 | 0.9625 | 0.9633 |
| 1.8 | 0.9641 | 0.9649 | 0.9656 | 0.9664 | 0.9671 | 0.9678 | 0.9686 | 0.9693 | 0.9699 | 0.9706 |
| 1.9 | 0.9713 | 0.9719 | 0.9726 | 0.9732 | 0.9738 | 0.9744 | 0.9750 | 0.9756 | 0.9761 | 0.9767 |
| 2.0 | 0.9772 | 0.9778 | 0.9783 | 0.9788 | 0.9793 | 0.9798 | 0.9803 | 0.9808 | 0.9812 | 0.9817 |
| 2.1 | 0.9821 | 0.9826 | 0.9830 | 0.9834 | 0.9838 | 0.9842 | 0.9846 | 0.9850 | 0.9854 | 0.9857 |
| 2.2 | 0.9861 | 0.9864 | 0.9868 | 0.9871 | 0.9875 | 0.9878 | 0.9881 | 0.9884 | 0.9887 | 0.9890 |
| 2.3 | 0.9893 | 0.9896 | 0.9898 | 0.9901 | 0.9904 | 0.9906 | 0.9909 | 0.9911 | 0.9913 | 0.9916 |
| 2.4 | 0.9918 | 0.9920 | 0.9922 | 0.9925 | 0.9927 | 0.9929 | 0.9931 | 0.9932 | 0.9934 | 0.9936 |
| 2.5 | 0.9938 | 0.9940 | 0.9941 | 0.9943 | 0.9945 | 0.9946 | 0.9948 | 0.9949 | 0.9951 | 0.9952 |
| 2.6 | 0.9953 | 0.9955 | 0.9956 | 0.9957 | 0.9959 | 0.9960 | 0.9961 | 0.9962 | 0.9963 | 0.9964 |
| 2.7 | 0.9965 | 0.9966 | 0.9967 | 0.9968 | 0.9969 | 0.9970 | 0.9971 | 0.9972 | 0.9973 | 0.9974 |
| 2.8 | 0.9974 | 0.9975 | 0.9976 | 0.9977 | 0.9977 | 0.9978 | 0.9979 | 0.9979 | 0.9980 | 0.9981 |
| 2.9 | 0.9981 | 0.9982 | 0.9982 | 0.9983 | 0.9984 | 0.9984 | 0.9985 | 0.9985 | 0.9986 | 0.9986 |
| 3.0 | 0.9987 | 0.9987 | 0.9987 | 0.9988 | 0.9988 | 0.9989 | 0.9989 | 0.9989 | 0.9990 | 0.9990 |

**$Z_\alpha$ = 1.65**

# Bước 4: Xác định giá trị quan sát của tiêu chuẩn kiểm định Z

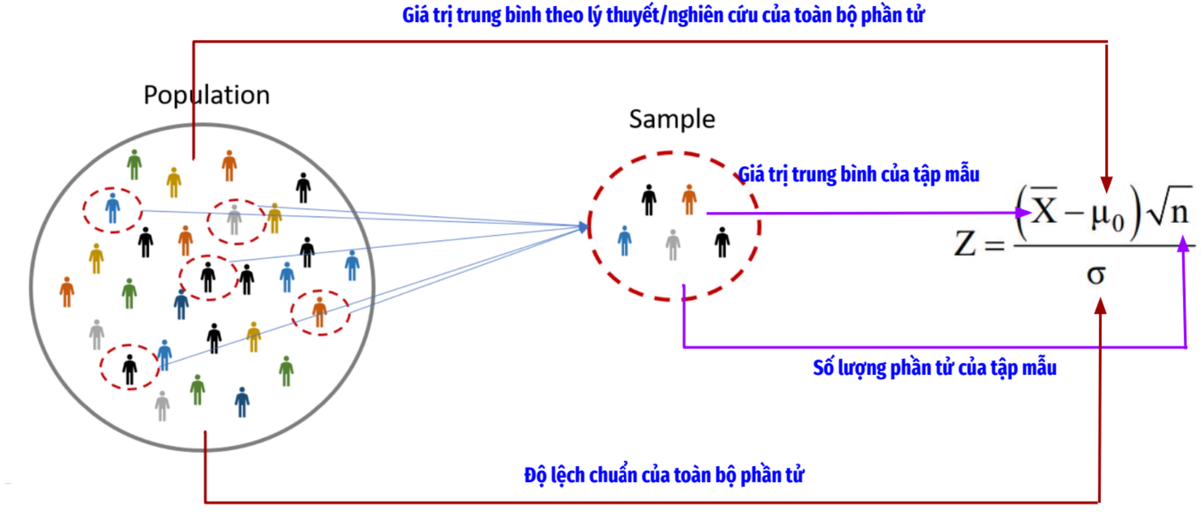

# Bước 5: So sánh giá trị quan sát và giá trị tới hạn

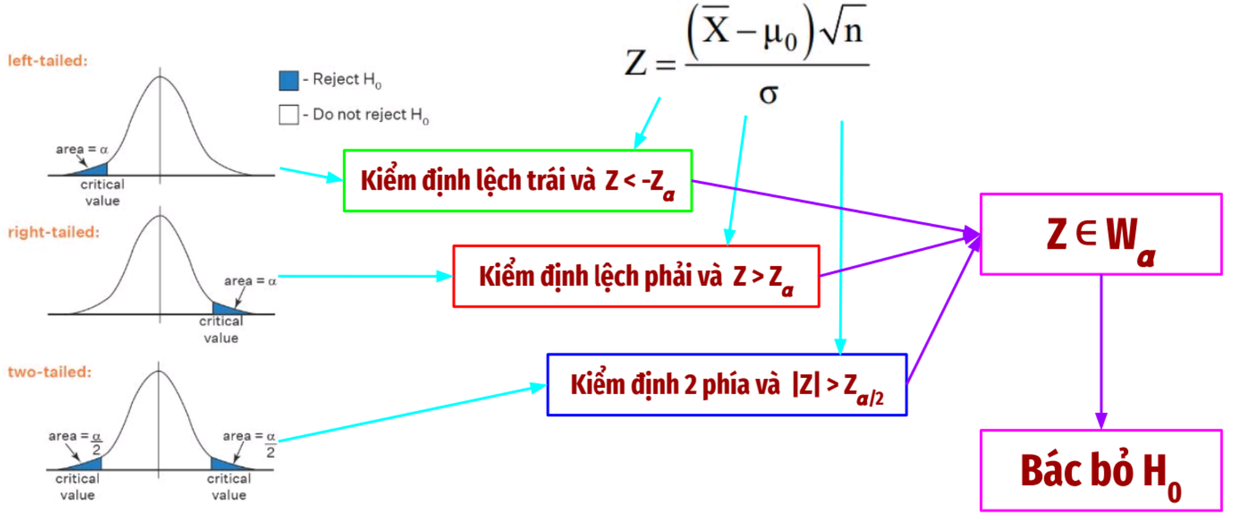

# Trường hợp không biết phương sai của tập đối tượng gốc

# Các thay đổi so với Z-test: Tiêu chuẩn kiểm định

$$Z = \frac{\left(\overline{X} - \mu_0\right)\sqrt{n}}{\sigma}$$

$\sigma^2$ cho trước từ tập gốc

$$T = \frac{\left(\overline{X} - \mu_0\right)\sqrt{n}}{S}$$

$S^2$: Độ lệch chuẩn hiệu chỉnh được tính từ tập mẫu

# Phương sai tổng thể vs phương sai mẫu hiệu chỉnh

| Population Variance | Sample Variance |
| --- | --- |
| $\sigma^2 = \frac{\sum_{i=1}^{N}(x_i - \mu)^2}{N}$ | $s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$ |
| $\sigma^2$ = population variance<br>$x_i$ = value of $i^{th}$ element<br>$\mu$ = population mean<br>$N$ = population size | $s^2$ = sample variance<br>$x_i$ = value of $i^{th}$ element<br>$\bar{x}$ = sample mean<br>$n$ = sample size |

# Các thay đổi so với Z-test: Bảng phân phối

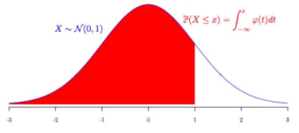


| | 0.00 | 0.01 | 0.02 | 0.03 | 0.04 | 0.05 | 0.06 | 0.07 | 0.08 | 0.09 |
|---|---|---|---|---|---|---|---|---|---|---|
| 0.0 | 0.5000 | 0.5040 | 0.5080 | 0.5120 | 0.5160 | 0.5199 | 0.5239 | 0.5279 | 0.5319 | 0.5359 |
| 0.1 | 0.5398 | 0.5438 | 0.5478 | 0.5517 | 0.5557 | 0.5596 | 0.5636 | 0.5675 | 0.5714 | 0.5753 |
| 0.2 | 0.5793 | 0.5832 | 0.5871 | 0.5910 | 0.5948 | 0.5987 | 0.6026 | 0.6064 | 0.6103 | 0.6141 |
| 0.3 | 0.6179 | 0.6217 | 0.6255 | 0.6293 | 0.6331 | 0.6368 | 0.6406 | 0.6443 | 0.6480 | 0.6517 |
| 0.4 | 0.6554 | 0.6591 | 0.6628 | 0.6664 | 0.6700 | 0.6736 | 0.6772 | 0.6808 | 0.6844 | 0.6879 |
| 0.5 | 0.6915 | 0.6950 | 0.6985 | 0.7019 | 0.7054 | 0.7088 | 0.7123 | 0.7157 | 0.7190 | 0.7224 |
| 0.6 | 0.7257 | 0.7291 | 0.7324 | 0.7357 | 0.7389 | 0.7422 | 0.7454 | 0.7486 | 0.7517 | 0.7549 |
| 0.7 | 0.7580 | 0.7611 | 0.7642 | 0.7673 | 0.7704 | 0.7734 | 0.7764 | 0.7794 | 0.7823 | 0.7852 |
| 0.8 | 0.7881 | 0.7910 | 0.7939 | 0.7967 | 0.7995 | 0.8023 | 0.8051 | 0.8078 | 0.8106 | 0.8133 |
| 0.9 | 0.8159 | 0.8186 | 0.8212 | 0.8238 | 0.8264 | 0.8289 | 0.8315 | 0.8340 | 0.8365 | 0.8389 |
| 1.0 | 0.8413 | 0.8438 | 0.8461 | 0.8485 | 0.8508 | 0.8531 | 0.8554 | 0.8577 | 0.8599 | 0.8621 |
| 1.1 | 0.8643 | 0.8665 | 0.8686 | 0.8708 | 0.8729 | 0.8749 | 0.8770 | 0.8790 | 0.8810 | 0.8830 |
| 1.2 | 0.8849 | 0.8869 | 0.8888 | 0.8907 | 0.8925 | 0.8944 | 0.8962 | 0.8980 | 0.8997 | 0.9015 |
| 1.3 | 0.9032 | 0.9049 | 0.9066 | 0.9082 | 0.9099 | 0.9115 | 0.9131 | 0.9147 | 0.9162 | 0.9177 |
| 1.4 | 0.9192 | 0.9207 | 0.9222 | 0.9236 | 0.9251 | 0.9265 | 0.9279 | 0.9292 | 0.9306 | 0.9319 |
| 1.5 | 0.9332 | 0.9345 | 0.9357 | 0.9370 | 0.9382 | 0.9394 | 0.9406 | 0.9418 | 0.9429 | 0.9441 |
| 1.6 | 0.9452 | 0.9463 | 0.9474 | 0.9484 | 0.9495 | 0.9505 | 0.9515 | 0.9525 | 0.9535 | 0.9545 |
| 1.7 | 0.9554 | 0.9564 | 0.9573 | 0.9582 | 0.9591 | 0.9599 | 0.9608 | 0.9616 | 0.9625 | 0.9633 |
| 1.8 | 0.9641 | 0.9649 | 0.9656 | 0.9664 | 0.9671 | 0.9678 | 0.9686 | 0.9693 | 0.9699 | 0.9706 |
| 1.9 | 0.9713 | 0.9719 | 0.9726 | 0.9732 | 0.9738 | 0.9744 | 0.9750 | 0.9756 | 0.9761 | 0.9767 |
| 2.0 | 0.9772 | 0.9778 | 0.9783 | 0.9788 | 0.9793 | 0.9798 | 0.9803 | 0.9808 | 0.9812 | 0.9817 |
| 2.1 | 0.9821 | 0.9826 | 0.9830 | 0.9834 | 0.9838 | 0.9842 | 0.9846 | 0.9850 | 0.9854 | 0.9857 |
| 2.2 | 0.9861 | 0.9864 | 0.9868 | 0.9871 | 0.9875 | 0.9878 | 0.9881 | 0.9884 | 0.9887 | 0.9890 |
| 2.3 | 0.9893 | 0.9896 | 0.9898 | 0.9901 | 0.9904 | 0.9906 | 0.9909 | 0.9911 | 0.9913 | 0.9916 |
| 2.4 | 0.9918 | 0.9920 | 0.9922 | 0.9925 | 0.9927 | 0.9929 | 0.9931 | 0.9932 | 0.9934 | 0.9936 |
| 2.5 | 0.9938 | 0.9940 | 0.9941 | 0.9943 | 0.9945 | 0.9946 | 0.9948 | 0.9949 | 0.9951 | 0.9952 |
| 2.6 | 0.9953 | 0.9955 | 0.9956 | 0.9957 | 0.9959 | 0.9960 | 0.9961 | 0.9962 | 0.9963 | 0.9964 |
| 2.7 | 0.9965 | 0.9966 | 0.9967 | 0.9968 | 0.9969 | 0.9970 | 0.9971 | 0.9972 | 0.9973 | 0.9974 |
| 2.8 | 0.9974 | 0.9975 | 0.9976 | 0.9977 | 0.9977 | 0.9978 | 0.9979 | 0.9979 | 0.9980 | 0.9981 |
| 2.9 | 0.9981 | 0.9982 | 0.9982 | 0.9983 | 0.9984 | 0.9984 | 0.9985 | 0.9985 | 0.9986 | 0.9986 |
| 3.0 | 0.9987 | 0.9987 | 0.9987 | 0.9988 | 0.9988 | 0.9989 | 0.9989 | 0.9989 | 0.9990 | 0.9990 |

**Giá trị tới hạn**

$Z_a$ -> $T_a^{n-1}$

$Z_{a/2}$ -> $T_{a/2}^{n-1}$

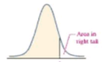


*t*-Distribution
Area in Right Tail

| Degrees of Freedom | 0.25 | 0.20 | 0.15 | 0.10 | 0.05 | 0.025 | 0.02 | 0.01 | 0.005 | 0.0025 | 0.001 | 0.0005 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | 1.000 | 1.376 | 1.963 | 3.078 | 6.314 | 12.706 | 15.894 | 31.821 | 63.657 | 127.321 | 318.309 | 636.619 |
| 2 | 0.816 | 1.061 | 1.386 | 1.886 | 2.920 | 4.303 | 4.849 | 6.965 | 9.925 | 14.089 | 22.327 | 31.599 |
| 3 | 0.765 | 0.978 | 1.250 | 1.638 | 2.353 | 3.182 | 3.482 | 4.541 | 5.841 | 7.453 | 10.215 | 12.924 |
| 4 | 0.741 | 0.941 | 1.190 | 1.533 | 2.132 | 2.776 | 2.999 | 3.747 | 4.604 | 5.598 | 7.173 | 8.610 |
| 5 | 0.727 | 0.920 | 1.156 | 1.476 | 2.015 | 2.571 | 2.757 | 3.365 | 4.032 | 4.773 | 5.893 | 6.869 |
| 6 | 0.718 | 0.906 | 1.134 | 1.440 | 1.943 | 2.447 | 2.612 | 3.143 | 3.707 | 4.317 | 5.208 | 5.959 |
| 7 | 0.711 | 0.896 | 1.119 | 1.415 | 1.895 | 2.365 | 2.517 | 2.998 | 3.499 | 4.029 | 4.785 | 5.408 |
| 8 | 0.706 | 0.889 | 1.108 | 1.397 | 1.860 | 2.306 | 2.449 | 2.896 | 3.355 | 3.833 | 4.501 | 5.041 |
| 9 | 0.703 | 0.883 | 1.100 | 1.383 | 1.833 | 2.262 | 2.398 | 2.821 | 3.250 | 3.690 | 4.297 | 4.781 |
| 10 | 0.700 | 0.879 | 1.093 | 1.372 | 1.812 | 2.228 | 2.359 | 2.764 | 3.169 | 3.581 | 4.144 | 4.587 |
| 11 | 0.697 | 0.876 | 1.088 | 1.363 | 1.796 | 2.201 | 2.328 | 2.718 | 3.106 | 3.497 | 4.025 | 4.437 |
| 12 | 0.695 | 0.873 | 1.083 | 1.356 | 1.782 | 2.179 | 2.303 | 2.681 | 3.055 | 3.428 | 3.930 | 4.318 |
| 13 | 0.694 | 0.870 | 1.079 | 1.350 | 1.771 | 2.160 | 2.282 | 2.650 | 3.012 | 3.372 | 3.852 | 4.221 |
| 14 | 0.692 | 0.868 | 1.076 | 1.345 | 1.761 | 2.145 | 2.264 | 2.624 | 2.977 | 3.326 | 3.787 | 4.140 |
| 15 | 0.691 | 0.866 | 1.074 | 1.341 | 1.753 | 2.131 | 2.249 | 2.602 | 2.947 | 3.286 | 3.733 | 4.073 |
| 16 | 0.690 | 0.865 | 1.071 | 1.337 | 1.746 | 2.120 | 2.235 | 2.583 | 2.921 | 3.252 | 3.686 | 4.015 |
| 17 | 0.689 | 0.863 | 1.069 | 1.333 | 1.740 | 2.110 | 2.224 | 2.567 | 2.898 | 3.222 | 3.646 | 3.965 |
| 18 | 0.688 | 0.862 | 1.067 | 1.330 | 1.734 | 2.101 | 2.214 | 2.552 | 2.878 | 3.197 | 3.610 | 3.922 |
| 19 | 0.688 | 0.861 | 1.066 | 1.328 | 1.729 | 2.093 | 2.205 | 2.539 | 2.861 | 3.174 | 3.579 | 3.883 |
| 20 | 0.687 | 0.860 | 1.064 | 1.325 | 1.725 | 2.086 | 2.197 | 2.528 | 2.845 | 3.153 | 3.552 | 3.850 |
| 21 | 0.686 | 0.859 | 1.063 | 1.323 | 1.721 | 2.080 | 2.189 | 2.518 | 2.831 | 3.135 | 3.527 | 3.819 |
| 22 | 0.686 | 0.858 | 1.061 | 1.321 | 1.717 | 2.074 | 2.183 | 2.508 | 2.819 | 3.119 | 3.505 | 3.792 |
| 23 | 0.685 | 0.858 | 1.060 | 1.319 | 1.714 | 2.069 | 2.177 | 2.500 | 2.807 | 3.104 | 3.485 | 3.768 |
| 24 | 0.685 | 0.857 | 1.059 | 1.318 | 1.711 | 2.064 | 2.172 | 2.492 | 2.797 | 3.091 | 3.467 | 3.745 |
| 25 | 0.684 | 0.856 | 1.058 | 1.316 | 1.708 | 2.060 | 2.167 | 2.485 | 2.787 | 3.078 | 3.450 | 3.725 |
| 26 | 0.684 | 0.856 | 1.058 | 1.315 | 1.706 | 2.056 | 2.162 | 2.479 | 2.779 | 3.067 | 3.435 | 3.707 |
| 27 | 0.684 | 0.855 | 1.057 | 1.314 | 1.703 | 2.052 | 2.158 | 2.473 | 2.771 | 3.057 | 3.421 | 3.690 |
| 28 | 0.683 | 0.855 | 1.056 | 1.313 | 1.701 | 2.048 | 2.154 | 2.467 | 2.763 | 3.047 | 3.408 | 3.674 |
| 29 | 0.683 | 0.854 | 1.055 | 1.311 | 1.699 | 2.045 | 2.150 | 2.462 | 2.756 | 3.038 | 3.396 | 3.659 |
| 30 | 0.683 | 0.854 | 1.055 | 1.310 | 1.697 | 2.042 | 2.147 | 2.457 | 2.750 | 3.030 | 3.385 | 3.646 |
| 31 | 0.682 | 0.853 | 1.054 | 1.309 | 1.696 | 2.040 | 2.144 | 2.453 | 2.744 | 3.022 | 3.375 | 3.633 |
| 32 | 0.682 | 0.853 | 1.054 | 1.309 | 1.694 | 2.037 | 2.141 | 2.449 | 2.738 | 3.015 | 3.365 | 3.622 |
| 33 | 0.682 | 0.853 | 1.053 | 1.308 | 1.692 | 2.035 | 2.138 | 2.445 | 2.733 | 3.008 | 3.356 | 3.611 |
| 34 | 0.682 | 0.852 | 1.052 | 1.307 | 1.691 | 2.032 | 2.136 | 2.441 | 2.728 | 3.002 | 3.348 | 3.601 |
| 35 | 0.682 | 0.852 | 1.052 | 1.306 | 1.690 | 2.030 | 2.133 | 2.438 | 2.724 | 2.996 | 3.340 | 3.591 |
| 36 | 0.681 | 0.852 | 1.052 | 1.306 | 1.688 | 2.028 | 2.131 | 2.434 | 2.719 | 2.990 | 3.333 | 3.582 |
| 37 | 0.681 | 0.851 | 1.051 | 1.305 | 1.687 | 2.026 | 2.129 | 2.431 | 2.715 | 2.985 | 3.326 | 3.574 |
| 38 | 0.681 | 0.851 | 1.051 | 1.304 | 1.686 | 2.024 | 2.127 | 2.429 | 2.712 | 2.980 | 3.319 | 3.566 |
| 39 | 0.681 | 0.851 | 1.050 | 1.304 | 1.685 | 2.023 | 2.125 | 2.426 | 2.708 | 2.976 | 3.313 | 3.558 |
| 40 | 0.681 | 0.851 | 1.050 | 1.303 | 1.684 | 2.021 | 2.123 | 2.423 | 2.704 | 2.971 | 3.307 | 3.551 |
| 50 | 0.679 | 0.849 | 1.047 | 1.299 | 1.676 | 2.009 | 2.109 | 2.403 | 2.678 | 2.937 | 3.261 | 3.496 |
| 60 | 0.679 | 0.848 | 1.045 | 1.296 | 1.671 | 2.000 | 2.099 | 2.390 | 2.660 | 2.915 | 3.232 | 3.460 |
| 70 | 0.678 | 0.847 | 1.044 | 1.294 | 1.667 | 1.994 | 2.093 | 2.381 | 2.648 | 2.899 | 3.211 | 3.435 |
| 80 | 0.678 | 0.846 | 1.043 | 1.292 | 1.664 | 1.990 | 2.088 | 2.374 | 2.639 | 2.887 | 3.195 | 3.416 |
| 90 | 0.677 | 0.846 | 1.042 | 1.291 | 1.662 | 1.987 | 2.084 | 2.368 | 2.632 | 2.878 | 3.183 | 3.402 |
| 100 | 0.677 | 0.845 | 1.042 | 1.290 | 1.660 | 1.984 | 2.081 | 2.364 | 2.626 | 2.871 | 3.174 | 3.390 |
| 1000 | 0.675 | 0.842 | 1.037 | 1.282 | 1.646 | 1.962 | 2.056 | 2.330 | 2.581 | 2.813 | 3.098 | 3.300 |
| $z$ | 0.674 | 0.842 | 1.036 | 1.282 | 1.645 | 1.960 | 2.054 | 2.326 | 2.576 | 2.807 | 3.090 | 3.291 |
| Degrees of Freedom | 0.25 | 0.20 | 0.15 | 0.10 | 0.05 | 0.025 | 0.02 | 0.01 | 0.005 | 0.0025 | 0.001 | 0.0005 |

*t*-Distribution
Area in Right Tail

# Z-test vs T-test

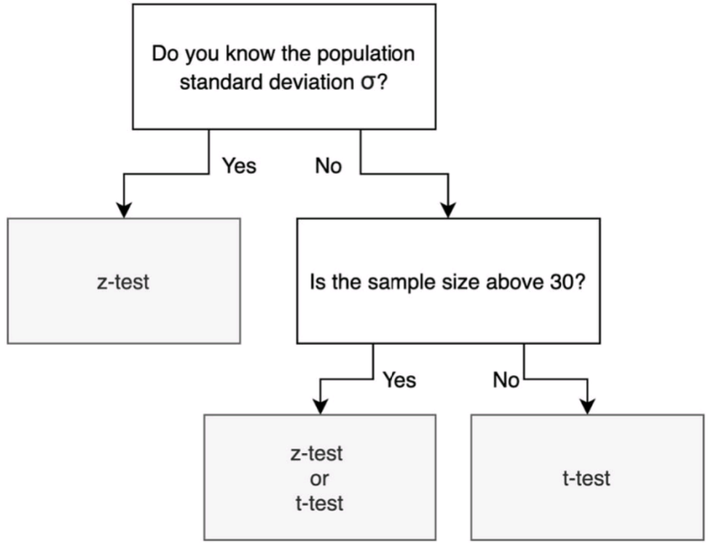

# Kiểm định giả thuyết

1. Trọng lượng mỗi gói sản phẩm do 1 nhà máy sản xuất là biến ngẫu nhiên có kỳ vọng là 453g và độ lệch chuẩn là 36g. Kiểm tra ngẫu nhiên 81 gói sản phẩm thì thấy trọng lượng trung bình là 448g. Với mức ý nghĩa 5% có thể kết luận các sản phẩm đóng gói bị thiếu hay không?
2. Một hãng bảo hiểm thông báo rằng số tiền trung bình hãng chi trả cho khách hàng bị tai nạn ô tô là 8500$. Để kiểm tra lại thông báo này, người ta kiểm tra ngẫu nhiên hồ sơ chi trả của 25 trường hợp thì thấy số tiền trung bình hãng bảo hiểm chi trả là 8900$. Giả sử số tiền hãng bảo hiểm chi trả tuân theo phân phối chuẩn với độ lệch chuẩn là 2600$, hãy kiểm định lại thông báo của hãng bảo hiểm với mức ý nghĩa 5%
3. Một ông chủ cửa hàng thùng cho rằng dung tích trung bình của thùng là 55 lít (độ lệch chuẩn là 6 lít). Người ta kiểm tra ngẫu nhiên 36 thùng thì thấy dung tích trung bình chỉ là 49 lít. Với mức ý nghĩa 0.1% có thể kết luận ông chủ nói điêu hay không?
4. Nếu máy móc hoạt động bình thường thì trọng lượng sản phẩm là biến ngẫu nhiên với giá trị trung bình là 100g và độ lệch chuẩn là 2g. Sau 1 thời gian chạy thì người ta nghi ngờ trọng lượng của sản phẩm có xu hướng tăng lên. Người ta cân thử 100 sản phẩm thì trọng lượng trung bình của chúng là 100.4g. Với mức ý nghĩa là 5%, hãy kết luận về điều nghi ngờ trên

# Kiểm định giả thuyết

1. Trong 1 quần thể dân cư, theo nghiên cứu thì IQ trung bình của người dân là 100, với độ lệch chuẩn là 15. 1 nhóm các nhà khoa học muốn kiểm tra xem 1 loại thuốc mới có ảnh hưởng tích cực hay tiêu cực gì đến trí thông minh của con người hay không. Họ cho ngẫu nhiên 30 người thuộc quần thể dân cư kia sử dụng thuốc, và kết quả là IQ trung bình sau khi sử dụng thuốc của 30 người này là 140. Với mức ý nghĩa 5% liệu có thể kết luận là loại thuốc này có tác động đến IQ của con người không?
2. Theo nhà sản xuất, tuổi thọ trung bình của 1 loại bóng đèn là 1600 giờ, với độ lệch chuẩn là 90 giờ. Người ta kiểm tra ngẫu nhiên 100 bóng đèn thì thấy tuổi thọ trung bình là 1580 giờ. Với mức ý nghĩa 5% liệu có thể kết luận là công ty không trung thực không?
3. 1 công ty bảo hiểm đang xem xét lại hoạt động của mình. Ban đầu họ đánh giá rằng trung bình họ sẽ phải trả cho người bị tai nạn tối đa khoảng 180k$, với độ lệch chuẩn là 50k$. Nhưng trong 1 nghiên cứu gần đây được tiến hành trên 40 khách hàng bị tai nạn, số tiền trung bình công ty phải chi trả lên đến 195k$. Với mức ý nghĩa là 5%, hãy kiểm định xem liệu công ty bảo hiểm có đang chịu thiệt với chính sách hiện tại không?

# Kiểm định giả thuyết

1. Trong điều kiện chăn nuôi bình thường, lượng  sữa trung bình của 1 con bò là 14 lít/ngày. Nghi ngờ điều kiện chăn nuôi kém đi làm cho lượng sữa thu được giảm xuống, người ta kiểm tra ngẫu nhiên 25 con bò và tính được lượng sữa trung bình của mỗi con chỉ là 12.5 lít/ngày và độ lệch chuẩn hiệu chỉnh  là 2.5 lít. Giả sử lượng sữa bò là 1 biến ngẫu nhiên theo phân phối chuẩn, với mức ý nghĩa 5% hãy kiểm định nghi ngờ trên
2. 1 giống lúa ngày trước được cho là có năng suất 39 tạ/ha. Người ta thu hoạch thử 41 thửa ruộng trồng giống lúa này, và thấy rằng năng suất trung bình là 39.5 tạ/ha, với độ lệch hiệu chỉnh 1.2 tạ/ha. Biết rằng năng suất lúa là biến ngẫu nhiên theo phân phối chuẩn. Với mức ý nghĩa 5%, liệu có thể cho rằng năng suất lúa đã tăng lên so với trước hay không?
3. 1 máy đóng gói các sản phẩm có khối lượng tiêu chuẩn là 1kg. Nghi ngờ máy móc hoạt động không bình thường, người ta chọn ra ngẫu nhiên 100 sản phẩm và đem cân thì thấy như sau:

| Khối lượng | 0.95 | 0.97 | 0.99 | 1.01 | 1.03 | 1.05 |
|---|---|---|---|---|---|---|
| Số gói | 9 | 31 | 40 | 15 | 3 | 2 |

Với mức ý nghĩa 5%, hãy kết luận về nghi ngờ trên

# Kiểm định giả thuyết

1. 1 nhà nhân chủng học cho rằng chiều cao trung bình của 1 bộ tộc người thiểu số là 160cm. Người ta chọn ra ngẫu nhiên 16 người của bộ tộc đó thì thấy chiều cao trung bình là 164.25cm, với độ lệch chuẩn hiệu chỉnh là 6.25cm. Với mức ý nghĩa 5% liệu có thể kết luận rằng chiều cao trung bình của bộ tộc ấy lớn hơn 160cm hay không? (Giả sử chiều cao của người trong bộ tộc tuân theo phân phối chuẩn)
2. Độ bền của 1 loại dây thép sản xuất theo công nghệ cũ là 150. Sau khi cải tiến kỹ thuật người ta lấy mẫu gồm 100 sợi dây thép để thử độ bền thì thấy độ bền trung bình là 185 với độ lệch chuẩn là 25. Với mức ý nghĩa là 5% liệu có thể khẳng định là công nghệ mới tốt hơn công nghệ cũ hay không?
3. 1 công ty có hệ thống máy tính có thể xử lý được 1200 hóa đơn trong 1 giờ. Công ty mới nhập 1 hệ thống máy tính mới. Chạy test thử hệ thống mới này trong 40 giờ thì thấy số hóa đơn được xử lý trung bình trong 1 giờ là 1260 hóa đơn với độ lệch chuẩn hiệu chỉnh là 215. Với mức ý nghĩa 5% hãy kiểm định xem là hệ thống mới này có tốt hơn hệ thống cũ hay không?

# Kiểm định giả thuyết

1. 1 công ty sản xuất hạt giống tuyên bố rằng 1 loại giống mới của họ có năng suất trung bình là 21.5 tạ/ha. Người ta gieo thử giống mới này tại 16 vườn thí nghiệm và thu được kết quả như sau:

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| 19.2 | 18.7 | 22.4 | 20.3 | 16.8 | 25.1 | 17.0 | 15.8 |
| 21.0 | 18.6 | 23.7 | 24.1 | 23.4 | 19.8 | 21.7 | 18.9 |

Biết rằng năng suất của giống cây này là biến ngẫu nhiên tuân theo phân phối chuẩn. Với mức ý nghĩa 5% hãy kiểm định xem quảng cáo của công ty trên có đúng không

2. 1 cửa hàng thực phẩm cho rằng trung bình mỗi vị khách tiêu 25k/ngày mua thực phẩm. Để kiểm chứng hôm nay cửa hàng chọn ra ngẫu nhiên 15 vị khách và thấy sức tiêu trung bình của họ là 24k/ngày và độ lệch chuẩn hiệu chỉnh là 2k. Biết sức mua của khách là biến ngẫu nhiên tuân theo phân phối chuẩn. Với mức ý nghĩa 5%, hãy kiểm tra xem liệu có phải sức mua của khách hàng hiện nay đã giảm sút không?